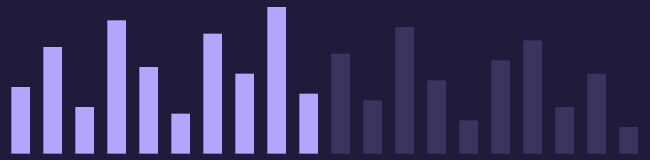
IIC3633 SISTEMAS RECOMENDADORES · PRESENTACIÓN DE PAPER



# Contextual and Sequential User Embeddings for Large-Scale Music Recommendation

CoSeRNN · Hansen, Hansen, Maystre, Mehrotra, Brost, Tomasi y Lalmas
Spotify y Universidad de Copenhague · RecSys 2020

Presentan Catalina Rozas

MOTIVACIÓN

# La música no se recomienda como una película

### Tracks cortos

Se escuchan varios seguidos, en sesiones de unas 10 canciones.

### Repetición

Cada sesión repite mucho de lo escuchado hace poco.

### Contexto

Lo que quieres oír cambia con la hora, el día y el dispositivo.

### Skips

Saltar una canción es la señal negativa más clara que deja el usuario.

LA PREGUNTA DEL PAPER

Al comienzo de una sesión, antes de cualquier clic, ¿qué tracks va a escuchar este usuario?

TIPO DE SISTEMA

# Un recomendador secuencial y contextual, basado en embeddings

- **Feedback implícito.** Aprende de plays y skips, no de ratings.
- **Sequence y session-aware.** Una RNN modela la secuencia de sesiones.
- **Context-aware.** Usa día, hora y dispositivo de la sesión que empieza.
- **Basado en embeddings.** Usuarios y tracks viven en el mismo espacio vectorial.
- **Colaborativo de fondo.** Los embeddings de tracks salen de playlists de muchos usuarios. No usa audio ni metadata.

CÓMO FUNCIONA

1 Abres la app

2 Lee tu contexto y tu última sesión

3 Calcula tu vector de sesión u

4 Trae los tracks más cercanos a u

DATOS

# 200 mil usuarios de Spotify, dos meses de historial

**200k**

usuarios premium, abril y mayo de 2019

**220**

sesiones por usuario en promedio

**~10**

tracks por sesión en promedio

**20 min**

de inactividad separan una sesión de la siguiente

### Qué se sabe de cada sesión

- Día de la semana y hora de inicio
- Dispositivo: mobile, desktop, speaker, web o tablet
- Tracks escuchados y tracks saltados
- Fuente: playlist propia, top charts, etc.
- Tiempo desde la sesión anterior

REPRESENTACIÓN

# Todo vive en un espacio de 40 dimensiones

**1 · Tracks**

word2vec entrenado sobre playlists de usuarios. Dos tracks quedan cerca si suelen aparecer juntos.

**2 · Sesiones**

Promedio normalizado de los primeros 10 tracks. Tres versiones: **s** todos, $\mathbf{s}^{+}$ escuchados, $\mathbf{s}^{-}$ saltados.

**3 · Usuario**

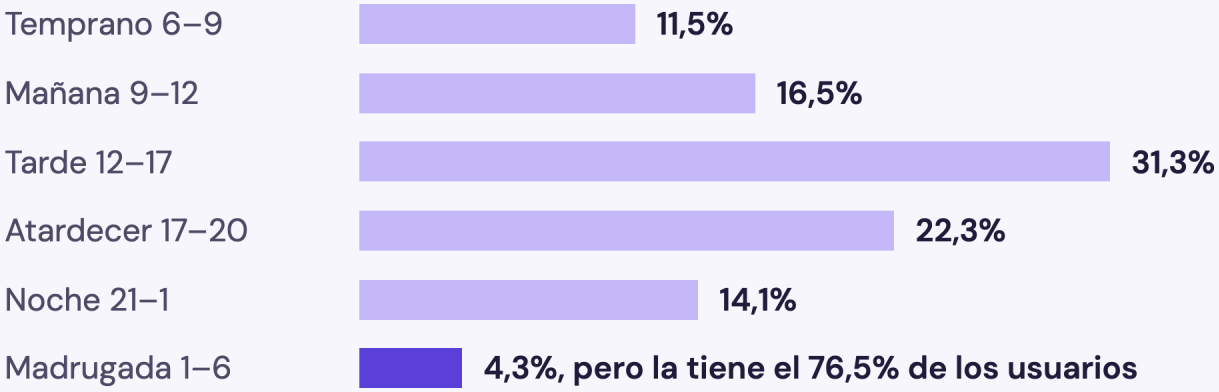
Un vector **u** en el mismo espacio. La relevancia es un producto punto y recomendar es buscar vecinos cercanos.

**Decisión clave:** los embeddings de tracks quedan fijos y el modelo solo aprende el del usuario. Por eso escala a millones de tracks.

RQ1 · ¿EL CONSUMO DEPENDE DEL CONTEXTO?

# Sí, y los contextos poco frecuentes son los más distintos

### Sesiones por franja horaria




## 88,3% mobile

Aun así, casi la mitad de los usuarios tiene sesiones en desktop.

## Más variedad

En madrugada, temprano y fuera del celular la música es menos homogénea.

## Mismo contexto

La sesión más parecida de un usuario suele compartir hora o dispositivo.

HALLAZGO CLAVE

# Mientras más se aleja una sesión de los gustos promedio del usuario, más canciones salta.

La correlación entre skip rate y similitud usuario–sesión es siempre negativa, y se vuelve más fuerte en sesiones con más skips. Anticipar estas sesiones “raras” es una oportunidad para mejorar la satisfacción.

RQ2 · EL MODELO

# CoSeRNN: gustos de largo plazo más un ajuste por sesión

### Entradas
Contexto actual: día, hora, dispositivo. Sesión anterior: $s^{+}$, $s^{-}$, n° de tracks, fuente y Δt.

→

### Capas FC
Dos capas ReLU transforman las features. Una ruta play y otra skip.

→

### 2 LSTM
Una por ruta. Recuerdan toda la secuencia de sesiones del usuario.

→

### Offset û
Combina ambas rutas: el desvío propio de esta sesión y contexto.

→

### Fusión
Pesos de atención mezclan û con ū y entregan el vector final u.

**ū · gustos de largo plazo**

Promedio ponderado de todas las sesiones pasadas, con más peso a las recientes. Si la RNN duda, la atención vuelve a ū.

**Salida**

Con u se buscan los tracks más cercanos en el espacio, por vecinos aproximados, apenas se abre la app.

ENTRENAMIENTO

# Acercar u a lo que el usuario sí escuchó

$$\ell = \Sigma \left( 1 - u^{\top} s^{+} \right)$$

Se maximiza la similitud coseno entre el vector predicho y el promedio de los tracks escuchados. Como ambos tienen norma 1, el coseno es un simple producto punto.

### Setup

| Parámetro | Valor |
|---|---|
| Optimizador | Adam |
| Test | Últimas 2 semanas |
| Validación | 5 días previos |
| Learning rate | 0,0005 |
| Celdas LSTM | 400 |
| Batch | 256 |

EVALUACIÓN

# Dos tareas de ranking contra ocho baselines

### Session ranking

Entre las últimas K sesiones del usuario, con K = 20 y 50, ¿qué tan arriba queda la sesión real?

**MRR y rank promedio**

### Track ranking

Entre los K tracks más recientes del usuario, con K = 25 y 100, ¿quedan arriba los que sí escucha?

**mAP y Recall@10**

| | | | | | | | |
|---|---|---|---|---|---|---|---|
| **Heurísticas** | Last, any cxt | Last, same cxt | Avg, any cxt | Avg, same cxt | Popularity | | |
| **Estado del arte** | RRN | LatentCross | JODIE | **Cotas** | Oracle half | Oracle full | |

RESULTADOS

# CoSeRNN gana en todas las métricas

**Mejora sobre JODIE**

**+15,7%**
MRR, session ranking K = 50

**+10,9%**
Recall@10, track ranking K = 100

**+8,6%**
mAP, track ranking K = 100

| Modelo | Coseno | MRR | mAP | R@10 |
|---|---|---|---|---|
| Last, any cxt | 0,653 | 0,113 | 0,130 | 0,137 |
| Avg, any cxt | 0,680 | 0,103 | 0,123 | 0,129 |
| JODIE | 0,697 | 0,130 | 0,145 | 0,164 |
| CoSeRNN | 0,712 | 0,151 | 0,157 | 0,182 |
| Oracle half | 0,708 | 0,371 | 0,582 | 0,616 |

Diferencias significativas, t-test pareado $p < 0{,}001$. Ojo con Oracle half: menos coseno que CoSeRNN pero rankea mucho mejor, más coseno no implica mejor ranking.

ABLACIÓN

# De dónde viene la mejora

**Por contexto**

## ≈ 28%

más MRR que JODIE en sesiones web. Las mayores ganancias están en contextos poco frecuentes como web y madrugada.

**Play vs skip**

## +11,9%

de Recall@10 al separar escuchados y saltados en vez de promediarlos todos juntos.

**Intención**

## +15,6%

de Recall@10 si además se supiera la fuente de la sesión actual. Pero ya no sirve para recomendar al abrir la app.

El contexto actual es lo que más sube el coseno; la info de la sesión anterior es lo que más ayuda a rankear tracks. **Secuencia y contexto se necesitan juntos.**

DEMO EN VIVO · PYTHON COSERNN_DEMO.PY --RAPIDO

# Implementamos CoSeRNN en Python

| Modelo | Coseno | MRR@20 | R@10 |
|---|---|---|---|
| Last, any cxt | 0,579 | 0,174 | 0,189 |
| Avg, same cxt | 0,687 | 0,197 | 0,120 |
| CoSeRNN sin contexto | 0,711 | 0,190 | 0,126 |
| CoSeRNN | 0,729 | 0,245 | 0,151 |

Datos sintéticos con la estructura del paper: 800 usuarios × 60 sesiones. CoSeRNN gana en session ranking, +24% de MRR, y sacarle el contexto le quita casi todo. En track ranking gana Last, porque nuestros embeddings casi no distinguen canciones dentro de un mismo género.

MISMO USUARIO, DOS CONTEXTOS

Lunes 08:00 · celular

**Clásica**

Lo que quería: Clásica 39%

Sábado 23:00 · parlante

**Jazz**

Lo que quería: Jazz 24%

ANÁLISIS CRÍTICO

# Lo que convence y lo discutible

## Fortalezas

- Problema realista: recomendar al abrir la app, sin ninguna interacción previa
- Escala bien: un vector por usuario y búsqueda de vecinos aproximados
- Embeddings de tracks desacoplados y reutilizables por otros modelos
- Ablaciones claras y código público

## Limitaciones

- Dataset privado, solo 2 meses y solo premium: difícil de replicar
- Contexto acotado a día, hora y dispositivo
- Track ranking solo entre tracks ya escuchados: no mide descubrimiento
- Solo evaluación offline, sin A/B test con usuarios reales

DISCUSIÓN

## ¿Cómo le iría con usuarios nuevos o con poco historial?

### Ventajas

- El contexto sirve desde la primera sesión
- La atención se apoya en ū cuando duda
- Embeddings de tracks fijos, sin reentrenar

### Desventajas

- Sin historial, ū y la LSTM parten casi vacíos
- El estado inicial solo usa la edad del usuario
- El paper no evalúa cold start

## ¿Qué pasa si se agregan contextos como actividad, ánimo o ubicación?

### Ventajas

- Fácil: se concatena al vector de entrada
- Las mayores ganancias ya están en contextos raros
- Explicarían sesiones raras con más skips

### Desventajas

- Ubicación y ánimo exigen permisos y privacidad
- El ánimo no se observa, habría que inferirlo
- Más features escasas piden más datos

CONCLUSIÓN

# Modelar los gustos a nivel de sesión, con contexto y secuencia, supera al estado del arte en más de 10% y escala a millones de tracks.

Trabajo futuro según los autores: embeddings con hashing para ganar eficiencia.

¿Preguntas?