PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

LatentR^3

Reinforced Latent Reasoning For LLM-Based Recommendation

Un framework de entrenamiento de extremo a extremo (end-to-end) que aprovecha aprendizaje reforzado para optimizar el razonamiento latente, sin depender de datos de razonamiento paso a paso (Chain-Of-Thought)

14th International Conference on Learning Representations | ICLR 2026

Yang Zhang · Wenxin Xu · Xiaoyan Zhao · Wenjie Wang · Fuli Feng · Xiangnan He · Tat-Seng Chua

National University of Singapore, University of Science and Technology of China, The Chinese University of Hong Kong

IIC3633 · Sistemas Recomendadores 2026-2 · Denis Parra

Mauricio Annicchiarico · Cristian Troncoso · Tomás Salinas

Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

07 · EVALUACIÓN Y RESULTADOS

08 · CONCLUSIÓN

Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

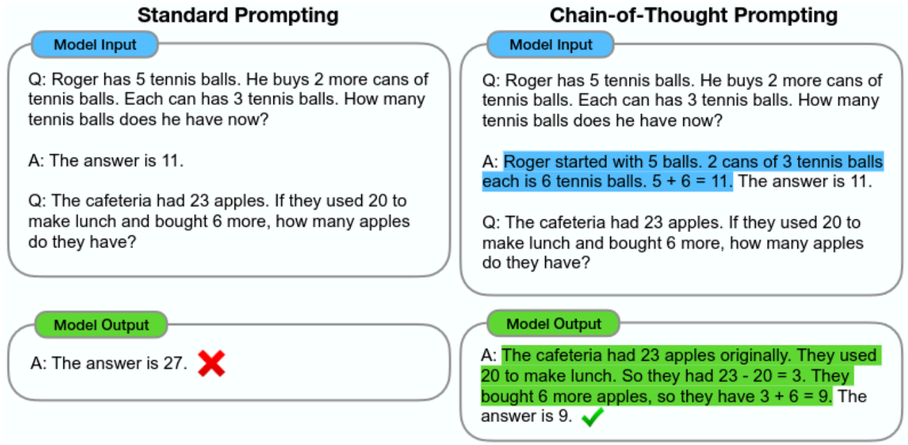
07 · EVALUACIÓN Y RESULTADOS

08 · CONCLUSIÓN

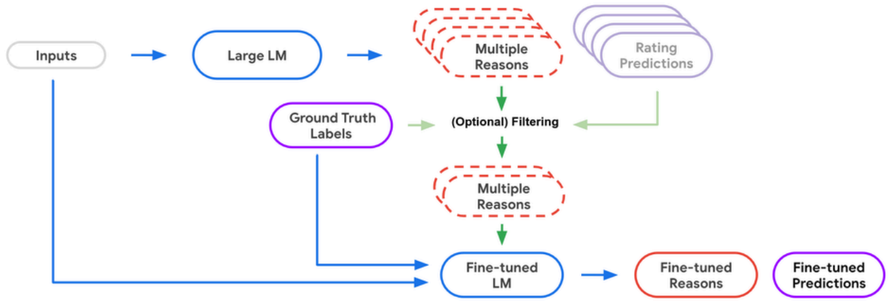
Razonamiento, LLMs y recomendación

En los últimos años se ha observado que los grandes modelos de lenguaje demuestran capacidades de razonamiento similares a las de los humanos. En sistemas de recomendación, el interés yace en poder razonar los intereses del usuario en base a su historial de interacciones.

Beneficios de Chain-of-Thought prompting



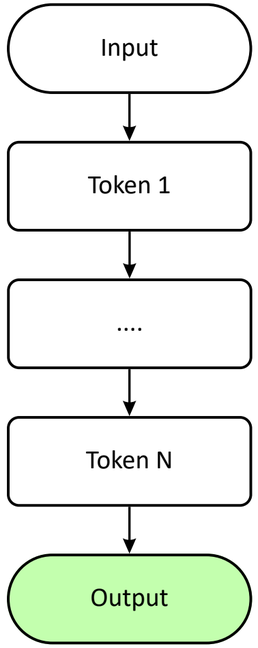
Fine-tuning de un modelo con razonamiento



Fuente: Wei et al., 2022 y Tsai et al., 2024

Limitaciones del Fine-Tuning con CoT (Chain-Of-Thought) en Recomendación

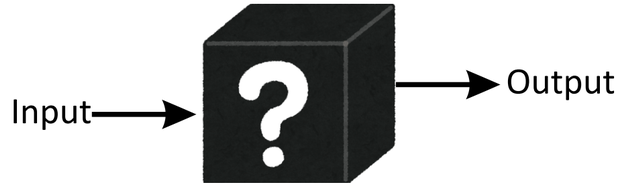
Alta latencia y costos de inferencia



La generación de tokens textuales en gran cantidad genera cuellos de botella en sistemas de recomendación en producción

Dificultad para Obtener Datos CoT de Calidad

Feedback implícito: Las interacciones del usuario solo registran el resultado final, no hay un rastro del pensamiento explicito.



Alta subjetividad: Gustos personales variables provocan que la anotación manual de datos CoT sea poco confiable y costosa.

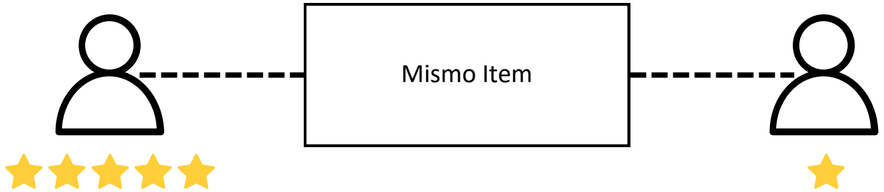


Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

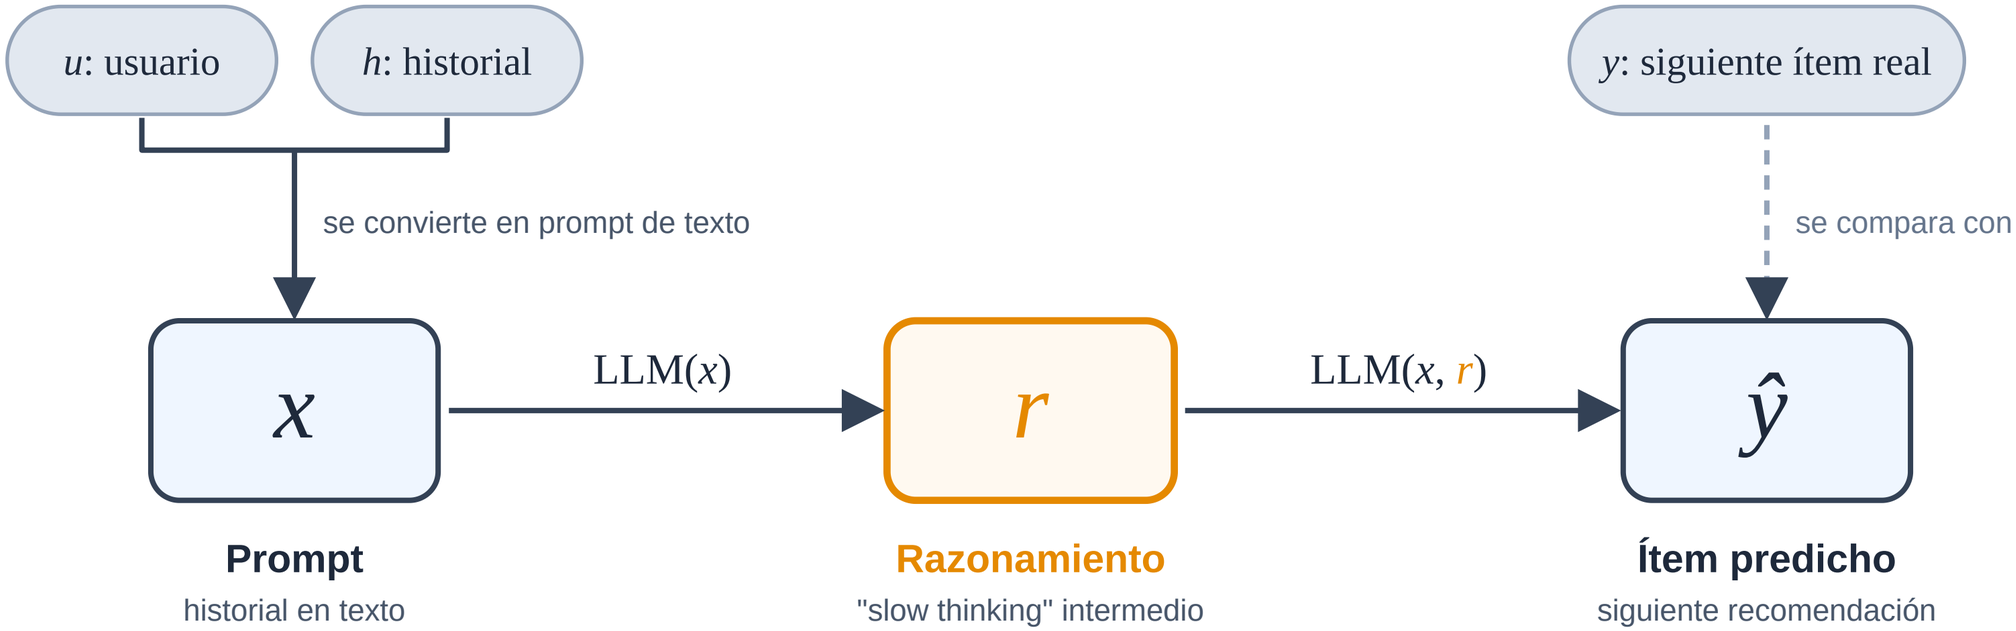
05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

07 · EVALUACIÓN Y RESULTADOS

08 · CONCLUSIÓN

Definición del problema: *Next-Item Recommendation*



Objetivo: aprender ***r*** solo desde los datos, sin anotaciones de chain-of-thought

Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

07 · EVALUACIÓN Y RESULTADOS

08 · CONCLUSIÓN

Principales contribuciones del paper

1. EFICIENCIA: destacan que razonamiento latente permite menor latencia, sin datos explícitos de CoT, ya que los estados latentes tienen una densidad de información mucho mayor a los tokens textuales.

2. MÉTODO: proponen LatentR^3, un framework de aprendizaje por refuerzo con nuevas estrategias de recompensa y optimización.

3. VALIDACIÓN: se observan mejoras significativas en el rendimiento de recomendación, validadas experimentalmente.

Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

07 · EVALUACIÓN Y RESULTADOS

08 · CONCLUSIÓN

Evolución hacia el Razonamiento Latente en Recomendación

Recomendación Generativa Directa

BIGRec · D3

Idea

Realizan fine-tuning de LLMs para predecir directamente el siguiente ítem a partir del historial del usuario

Limitación

Operan mediante pensamiento directo, sin etapas intermedias de reflexión, lo que limita su capacidad para capturar relaciones y preferencias complejas del usuario

Razonamiento Latente en Espacio Continuo

Implicit CoT

Idea

Reemplazan el texto autorregresivo por vectores de estado oculto (tokens latentes continuos), comprimiendo el pensamiento para lograr una inferencia ultrarrápida

Limitación

Los métodos de razonamiento latente en dominios generales dependen de datos CoT explícitos para entrenarse, los cuales no existen en el ámbito de recomendación

Aprendizaje por Refuerzo sin CoT

GRPO

Idea

En RL se elimina la necesidad de un modelo de valor para evaluar la calidad de las respuestas, se utiliza un muestreo en grupo para estimar la ventaja de cada respuesta respecto a sus pares

Oportunidad

Demuestran que el Aprendizaje por Refuerzo puede guiar el descubrimiento de estrategias de razonamiento basándose únicamente en recompensas por el resultado final (rule-based rewards), sin supervisión paso a paso

Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

07 · EVALUACIÓN Y RESULTADOS

08 · CONCLUSIÓN

Group Relative Policy Optimization (GRPO)

1

¿Qué es?

Variante del algoritmo de RL PPO, que elimina la necesidad de una red neuronal para estimar la recompensa futura

2

Mecanismo Clave

Para una misma pregunta, el modelo genera un grupo de G respuestas distintas, y en lugar de evaluar respuestas con un modelo de valor individual, calcula la calidad de cada respuesta comparándola con el promedio y desviación estándar del propio grupo

3

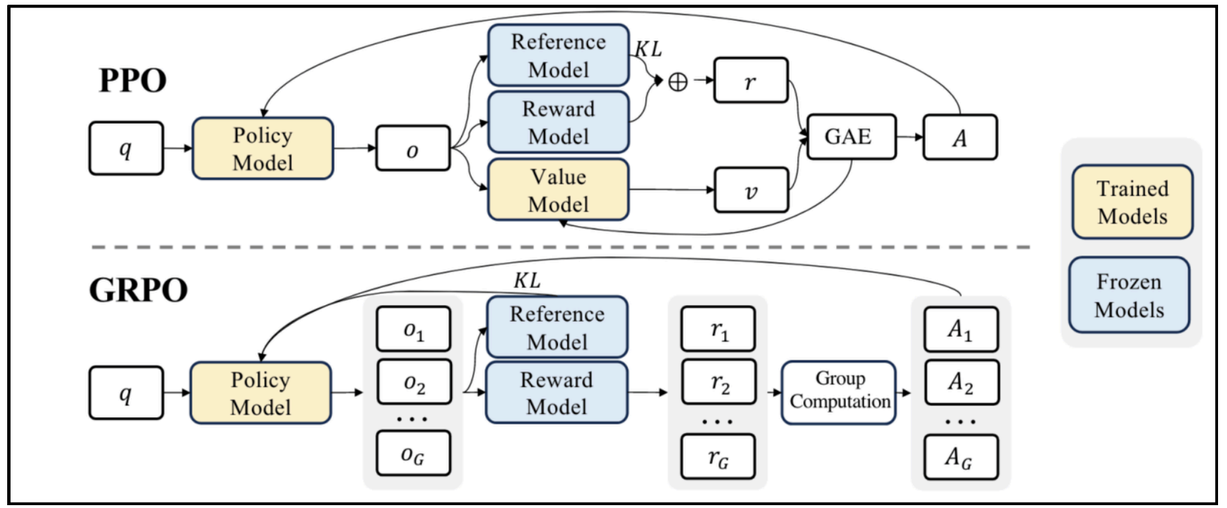
Actualización de política

Refuerza las respuestas que superan el promedio del grupo y penaliza las inferiores, utilizando un objetivo recortado y una penalización por divergencia

4

Beneficio

Reduce el uso de memoria VRAM y disminuye drásticamente el costo computacional de entrenamiento



Fuente: Shao et al., 2024

Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

07 · EVALUACIÓN Y RESULTADOS

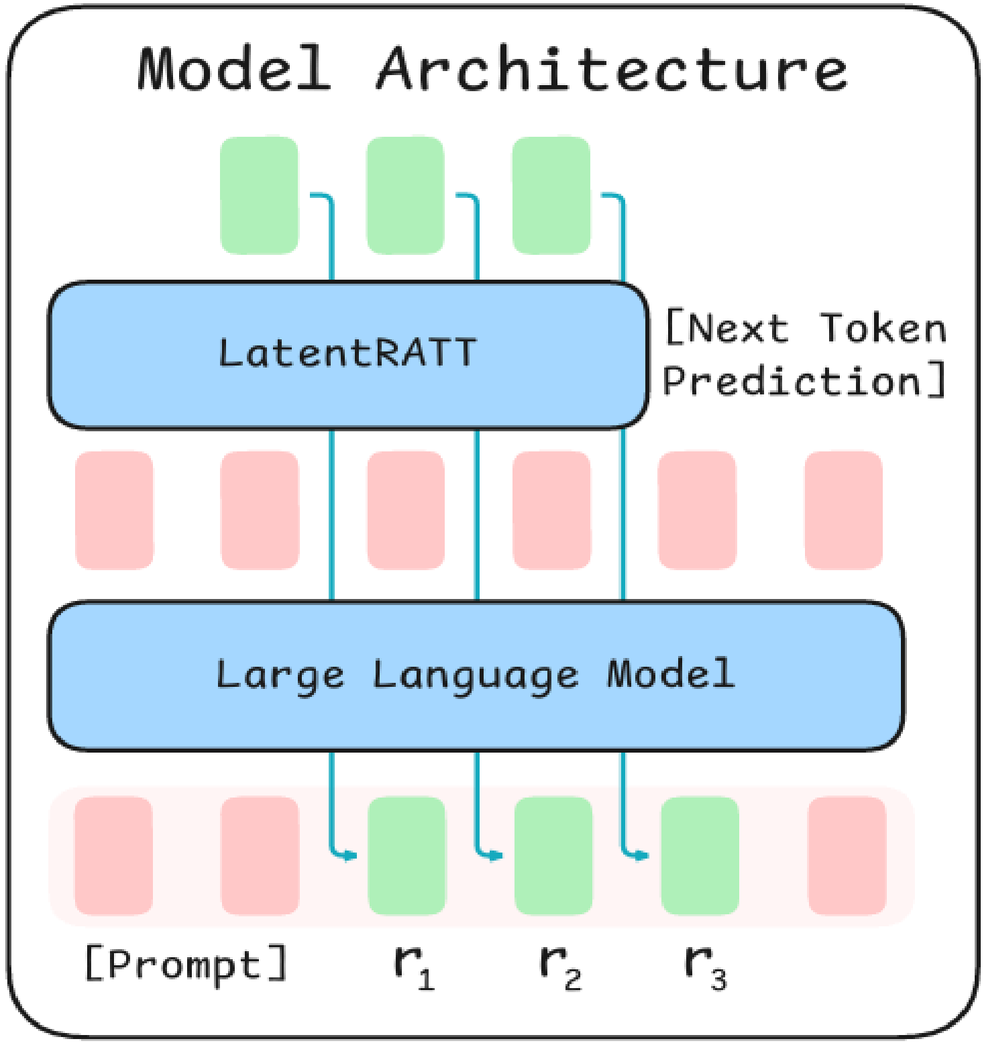
08 · CONCLUSIÓN

LatentR3: Entrenamiento de Razonamiento Latente Reforzado para Recomendación con LLMs

Innovación Arquitectónica

LatentRATT

- **Pensamiento en Espacio Continuo:** Capa de atención sobre la ultima decodificación del LLM para generar vectores de tokens latentes
- **Alineación de Representaciones:** Condensa la información contextual y alinea el vector de razonamiento con el espacio de embedding de entrada del LLM
- **Concatenación para Recomendación:** El prompt del historial del usuario se concatena con los tokens latentes para predecir el ítem objetivo



LatentR3: Entrenamiento de Razonamiento Latente Reforzado para Recomendación con LLMs

Estrategia de Aprendizaje

Two-stage Tuning

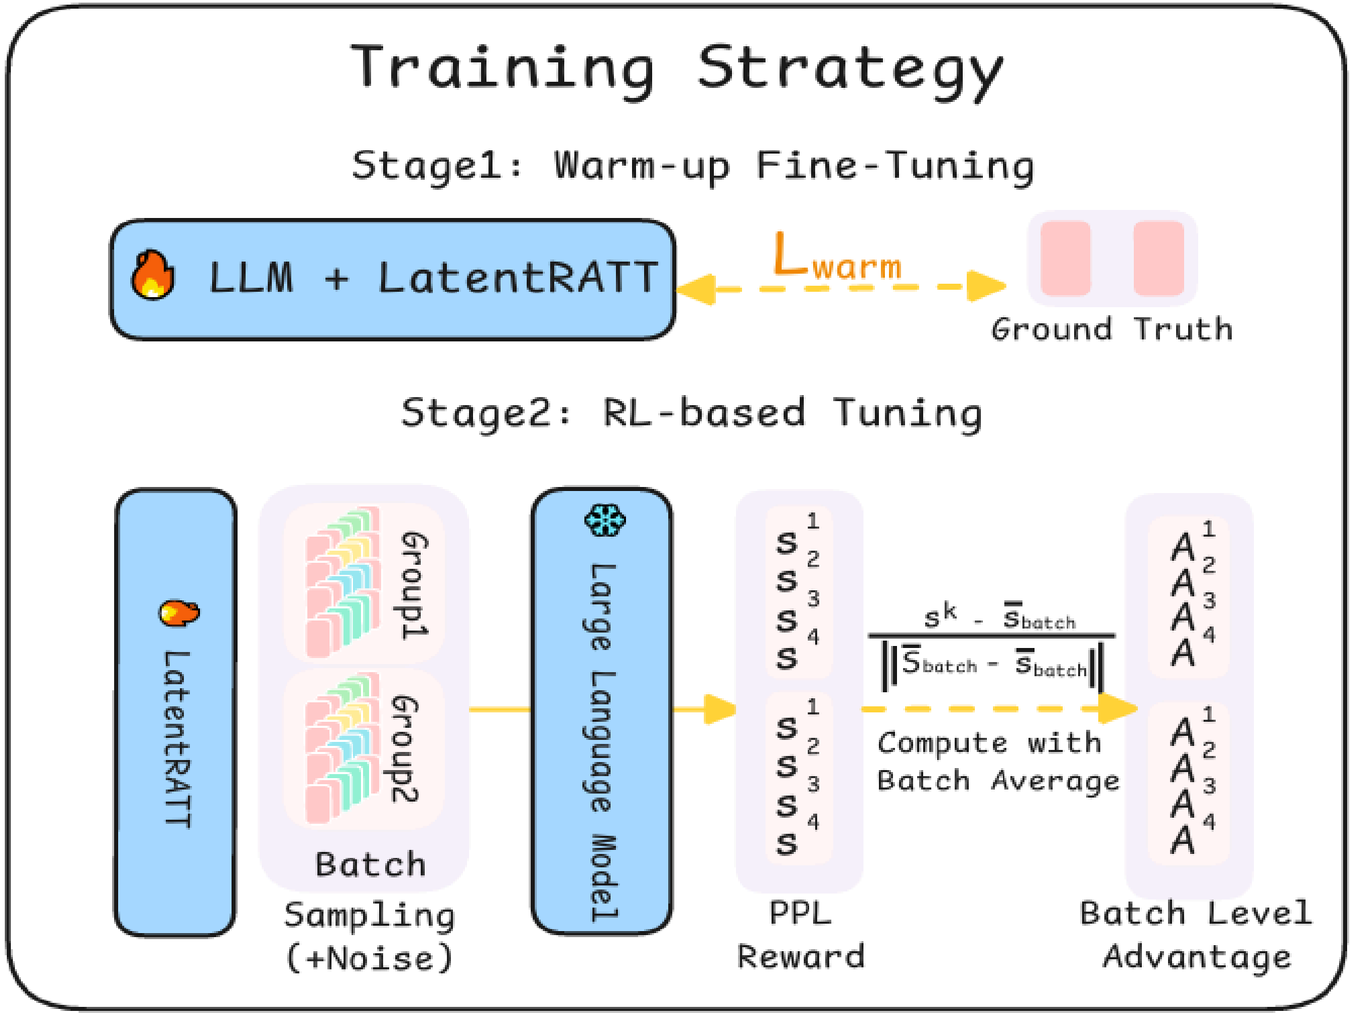
Warm-up Fine-Tuning (SFT)

Entrena conjuntamente el LLM y LatentRATT usando Next-Token Prediction para inicializar el espacio latente y prevenir la inestabilidad o colapso del RL

RL-Based Tuning (LR-GRPO)

Optimiza el espacio de razonamiento latente mediante una version modificada del algoritmo GRPO:

1. **Muestreo Continuo:** Muestreo en un espacio continuo inyectando ruido gaussiano
2. **PPL Reward:** Recompensa continua mediante perplejidad sobre el item real
3. **Batch-Level Advantage:** Calculo de ventaja respecto al promedio del batch para evitar falsos positivos



Warm-up Fine-Tuning

Ajuste supervisado que inicializa el módulo de razonamiento latente antes del aprendizaje reforzado

Dado un par *(x, y)* del dataset y el razonamiento latente ***r*** generado por LatentRATT, se entrena todo el modelo con predicción del siguiente token

$$\min_{\theta} \; L_{warm} = - \sum_{(x,y)\in\mathcal{D}} \sum_{i=1}^{|y|} \log P_\theta\left(y_i \mid x, r, y_{<i}\right)$$

$\sum_{(x,y)\in\mathcal{D}}$	Recorre todas las interacciones del dataset: prompt x e ítem objetivo y
$\sum_{i=1}^{\lvert y\rvert}$	Recorre cada token del ítem objetivo y (por ejemplo, su título)
$P_\theta(y_i \mid x, r, y_{<i})$	Probabilidad del token i dado el prompt, el razonamiento latente y los tokens anteriores
θ	Parámetros entrenados: el LLM original y la capa LatentRATT

RL-based Tuning con GRPO modificado

LatentR^3 modifica los tres primeros pasos de GRPO para adaptarlos al razonamiento latente continuo:

1 Sampling

GRPO ORIGINAL

Muestrea tokens discretos de texto

LatentR3

Ruido gaussiano sobre r (truco de reparametrización)

2 Reward

GRPO ORIGINAL

Genera la respuesta completa: recompensa 0/1

LatentR3

Menos la perplejidad del ítem real: continua y sin generar respuesta

3 Advantage

GRPO ORIGINAL

Compara con el promedio del grupo

LatentR3

Compara con el promedio del batch

4 Policy Update

GRPO ORIGINAL

Actualiza la política con la pérdida GRPO

LatentR3

Pérdida GRPO actualizando solo LatentRATT (LLM congelado)

Resultado: rendimiento comparable al GRPO original con cerca de 1/4 del costo de entrenamiento (83 vs. 314 min).

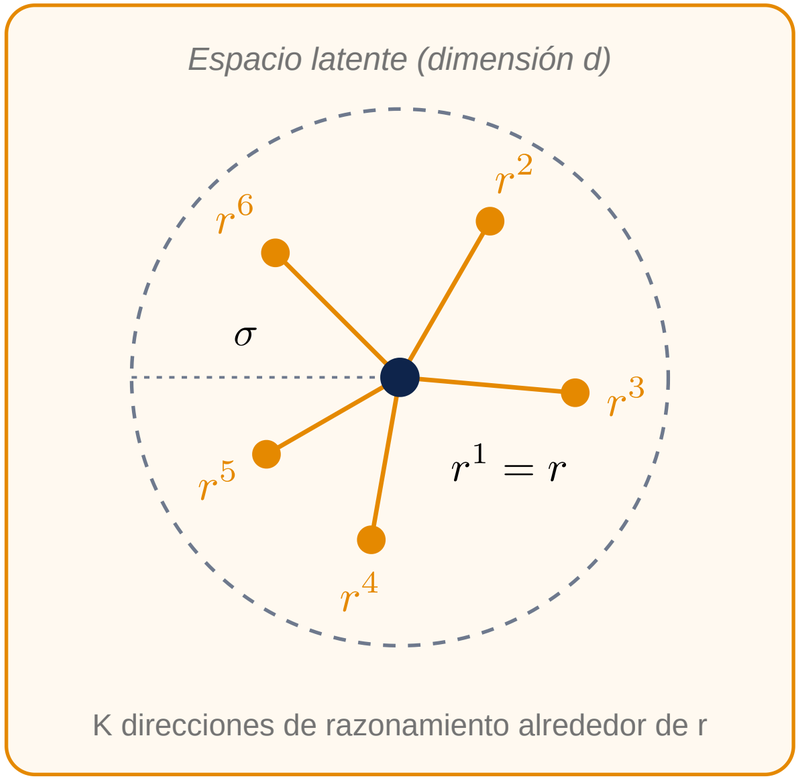
RL-based Tuning: Sampling

Para cada ejemplo *(x, y)* con razonamiento latente ***r***, se generan K variantes con el truco de reparametrización.

$$r^k = r + \epsilon, \qquad \epsilon \sim \mathcal{N}(0, \sigma^2), \qquad k = 2, \ldots, K$$

$$r^1 = r$$

r	Razonamiento latente original: actúa como media de la gaussiana
ϵ	Ruido muestreado: una dirección de exploración distinta en cada muestra
σ	Hiperparámetro que controla la intensidad del ruido
$r^1 = r$	La versión sin ruido se incluye como primera muestra



Intuición: cada muestra es una dirección de razonamiento distinta; la recompensa dirá cuál lleva a una mejor recomendación.

RL-based Tuning: Reward

Para cada razonamiento muestreado se concatena el prompt, el razonamiento y el ítem real y, y se calcula:

$$s^k = -\underbrace{\exp\Big(-\frac{1}{|y|}\sum_{i=1}^{|y|}\log \pi_\theta\big(y_i \mid x, r^k, y_{<i}\big)\Big)}_{\text{perplejidad (PPL) del ítem real } y} \qquad \mathbf{S} = [s^1, \ldots, s^K]$$

$\pi_\theta(y_i \mid x, r^k, y_{<i})$	Probabilidad que la política actual asigna al token i del ítem real
$\frac{1}{\lvert y\rvert}\sum \log \pi_\theta$	Log-probabilidad promedio por token del ítem real
$s^k = -\mathrm{PPL}$	Menor perplejidad, mayor recompensa: el razonamiento hace más probable el ítem correcto

GRPO ORIGINAL

Decodifica la respuesta completa por muestra

Recompensa binaria 0/1 (acierta o no)

LatentR3

Una sola pasada con el ítem real conocido

Recompensa continua: señal más rica y rápida

RL-based Tuning: Advantage

Para un razonamiento muestreado con recompensa s^k , la ventaja se calcula como:

$$A^k = \frac{s^k - \bar{s}_{batch}}{\|\mathbf{S}_{batch} - \bar{s}_{batch}\|}$$

$$\bar{s}_{batch} = \frac{1}{N_{group}} \sum_{S=[s^1,\ldots,s^K]\in\mathbf{S}_{batch}} s^1$$

$\bar{s}_{batch}$	Promedio de las recompensas sin ruido (s^1) de los grupos del batch
$\mathbf{S}_{batch}$, N_{group}	Recompensas de los grupos del batch y número de grupos
$\|\cdot\|$	Norma L2: normaliza la escala de las ventajas
$A^k > 0$	El razonamiento supera al promedio del batch: se refuerza

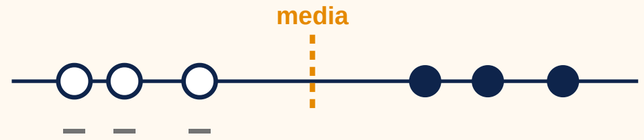
¿Por qué no el promedio del grupo?

Promedio del grupo B



una muestra de B queda con ventaja positiva

Promedio del batch



todo el grupo B queda con ventaja negativa

grupo A (bueno) grupo B (malo)

Problema que resuelve: con recompensas continuas, el promedio del grupo da ventaja positiva a alguna muestra aunque todo el grupo razone mal. El promedio del batch entrega una referencia global y más confiable.

RL-based Tuning: Policy Update

Se refuerzan los razonamientos con ventaja positiva y se penalizan los de ventaja negativa:

$$L_{\text{GRPO}} = \sum_{(x,y)\in\mathcal{D}} -\frac{1}{K}\sum_{k=1}^{K}\frac{1}{|y|}\sum_{i=1}^{|y|}\frac{\pi_\theta(y_i \mid x, r^k, y_{<i})}{\pi_{\text{old}}(y_i \mid x, r^k, y_{<i})}\cdot A^k \; - \; \underbrace{\beta\,\mathbb{D}_{KL}(\pi_\theta \,\|\, \pi_{ref})}_{=0}$$

$\frac{\pi_\theta}{\pi_{\text{old}}}$	Razón entre la política actual y la anterior para cada token del ítem real
A^k	Ventaja: indica cuánto reforzar o penalizar el razonamiento muestreado k
$\frac{1}{K}\sum_k \frac{1}{\lvert y\rvert}\sum_i$	Promedio sobre las K muestras de razonamiento y los tokens del ítem real
$\beta\,\mathbb{D}_{KL}$	Regularización KL: vale 0 porque el LLM original queda congelado

Eficiencia: solo se entrenan los parámetros de LatentRATT; el LLM original no cambia durante el RL.

Módulo LatentRATT: Generación de Razonamiento Latente Continuo

Capa de atención especializada construida sobre el decodificador del LLM para agregar contexto y alinear el espacio latente de razonamiento

Dado un prompt x de longitud |x| que representa el historial del usuario y la secuencia de tokens previamente generados

1 Extracción de estados ocultos

Última capa de decodificación del LLM

$$\boldsymbol{H}_{i-1} = \mathrm{LLM}^{-1}(x, r_1, \ldots, r_{i-1}) \in \mathbb{R}^{(|x|+i-1)\times d}$$

2 Generación del token latente

LatentRATT toma la última posición

$$r_i = \mathrm{LatentRATT}(\boldsymbol{H}_{i-1})[-1] \in \mathbb{R}^d$$

3 Predicción final del ítem

Con N tokens latentes concatenados al prompt

$$r = [r_1, \ldots, r_N] \qquad \hat{y} = \mathrm{LLM}(x, r)$$

Eficiencia en LatentR3: a diferencia de las largas secuencias de texto del CoT explícito, pocos tokens latentes capturan casi todo el razonamiento: **con N = 1 se obtiene la mayor ganancia** y pasar a N = 2 aporta poco.

Tabla de Contenidos

01 · CONTEXTO

02 · PROBLEMA DE RECOMENDACIÓN

03 · CONTRIBUCIONES

04 · ESTADO DEL ARTE

05 · MARCO TEÓRICO

06 · DETALLES DE SOLUCIÓN

07 · EVALUACIÓN Y RESULTADOS

08 · CONCLUSIÓN

Configuración Experimental y Datasets

1

Datasets de Amazon (2018)

Filtrado clásico **5-core** (≥ 5 interacciones):

- **Toys and Games**: 34.7k usuarios, 12.0k ítems
- **CDs and Vinyl**: 17.5k usuarios, 12.3k ítems
- **Video Games**: 15.6k usuarios, 9.8k ítems
- **Musical Instruments**: 14.3k usuarios, 9.5k ítems

2

Baselines de Comparación

Secuenciales clásicos (IDs):

- Caser (basado en CNN)
- GRU4Rec (basado en RNN)
- SASRec (Self-Attention)

Modelos con LLMs:

- Base LLM (Prompting directo)
- Explicit CoT (Cadenas de texto paso a paso)
- BIGRec y D^3 (Generativos de dos fases).

3

Métricas y Modelos Base.

Métricas de Ranking Top-N:

- **Hit Ratio**: HR@5 y HR@10 (mide si el ítem objetivo aparece en las recomendaciones)
- **NDCG**: NDCG@5 y NDCG@10 (sensible a la posición exacta en el ranking)

Backbones LLM Empleados:

Qwen2.5-1.5B

FUENTE: ZHANG ET AL., ICLR 2026 · SECTION 4.1: EXPERIMENTAL SETUP

Rendimiento Top-N: LatentR³ vs. Baselines

Dataset	Methods	Traditional			LLM-based						
	Metrics	Caser	GRU4Rec	SASRec	Base	COT	AlphaRec	BIGRec	+LatentR^3	D^3	+LatentR^3
Toys	H@5	0.0251	0.0417	0.0601	0.0203	0.0261	0.0579	0.0701	0.0821	0.0830	**0.0898**
	H@10	0.0384	0.0564	0.0760	0.0359	0.0496	0.0893	0.0931	0.1107	0.1026	**0.1152**
	N@5	0.0170	0.0305	0.0458	0.0128	0.0153	0.0347	0.0508	0.0600	0.0610	**0.0670**
	N@10	0.0214	0.0352	0.0510	0.0178	0.0229	0.0448	0.0582	0.0693	0.0674	**0.0752**
CDs	H@5	0.0469	0.0481	0.0841	0.0195	0.0302	0.0479	0.0757	0.0934	0.1122	**0.1137**
	H@10	0.0689	0.0669	0.1054	0.0252	0.0406	0.0774	0.0929	0.1160	0.1272	**0.1327**
	N@5	0.0312	0.0365	0.0622	0.0148	0.0213	0.0278	0.0616	0.0754	0.0906	**0.0915**
	N@10	0.0382	0.0425	0.0691	0.0167	0.0246	0.0373	0.0672	0.0826	0.0955	**0.0977**
Games	H@5	0.0324	0.0322	0.0416	0.0236	0.0120	0.0558	0.0461	0.0580	0.0608	**0.0716**
	H@10	0.0538	0.0517	0.0633	0.0311	0.0194	0.0893	0.0709	0.0870	0.0860	**0.1006**
	N@5	0.0211	0.0207	0.0280	0.0190	0.0082	0.0397	0.0334	0.0413	0.0423	**0.0507**
	N@10	0.0280	0.0270	0.0350	0.0214	0.0105	0.0515	0.0414	0.0506	0.0505	**0.0601**
Instruments	H@5	0.0564	0.0630	0.0708	0.0296	0.0261	0.0564	0.0807	0.0882	0.0848	**0.0920**
	H@10	0.0627	0.0692	0.0758	0.0411	0.0452	0.0640	0.0879	0.0941	0.0907	**0.0973**
	N@5	0.0781	0.0766	0.0793	0.0154	0.0135	0.0813	0.0938	0.1029	0.0984	**0.1066**
	N@10	0.0977	0.0960	0.0950	0.0192	0.0199	0.1051	0.1158	0.1214	0.1167	**0.1229**
	RI	85.8%	67.8%	27.9%	266.8%	245.9%	38.8%	17.0%	-	8.4%	-

1. Superioridad sobre modelos de IDs

D³ + LatentR³ supera de forma consistente a todos los modelos de IDs en promedio: +27.9% sobre SASRec, +67.8% sobre GRU4Rec y +85.8% sobre Caser

2. Falla del CoT Explícito

Generar cadenas de texto libre apenas mejora al modelo base.

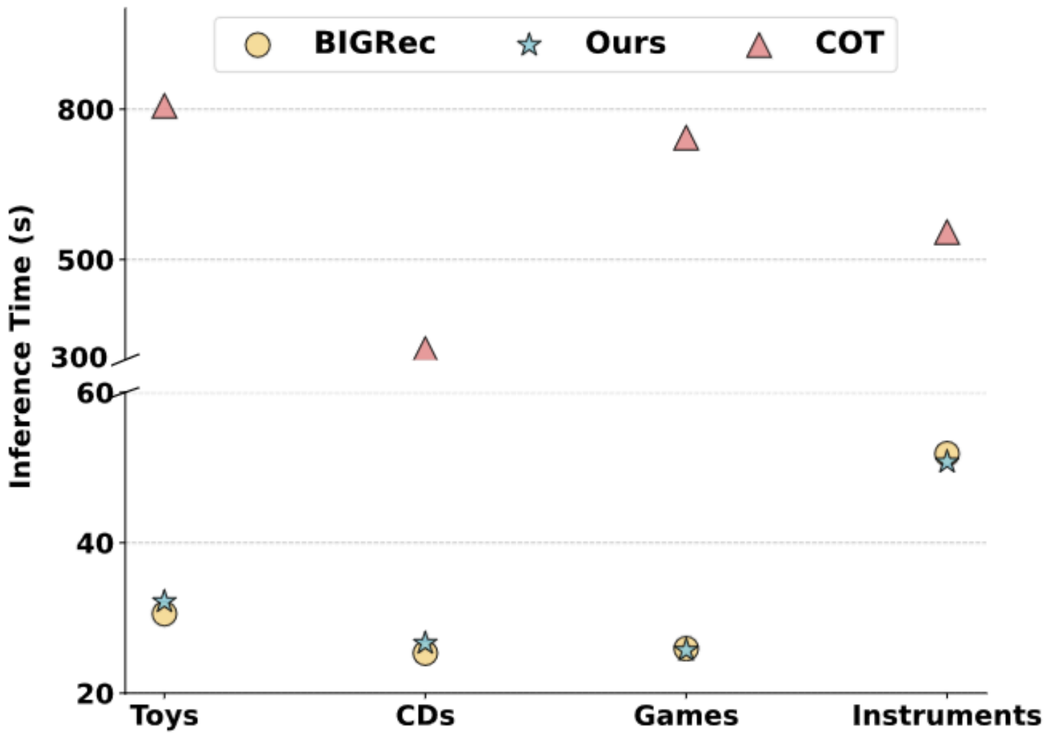
3. Máxima efectividad en LatentR³

Al añadir razonamiento latente sobre BIGRec, se obtiene la mayor ganancia de ranking en todos los dominios evaluados.

FUENTE: ZHANG ET AL., ICLR 2026 · TABLE 1: PERFORMANCE COMPARISON

Eficiencia en Inferencia y Latencia

Costo de inferencia: razonamiento latente vs. CoT explícito



1

Costo casi idéntico al de no razonar

LatentR³ tarda prácticamente lo mismo que BIGRec en los cuatro datasets, porque solo agrega un token latente antes de generar la recomendación.

2

El CoT explícito multiplica el tiempo

Generar el razonamiento en texto hace la inferencia entre 10 y 30 veces más lenta, con unos 25× en Toys y cerca de 30× en Games.

FUENTE: ZHANG ET AL., ICLR 2026 · APPENDIX G, FIGURE 5 (TIEMPO PARA 100 CONSULTAS EN GPU A100)

Estudios de Ablación y Sensibilidad

1. Cantidad de Tokens (K)

K = {0, 1, 2} : Con un solo token se logra captar el razonamiento completo, y con dos no se ve una mejora considerable que compense el aumento de costo para la mayoría de sistemas de recomendación.

2. Necesidad de SFT + RL

Solo RL (sin SFT): Divergencia inicial. El espacio latente continuo colapsa sin anclaje previo.

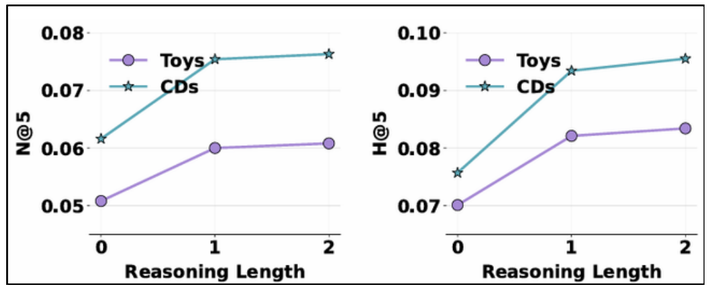
Solo SFT (sin GRPO): Mejora modesta (+4%), sin exploración de políticas.

SFT + GRPO: Logra la mejora completa (+15%).

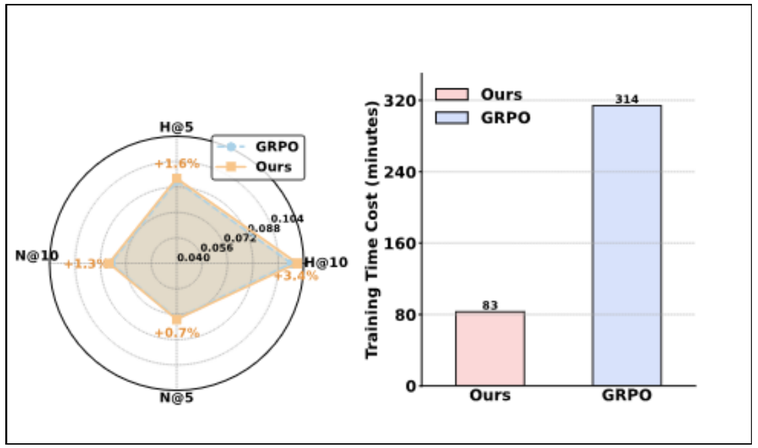
3. LR-GRPO VS GRPO

Performance: Resultados similares entre algoritmos con variaciones por dataset

Eficiencia: LR-GRPO es significativamente más rápido, con un costo de entrenamiento de 1/4 comparado a GRPO.



Method	Toys			
	H@5	H@10	N@5	N@10
LatentR^3	**0.0821**	**0.1107**	**0.0600**	**0.0693**
w/o Reasoning	0.0701	0.0931	0.0508	0.0582
w/o LatentRATT	0.0772	0.1040	0.0574	0.0661
w/o RL (only SFT)	0.0804	0.1067	0.0584	0.0669
w/o Batch Advantage	0.0812	0.1083	0.0589	0.0676
Method	**CDs**			
	H@5	H@10	N@5	N@10
LatentR^3	**0.0934**	**0.1160**	**0.0754**	**0.0826**
w/o Reasoning	0.0757	0.0929	0.0616	0.0672
w/o LatentRATT	0.0705	0.0875	0.0568	0.0624
w/o RL (only SFT)	0.0830	0.1005	0.0662	0.0719
w/o Batch Advantage	0.0828	0.1002	0.0661	0.0718



FUENTE: ZHANG ET AL., ICLR 2026 · SECTION 4.3.3: ABLATION STUDIES

Conclusiones del Paper

1

Conclusiones principales

- El **razonamiento en espacios latentes** resuelve la ineficiencia del CoT textual manteniendo la profundidad deductiva.
- **No requiere datos anotados de CoT**: el aprendizaje reforzado (GRPO) descubre trayectorias de inferencia de forma autónoma.
- Excelente balance entre precisión de ranking y velocidad de inferencia industrial.

2

Limitaciones

- **Escala limitada**: se evaluó sobre todo en datasets pequeños (~5.000 ítems) y con un LLM de 1.500 millones de parámetros. El modelo más grande que se prueba es de 3.000 millones (con LoRA), en un solo dataset y solo contra BIGRec.
- **Comparaciones con ventaja para el método:** el baseline CoT se usa sin ajuste fino, mientras que LatentR³ sí se ajusta. Además, D³ se evaluó sin su ensamble y los modelos secuenciales se entrenaron con BCE y negativos muestreados.
- **Baja interpretabilidad:** el razonamiento latente no se puede leer. Que realmente haya “razonamiento” se apoya en evidencia indirecta: más mejora en ítems poco populares, y una caída de rendimiento al enmascarar el token.

FUENTE: ZHANG ET AL., ICLR 2026 · SECTION 6: CONCLUSION & LIMITATIONS

Referencias

Yang Zhang, Wenxin Xu, Xiaoyan Zhao, Wenjie Wang, Fuli Feng, Xiangnan He, and Tat-Seng Chua. Reinforced latent reasoning for llm-based recommendation. arXiv preprint arXiv:2505.19092, 2025.

Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. Advances in neural information processing systems, 35:24824–24837, 2022.

Alicia Tsai, Adam Kraft, Long Jin, Chenwei Cai, Anahita Hosseini, Taibai Xu, Zemin Zhang, Lichan Hong, Ed H. Chi, and Xinyang Yi. Leveraging LLM reasoning enhances personalized recommender systems. In Lun-Wei Ku, Andre Martins, and Vivek Srikumar (eds.), Findings of the Association for Computational Linguistics: ACL 2024, pp. 13176–13188, Bangkok, Thailand, August 2024. Association for Computational Linguistics. doi: 10.18653 v1/2024.findings-acl.780. URL https://aclanthology.org/2024.findings-acl.780/.

Zhihong Shao, Peiyi Wang, Qihao Zhu, Runxin Xu, Junxiao Song, Xiao Bi, Haowei Zhang, Mingchuan Zhang, YK Li, Y Wu, et al. Deepseekmath: Pushing the limits of mathematical reasoning in open language models. arXiv preprint arXiv:2402.03300, 2024.

Shibo Hao, Sainbayar Sukhbaatar, DiJia Su, Xian Li, Zhiting Hu, Jason Weston, and Yuandong Tian. Training large language models to reason in a continuous latent space. arXiv preprint arXiv:2412.06769, 2024.