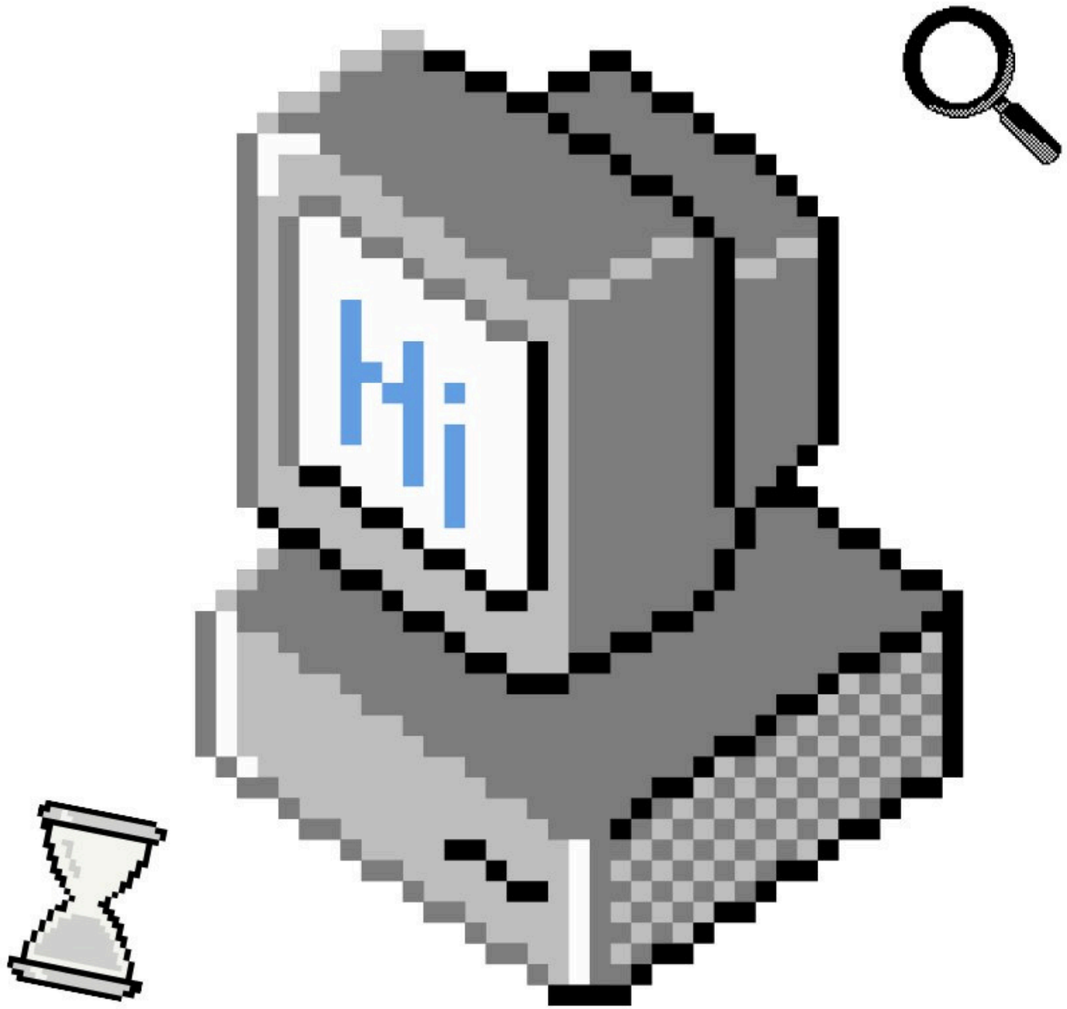

HARNESSING MULTIMODAL LLMS FOR MULTIMODAL SEQUENTIAL RECOMMENDATION

Yuyang Ye, Zhi Zheng, Yishan Shen, Tianshu Wang, Hengruo Zhang, Peijun Zhu, Runlong Yu, Kai Zhang, Hui Xiong

The 39th Annual AAAI Conference on Artificial Intelligence

Elías Ayaach, Diego Lizama, Carlos Rupallán

Motivación

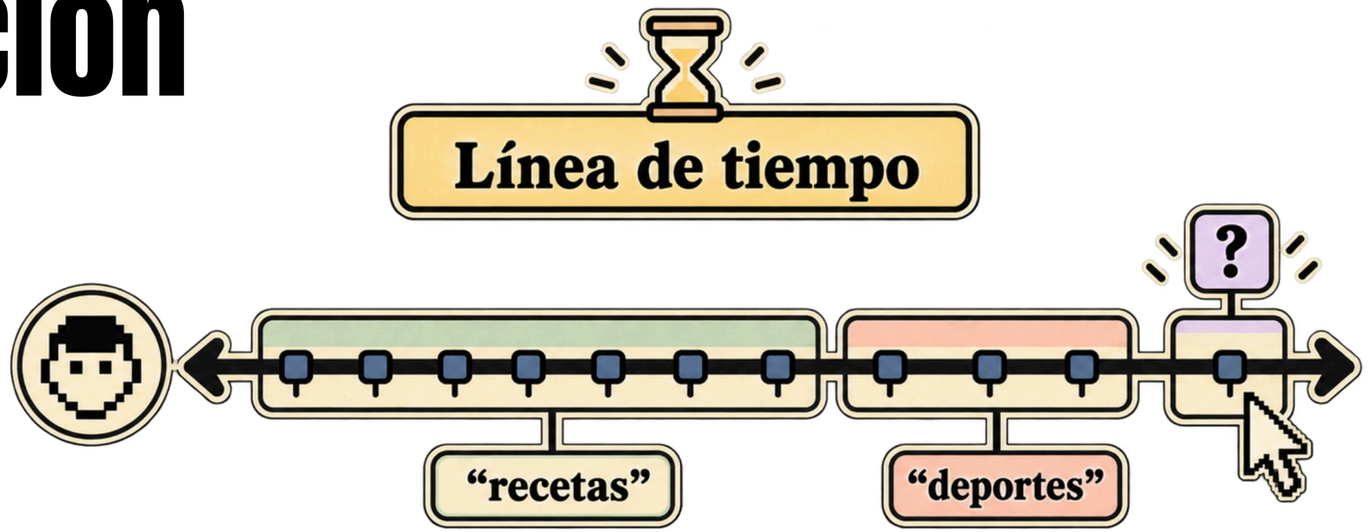
Línea de tiempo
?
“recetas”
“deportes”

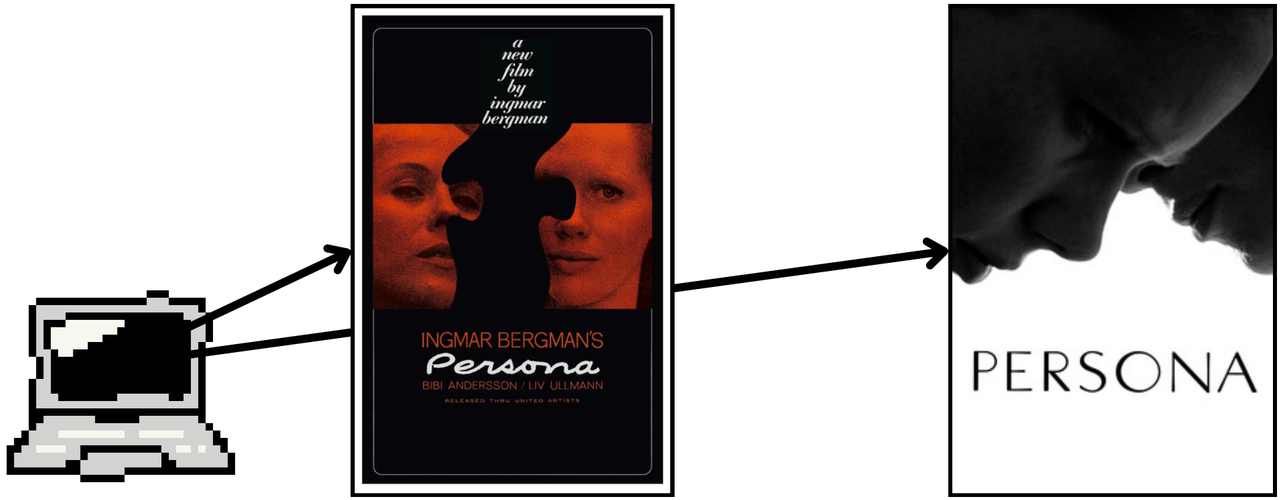
a new film by ingmar bergman
INGMAR BERGMAN'S
Persona
BIBI ANDERSSON / LIV ULLMANN
RELEASED THRU UNITED ARTISTS
PERSONA

Problema de la Recomendación Secuencial Multimodal

U	Conjunto de usuarios
I	Conjunto de items
$S_u = [\, i_u^1, \ldots, \, i_u^{n_u} \,]$	Secuencia ordenada de interacciones de un usuario con ítems
$\mathcal{W}$	Descripción textual de los ítems
$\mathcal{I}$	Imagenes de los ítems
I^C	Conjunto de ítems candidatos

Problema de la Recomendación Secuencial Multimodal

Entrada

$$S_u + (w_{i_c},\ v_{i_c})$$

$$w_{i_c} \in \mathcal{W}, v_{i_c} \in \mathcal{I}$$

Salida

$$g_u : I \to [0,1]$$

$$g_u(i_c) = P(y_{u,c} = 1 \mid S_u,\ w_{i_c},\ v_{i_c})$$

$$y_{u,c} = \begin{cases} 1 & \text{si } i_c = i_u^{n_u+1} \\ 0 & e.o.c. \end{cases}$$

Adaptado de Ye et al. (2025, p. 13071)

Estado del Arte

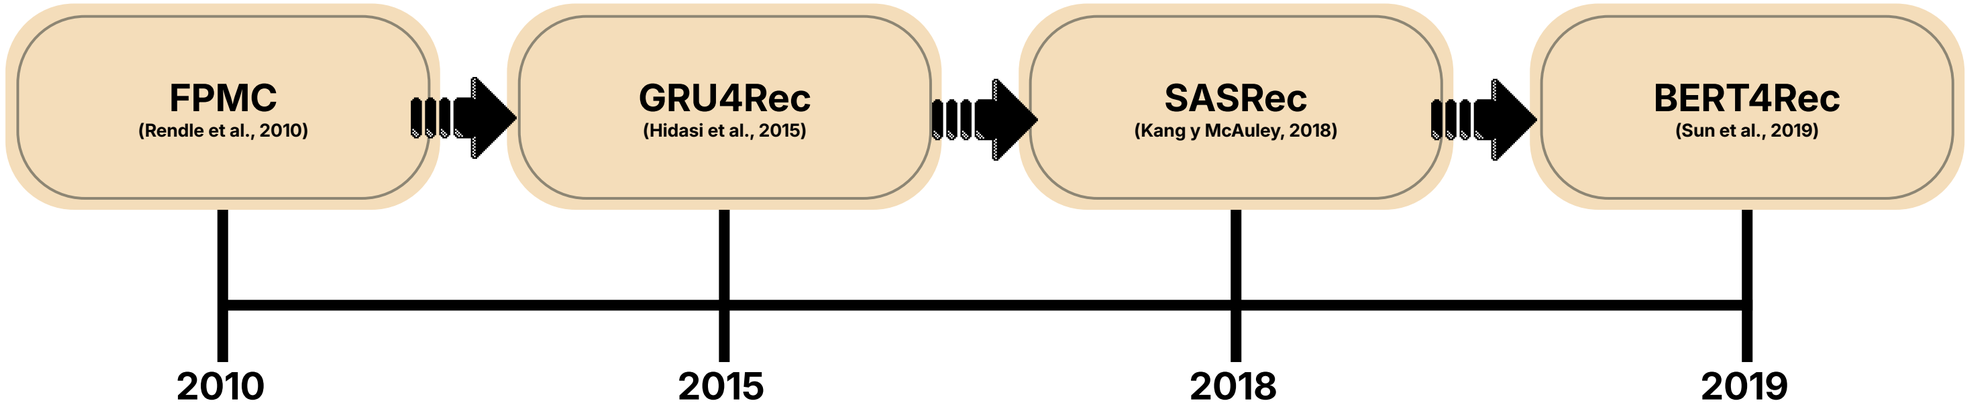

Ye et al. (2025, p. 13070)

Desafíos de la Implementación de MLLMs

Problemas de escalabilidad y eficiencia asociados a secuencias grandes de imágenes en el historial

[ ]

Dificultades de MLLMs de comprender dinamismo de las secuencias temporales de interacciones y preferencias de los usuarios

Fine-tuning de MLLMs evitando overfitting ni perder aprendizajes de preentrenamiento

Dar input que pueda procesar

Dar tarea en formato que entienda

Enseñar a responder pregunta de recomendación

(Ye et al., 2025, pp. 13069–13070)

Arquitectura

Detalles técnicos

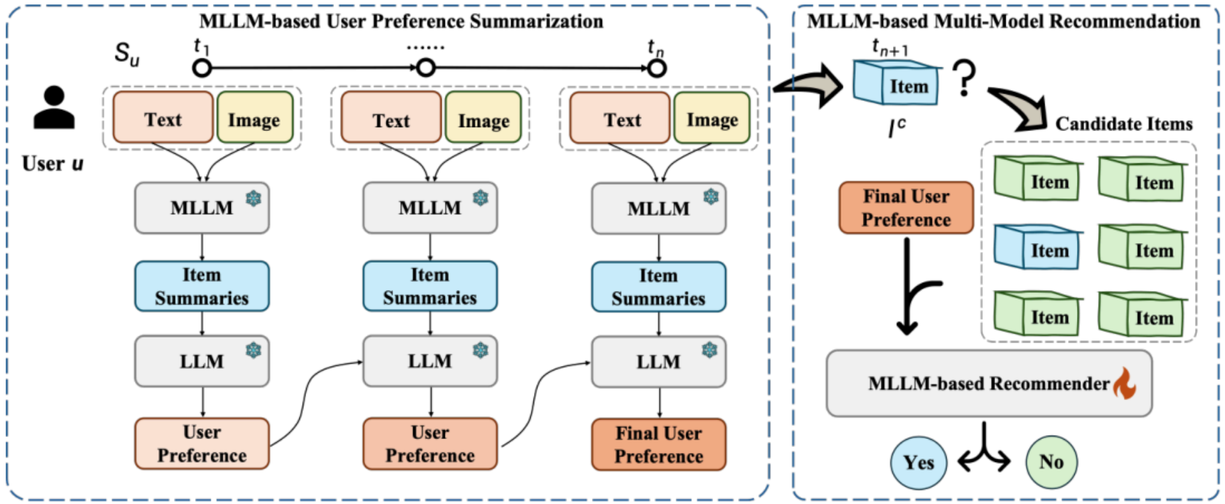

Figure 1: The schematic framework of MLLM-MSR

Multimodal User Preferences Inference

1.1. Multimodal Item Summarization

1.2. Recurrent User Preference Inference

Tuning MLLM-based Recommender

2.1. Diseño del prompt y predicción YES/NO

2.2. Supervised Fine-Tuning y función de pérdida

2.3. Negative Sampling y LoRA

Fuente: Ye et al. (2025, Fig. 1, p. 13072)

Multimodal User Preferences Inference

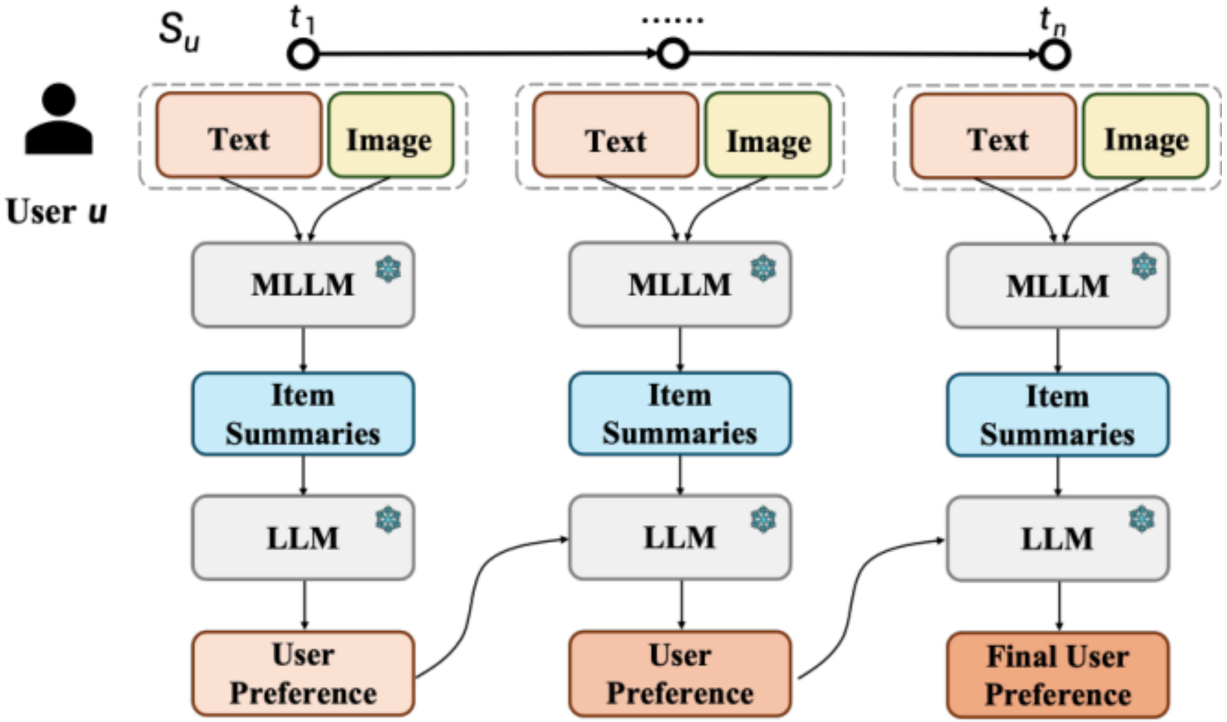

Problema

Los **MLLMs tienen dificultades para procesar secuencias** largas de múltiples imágenes manteniendo correctamente el orden y la correspondencia con sus textos.

Solución

Convertir la información multimodal de cada ítem en una descripción **textual unificada.**

Parte 1: Multimodal Item Summarization

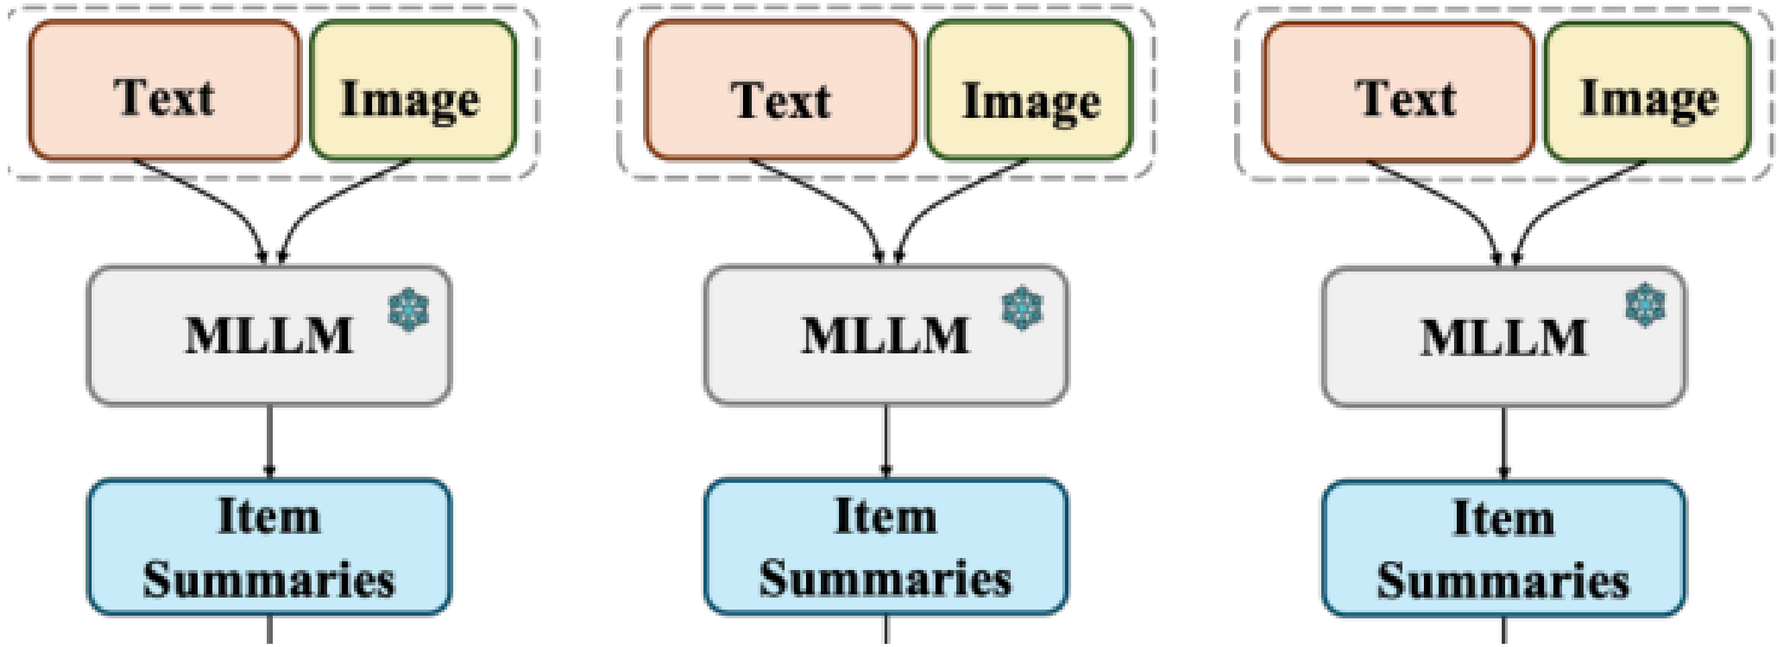

Se utilizan 3 prompts para lograrlo

Text Summarization Prompt

Primero se resume la información textual que acompaña al ítem.

Input (Información textual del ítem)

Título: 'Mourinho Real Madrid Tactical Analysis"
Descripción: Análisis de la etapa de José Mourinho en el Real Madrid, con tácticas, estrategias y momentos destacados del equipo.

MLLM
(Text Summarization Prompt)

Output (resumen textual)

"Video sobre el análisis táctico del Real Madrid durante la etapa de José Mourinho, incluyendo estrategias, formaciones y partidos clave."

Image Description Prompt

Después se utiliza el MLLM para extraer características semánticas de la imagen y expresarlas mediante lenguaje natural.

Input (Imagen del ítem)

MLLM
(Image Description Prompt)

Output (descripción de la imagen)

"Se observa a José Mourinho, entrenador del Real Madrid, dando indicaciones durante un partido, con el escudo del club de fondo y un estadio lleno de espectadores."

Fusion Prompt

Finalmente se combinan ambos resúmenes para obtener una descripción integrada del ítem.

Inputs

Resumen textual

"Video sobre el análisis táctico del Real Madrid durante la etapa de José Mourinho, incluyendo estrategias, formaciones y partidos clave."

Descripción de la imagen

"Se observa a José Mourinho, entrenador del Real Madrid, dando indicaciones durante un partido, con el escudo del club de fondo y un estadio lleno de espectadores."

MLLM
(Fusion Prompt)

Output (resumen multimodal)

"Video sobre el análisis táctico de José Mourinho en el Real Madrid, mostrando sus estrategias, formaciones y momentos clave de los partidos, con imágenes del entrenador dando indicaciones desde la banda y escenas del equipo en un estadio lleno."

Parte 2: Recurrent User Preference Inference

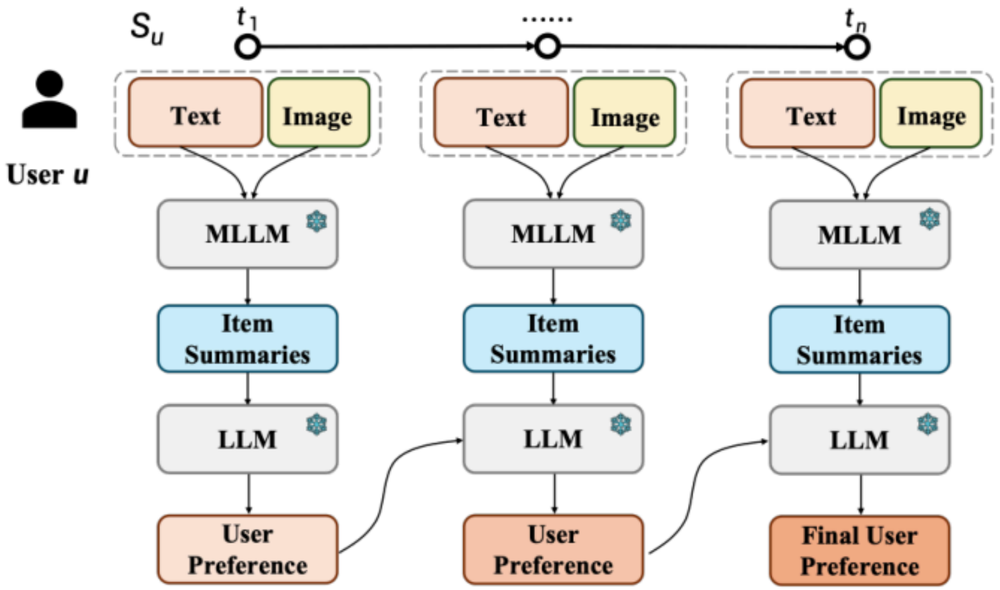

¿Que falta?

Con el paso anterior obtuvimos una descripción independiente de cada item pero aún **falta armar la representación de las preferencias del usuario**

¿Porque de forma recurrente?

Ahora tenemos muchos prompts de items por lo que el pormpt puede ser excesivamente largo para representar el historial completo. Además, no basta con identificar los temas que le gustan **queremos saber como evolucionan sus intereses**

¿Cómo se ve la inyección recurrente?

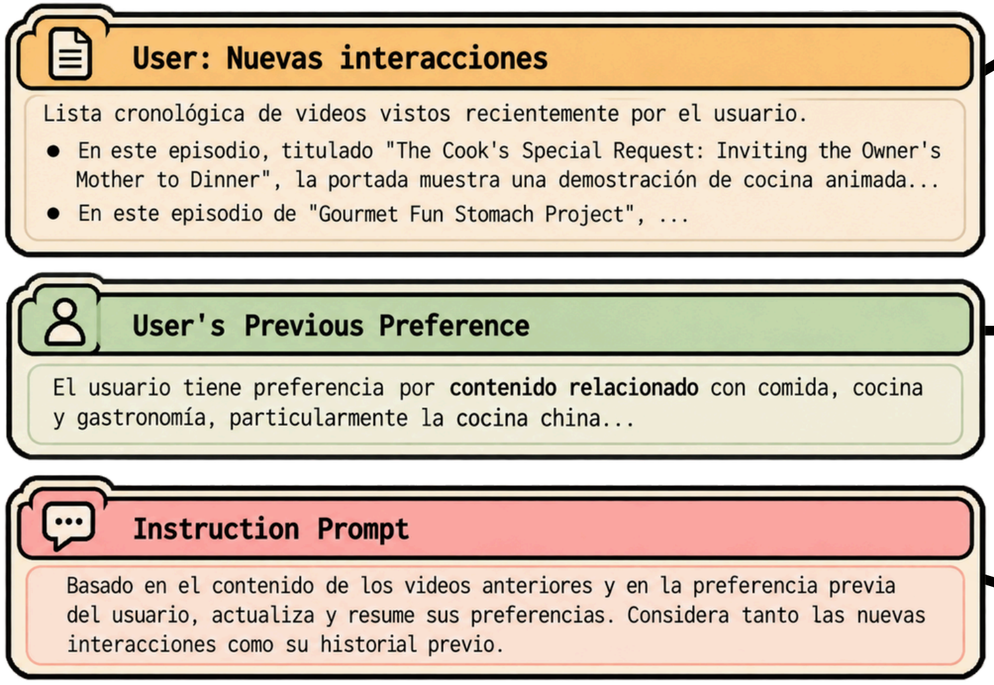

Primera sección

Incluye el texto que obtuvimos anteriormente del resumen del item summarization con la nueva interacción del usuario

Segunda sección

Usa la preferencia anterior y el prompt le solicita al LLM actualizar las preferencias considerando ambas fuentes de información.

Tercera sección

Es la salida del modelo y genera una descripción que conserva el interés o gustos previos del usuario agregando nuevas características

MLLM-Based Recommender

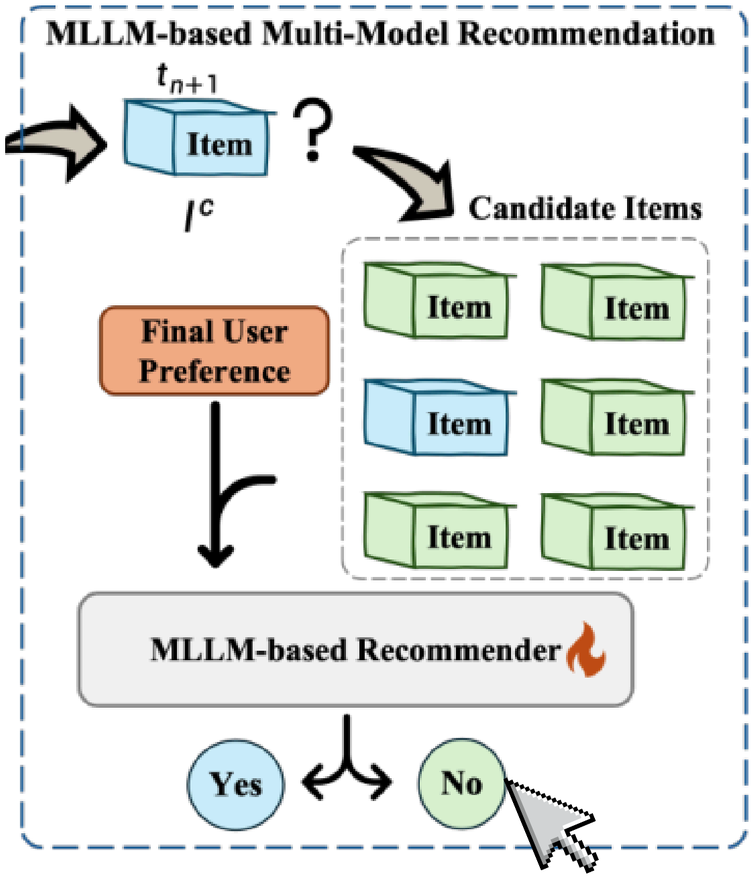

Fuente: Ye et al. (2025, Fig. 1, p. 13072)

Ahora ya tenemos el perfil resumido del usuario.

Queda usarlo para predecir si al usuario le va a interesar un nuevo item

Parte 1: Diseño del promt y predicción ‘yes’/’no’

Final User Preference
Perfil textual del usuario

Resumen final obtenido en las etapas anteriores. Describe los intereses del usuario y sirve como contexto para la recomendación.

El usuario muestra interés en fútbol, especialmente en el Real Madrid y en análisis tácticos, con preferencia por contenido de entrenadores y estrategias de partido.

Candidate Item
Texto + imagen

Ítem candidato que será evaluado por el modelo usando información textual y visual.

Titulo: Tactical analysis of Mourinho’s Real Madrid

Descripción: Video sobre la etapa de José Mourinho en el Real Madrid, incluyendo tácticas, formaciones y momentos clave.

Imagen:

Instruction Prompt
Estructura del prompt

El prompt guía al MLLM para decidir si el usuario interactuaría con el ítem.

System Instruction:

Given the image cover and title of a video together with the user preference, predict whether the user would interact with the video. Answer only YES or NO.

User Preference:

[Perfil textual del usuario]

Candidate Item:

[Titulo + imagen + descripción]

Assistant Response: YES / NO

MLLM-based Recommender (LLaVA)
Recibe el perfil del usuario, el ítem candidato y el instruction prompt para predecir la interacción.

(Liu et al., 2023; Liu et al., 2024)

YES **NO**

Predicción binaria del modelo

Interaction Score
Score continuo calculado a partir de las probabilidades de YES y NO

$$p = \frac{p'(yes)}{p'(yes) + p'(no)}$$

Parte 2: Entrenamiento usando SFT

Cómo consigue LLaVa aprender correctamente la Tarea?

Para lograr esto utilizan Supervised Fine-Tuning. Toman un MLLM pre entrenado y ajustan usando ejemplos de interacciones entre usuarios e items. Usan ***negative sampling*** esto significa que seleccionan ítems sin interacción observada y los utilizan como ejemplos negativos.

Construcción del dataset de entrenamiento (User preference, Candidate item, Label)

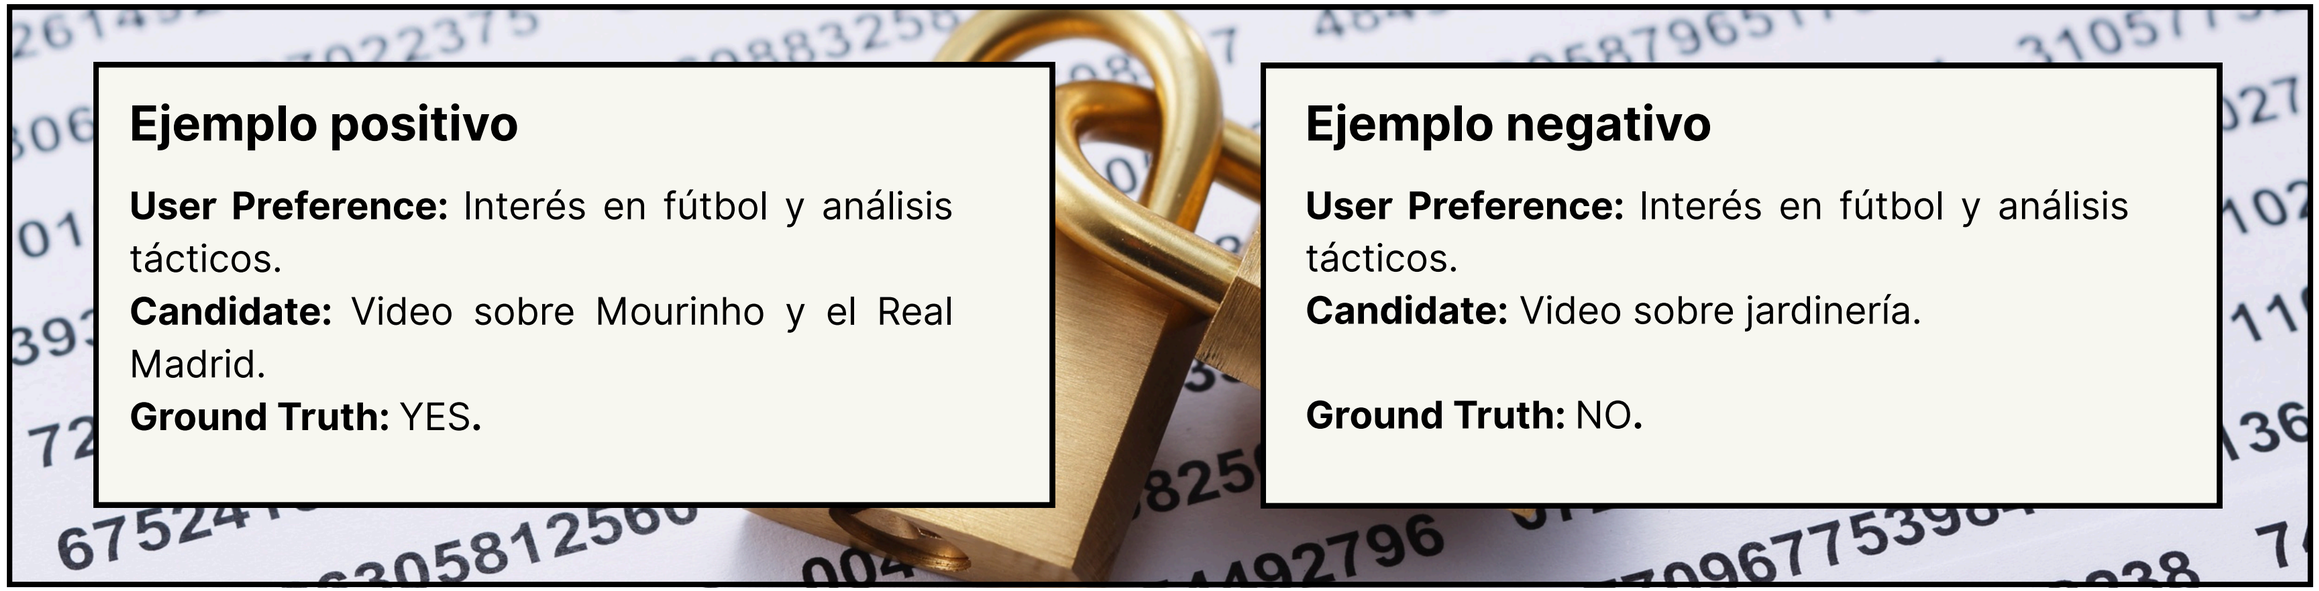

Ejemplo positivo

User Preference: Interés en fútbol y análisis tácticos.
Candidate: Video sobre Mourinho y el Real Madrid.
Ground Truth: YES.

Ejemplo negativo

User Preference: Interés en fútbol y análisis tácticos.
Candidate: Video sobre jardinería.

Ground Truth: NO.

Parte 2: Entrenamiento usando SFT

¿Cómo consigue LLaVa aprender correctamente la Tarea?

Perfil del usuario (u)

- Resumen de sus preferencias
- Historial de interacciones
- Intereses, estilo, contexto, etc.

Ítem candidato (i_c)

- Título, descripción
- Imagen del ítem
- Metadatos (categoría, etc.)

Instrucción de la tarea

- Instrucciones al modelo
- Formato de respuesta
- (ej. responder solo "YES" o "NO")

Input Prompt (I)

[User Profile]
{perfil del usuario}

[Candidate Item]
{título, descripción, imagen}

[Instruction]
{instrucciones de la tarea}

MLLM (LLaVA)

Output (secuencia de tokens)

Respuesta generada

$$v = [v_1, .., v_L]$$

Ejemplo:
"YES" → { 'Y', 'E', 'S' }

Función de pérdida (Supervised Fine-Tuning)

Pérdida autoregresiva de predicción del siguiente token (Ecuación 2 del paper):

$$\mathcal{L} = -\sum_{i=1}^{L} \log P(v_i \,|\, v_{<i}, I)$$

Parte 2: El uso de LoRA para el fine tuning

¿Para qué se usa? Permite realizar fine-tuning de LLaVA reduciendo el costo computacional y la memoria necesaria (Hu et al., 2022)

¿Cómo funciona? Congela los pesos originales del modelo y entrena pequeñas matrices de bajo rango que representan las actualizaciones de esos pesos.

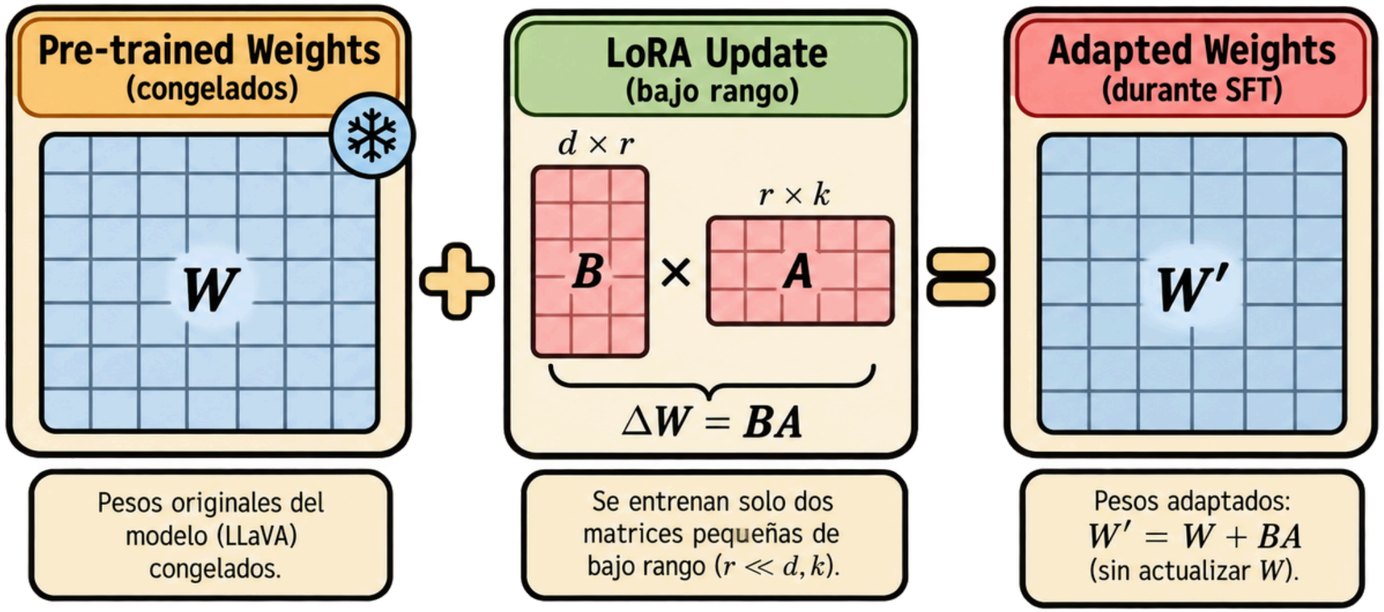

SETUP EXPERIMENTAL

¿Cómo probaron el modelo? Con 3 datasets reales, 5 tipos de baselines y 3 métricas.

Datasets

Microlens. Videos cortos tipo TikTok, con título y portada.

Amazon-Baby y **Amazon-Game.** Productos con descripción y foto.

Más de **99,9% de sparsity**. De cada 10.000 pares usuario-ítem, menos de 5 tienen una interacción.

Historiales cortos, de **~12 ítems** por usuario.

Baselines

GRU4Rec, SASRec. Usan el orden, pero no la imagen.

MMGCN, MGAT. Usan la imagen, pero no el orden.

SASRec_F, MMSR, Trans2D. Usan orden e imagen, pero no un LLM.

TALLRec. LLM ajustado para recomendar, pero solo con texto.

LLaVA sin SFT. El MLLM sin entrenar.

Métricas

Cada ítem real compite contra **20 negativos al azar**, o sea 21 candidatos.

AUC. ¿Le gana a los negativos?

HR@5. ¿Quedó en el top 5?

MRR@5. ¿Qué tan arriba quedó? Primero vale 1, tercero vale 1/3.

Adivinando se obtiene **AUC 50** y **HR@5 de 24%**.

RESULTADOS PRINCIPALES

Tabla 3 del paper. En amarillo MLLM-MSR, en azul TALLRec y en gris LLaVA sin SFT.

	Microlens			Video-Games			Amazon-Baby		
	AUC	HR@5	MRR@5	AUC	HR@5	MRR@5	AUC	HR@5	MRR@5
GRU4Rec	72.55	53.32	33.36	73.45	59.32	34.56	73.68	58.21	35.81
SASRec	74.02	58.88	36.57	71.06	43.81	23.94	80.50	70.09	52.34
MGAT	71.23	42.37	30.84	72.21	48.71	32.17	73.19	46.42	31.92
MMGCN	73.35	54.47	34.14	74.91	55.63	35.19	74.88	57.13	36.13
$GRU4Rec_F$	75.31	60.28	33.25	75.79	62.38	36.39	76.41	63.84	35.77
$SASRec_F$	77.69	63.03	37.42	77.51	66.64	43.55	81.94	72.08	58.32
MMSR	78.87	69.85	55.21	79.01	71.95	56.52	81.19	70.34	56.38
Trans2D	70.23	51.91	31.21	72.20	56.70	39.28	66.60	28.94	45.91
LLaVa	52.75	28.21	17.33	53.57	33.24	18.73	55.86	34.82	20.96
TALLREC	81.25	71.23	58.22	81.79	72.36	57.38	82.16	74.31	60.15
MLLM-MSR	**83.17**	**78.23**	**60.38**	**84.39**	**77.42**	**63.25**	**85.69**	**79.58**	**63.77**

Mejor en todo

Gana en los 3 datasets y en las 3 métricas, con **AUC entre 83 y 86**.

+5 a +7 pts sobre TALLRec

Mismo enfoque pero solo con texto. La mejora en HR@5 se atribuye a **la imagen**.

LLaVA sin SFT ≈ azar

AUC 53, cuando adivinar da 50. El salto viene del **fine-tuning**.

Imagen y orden

La imagen sube SASRec de 74 a 78. Sin orden, **MMGCN y MGAT** quedan abajo.

ABLACIÓN

¿Qué aporta cada pieza? Se le saca una al modelo y se mide cuánto cae el AUC.

Sin inferencia recurrente (azul)

Los 12 ítems del historial van en un solo prompt a Llama 3. El AUC baja **entre 2 y 4 puntos**, así que resumir por bloques sí ayuda.

Sin resumen de imagen (rojo)

El perfil se arma solo con los títulos, sin mirar las portadas del historial. Es la que más cae, **unos 5 puntos**.

Ojo. La variante sin imagen igual ve la portada del candidato. Lo que se pierde es **lo visual del historial**. Además, el eje parte en 0,70, así que las diferencias se ven más grandes de lo que son.

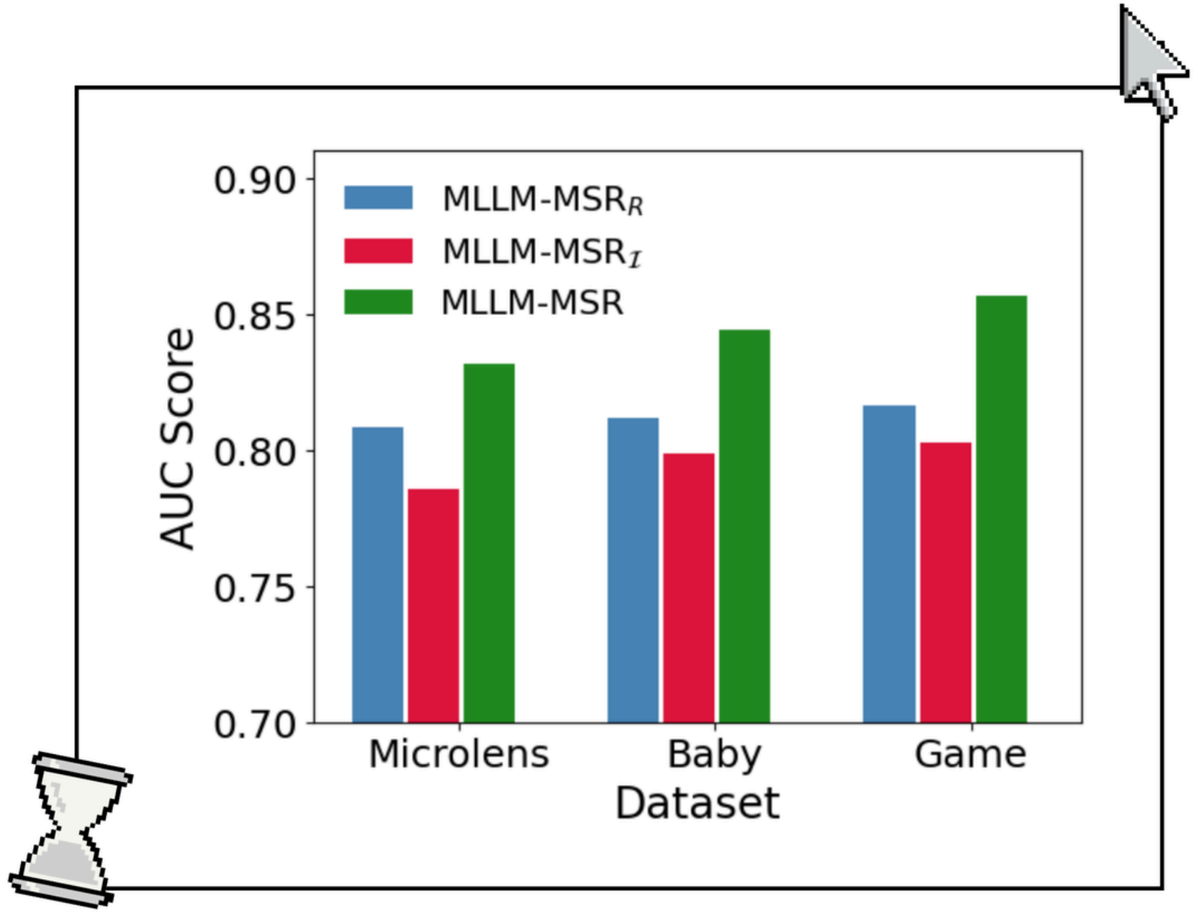

Figura 4 del paper · verde = modelo completo

ANÁLISIS DE SENSIBILIDAD

Se mueve un parámetro a la vez. En cada figura, izquierda AUC y derecha MRR@5, una línea por dataset.

Ítems por bloque

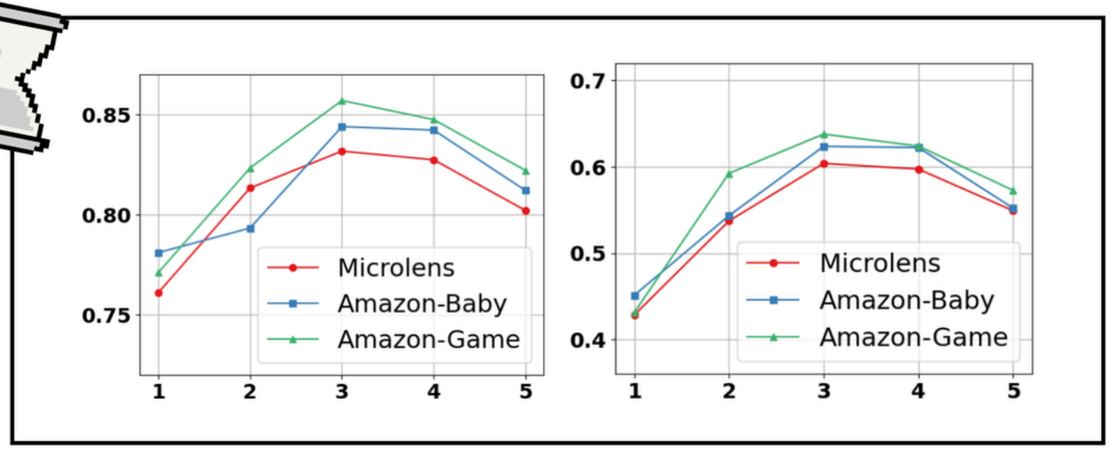

¿Qué es? Cuántos ítems del historial ve Llama 3 en cada actualización del perfil del usuario.

Resultado. El óptimo es **3 ítems**. Con 1 no hay contexto para ver un patrón, y con 5 hay pocas actualizaciones y se pierde cómo cambian los gustos.

Largo del resumen (tokens)

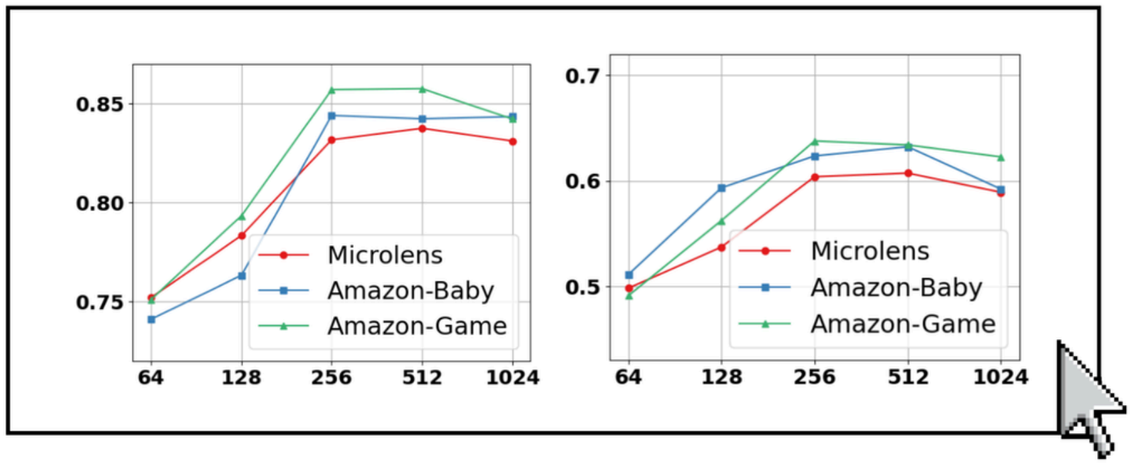

¿Qué es? El largo máximo del perfil del usuario. 64 tokens son un par de líneas, 512 un párrafo completo.

Resultado. Mejora hasta **256 a 512 tokens** y después se estabiliza. Un perfil más largo no agrega información, solo costo.

ANÁLISIS CRÍTICO

Los resultados son buenos, pero la forma de evaluar los hace ver mejores que en un sistema real.

Evaluación optimista

Cada ítem real compite contra solo **20 negativos al azar**, que suelen ser fáciles de descartar.

En una app real serían **miles de candidatos**, muchos parecidos al correcto.

Usan validación cruzada sin **split temporal**, así que el modelo podría entrenar con datos del futuro.

Costo no reportado

La eficiencia motiva el paper, pero **nunca se mide**.

Un usuario con 12 ítems requiere **16 llamadas** a modelos grandes solo para armar su perfil.

Después hay que correr **un modelo de 7B por cada candidato**. Con todo el catálogo serían miles de llamadas por usuario.

Otros vacíos

Secuencias cortas. Con ~12 ítems no se prueba el caso de historiales largos que motiva el método.

Sin desviaciones estándar en la Tabla 3, aunque dicen tener 95% de confianza.

Resúmenes sin evaluar. Si LLaVA describe mal una portada, el error pasa al perfil.

CONCLUSIONES

¿Qué nos llevamos del paper?

Todo a texto

Convertir cada ítem en un párrafo evita darle al MLLM **muchas imágenes juntas**, y deja un perfil del usuario que una persona puede leer.

Perfil recurrente

Resumir el historial por bloques captura **cómo cambian los gustos**. La ablación muestra que la recurrencia y la imagen aportan.

El fine-tuning es clave

Supera a todos los baselines, pero **sin entrenamiento el MLLM queda en el azar**.

Queda abierto

¿Cuánto cuesta llevarlo a un **catálogo real** con miles de ítems?

¿Qué tan **fieles** son los resúmenes que genera el LLM?

¿Funciona con **historiales largos**, de cientos de ítems?

¡GRACIAS! ¿PREGUNTAS?

REFERENCIAS

Bao, K., Zhang, J., Zhang, Y., Wang, W., Feng, F. y He, X. (2023). TALLRec: An effective and efficient tuning framework to align large language model with recommendation. En *Proceedings of the 17th ACM Conference on Recommender Systems* (pp. 1007–1014). ACM. https://doi.org/10.1145/3604915.3608857

Hidasi, B., Karatzoglou, A., Baltrunas, L. y Tikk, D. (2015). *Session-based recommendations with recurrent neural networks*. arXiv. https://arxiv.org/abs/1511.06939

Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. y Chen, W. (2022). LoRA: Low-rank adaptation of large language models. En *International Conference on Learning Representations.* https://openreview.net/forum?id=nZeVKeeFYf9

Kang, W.-C. y McAuley, J. (2018). Self-attentive sequential recommendation. En *2018 IEEE International Conference on Data Mining* (ICDM) (pp. 197–206). IEEE. https://doi.org/10.1109/ICDM.2018.00035

Liu, H., Li, C., Li, Y., Li, B., Zhang, Y., Shen, S. y Lee, Y. J. (2024, 30 de enero). *LLaVA-NeXT: Improved reasoning, OCR, and world knowledge* [Entrada de blog]. https://llava-vl.github.io/blog/2024-01-30-llava-next/

Liu, H., Li, C., Wu, Q. y Lee, Y. J. (2023). Visual instruction tuning. *Advances in Neural Information Processing Systems, 36*. https://proceedings.neurips.cc/paper_files/paper/2023/hash/6dcf277ea32ce3288914faf369fe6de0-Abstract.html

Rendle, S., Freudenthaler, C. y Schmidt-Thieme, L. (2010). Factorizing personalized Markov chains for next-basket recommendation. En *Proceedings of the 19th International Conference on World Wide Web* (pp. 811–820). ACM. https://doi.org/10.1145/1772690.1772773 †

Sun, F., Liu, J., Wu, J., Pei, C., Lin, X., Ou, W. y Jiang, P. (2019). BERT4Rec: Sequential recommendation with bidirectional encoder representations from transformer. En *Proceedings of the 28th ACM International Conference on Information and Knowledge Management* (pp. 1441–1450). ACM. https://doi.org/10.1145/3357384.3357895

Ye, Y., Zheng, Z., Shen, Y., Wang, T., Zhang, H., Zhu, P., Yu, R., Zhang, K. y Xiong, H. (2025). Harnessing multimodal large language models for multimodal sequential recommendation. *Proceedings of the AAAI Conference on Artificial Intelligence, 39*(12), 13069–13077. https://doi.org/10.1609/aaai.v39i12.33426