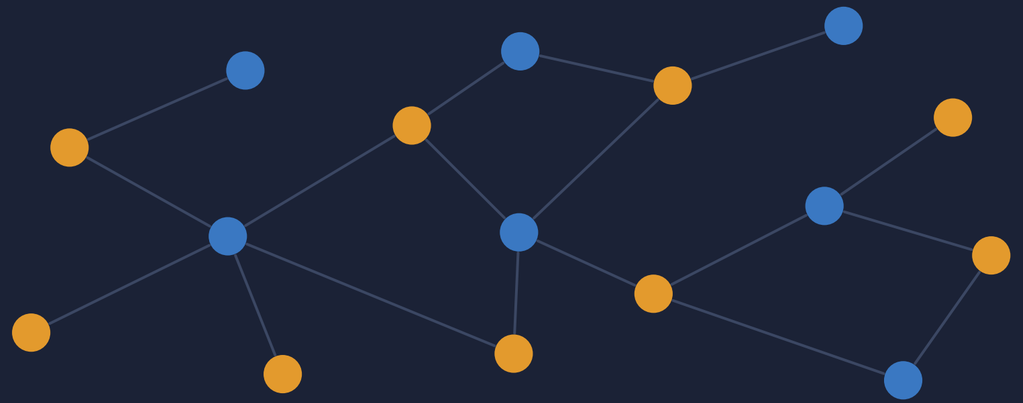
SIGIR ’25 · Padua, Italia

Comprehending Knowledge Graphs with Large Language Models for Recommender Systems

Ziqiang Cui, Yunpeng Weng, Xing Tang, Fuyuan Lyu, Dugang Liu, Xiuqiang He y Chen Ma
City University of Hong Kong · FiT, Tencent · McGill & MILA · Shenzhen University · Shenzhen Technology University



Benjamín Flores, Agustín González, Tomás Labraña
IIC3633 - Sistemas Recomendadores - 05/11/2026

Contexto

Sobrecarga de información

Gran avance de plataformas en línea. Como solución, los recomendadores modelan las preferencias de los usuarios a partir de su historial (Cui et al., 2025).

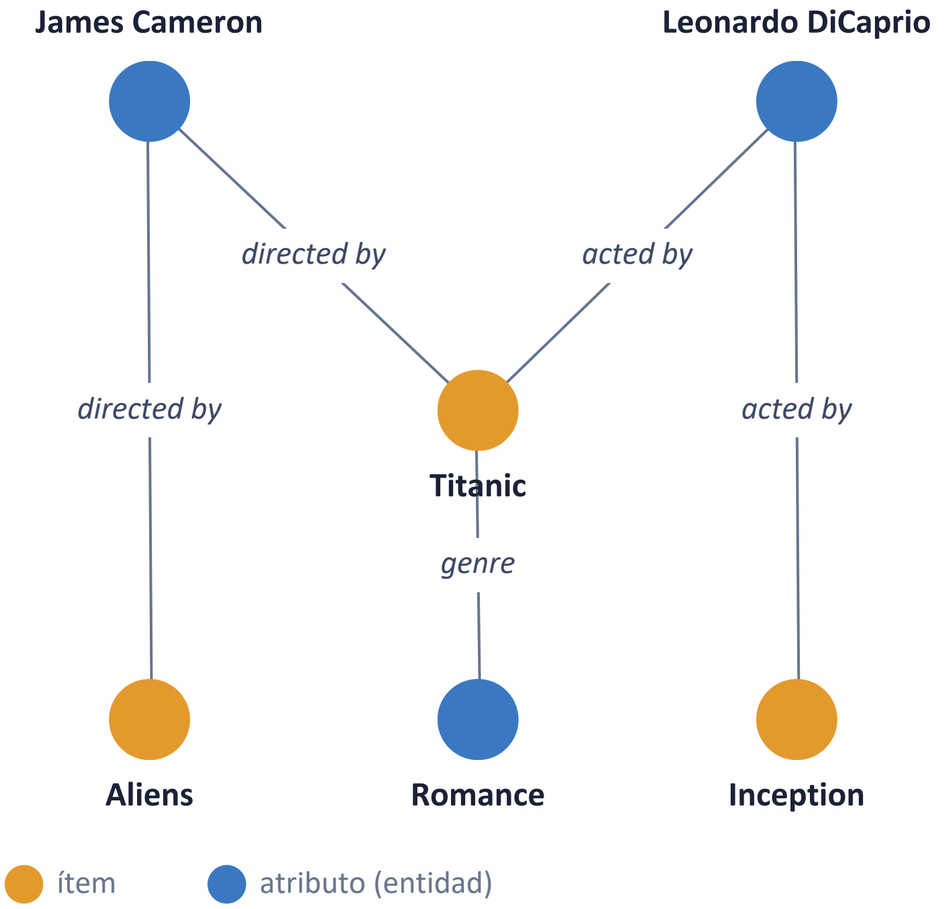
El filtrado colaborativo sufre con la dispersión

BPR-MF o LightGCN solo usan interacciones usuario-ítem; con pocos datos por usuario, el modelo aprende mal (Rendle et al., 2009; He et al., 2020).

Grafos de conocimiento (KG)

Ítems se conectan mediante atributos compartidos, como director, género o actor (Guo et al., 2022).

Ejemplo de KG de películas



Ejemplo basado en la Figura 2 de Cui et al. (2025)

Tres limitaciones de los métodos con KG

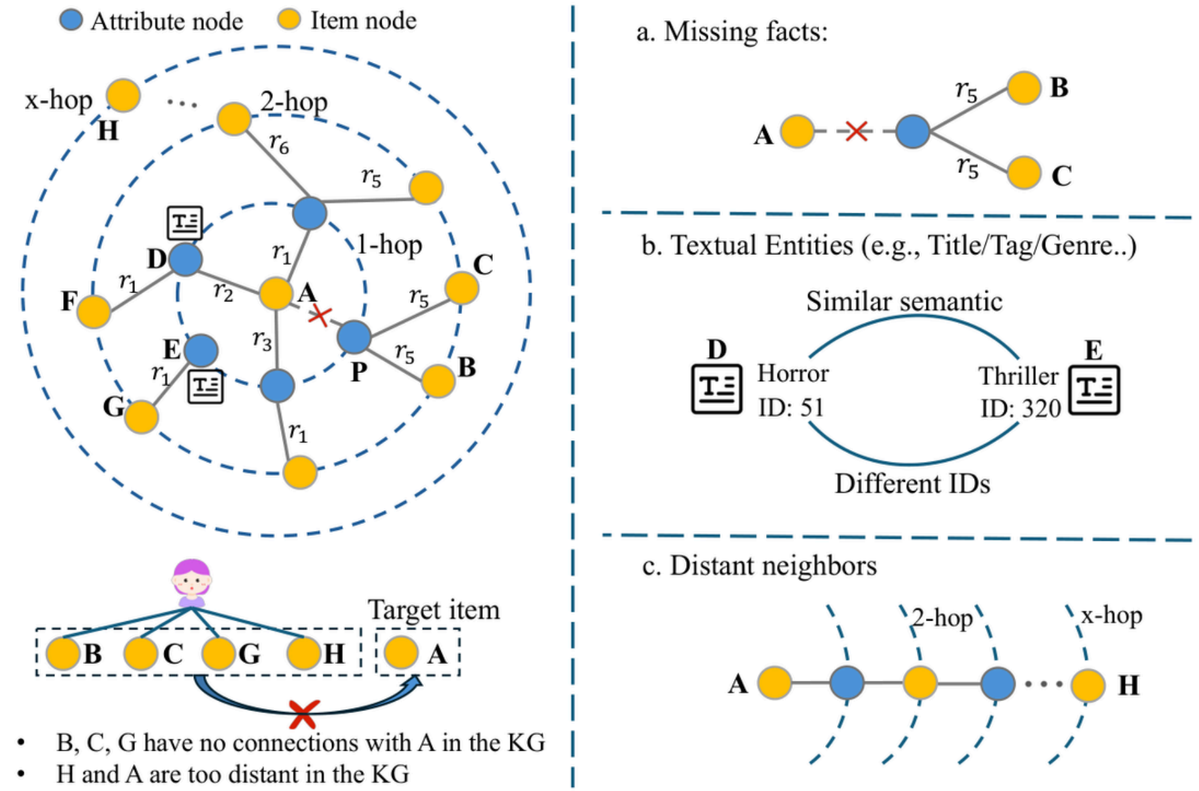


Figura 1. Problemas de los métodos actuales basados en KG (Cui et al., 2025)

a **Hechos faltantes**

Los KG se construyen a mano y quedan incompletos: si A pierde el atributo P, desaparece el camino A–P–B.

b **El texto se convierte en IDs**

«Horror» (ID 51) y «Thriller» (ID 320) significan algo parecido, pero sus IDs no reflejan esa cercanía.

c **Vecinos distantes**

Para capturar relaciones de alto orden hay que apilar capas GNN, lo que es ineficiente, acumula ruido y produce over-smoothing.

Oportunidad: los LLMs aportan conocimiento de mundo y razonamiento, pero un KG completo no cabe en un prompt.

Problema de recomendación

Interacciones
Usuarios $\mathcal{U}$, ítems $\mathcal{V}$ y grafo bipartito $\mathcal{G} = \{(u, y_{uv}, v) \mid u \in \mathcal{U}, v \in \mathcal{V}\}$, con $y_{uv} = 1$ si u interactuó con v (feedback implícito).

Grafo de conocimiento
$\mathcal{G}_k = \{(h, r, t)\}$ con $h, t \in \mathcal{E}$ y $r \in \mathcal{R}$; los ítems son entidades: $\mathcal{V} \subset \mathcal{E}$. Ej.: (James Cameron, directed, Titanic).

Objetivo
Dados $\mathcal{G}$ y $\mathcal{G}_k$, aprender un modelo que estime $\hat{y}_{uv}$, la probabilidad de que u interactúe con v, y recomendar el **top-K** de ítems no vistos.

¿Qué se recomienda?

Películas
MovieLens-1M · valoraciones (Harper & Konstan, 2015)

Artistas musicales
Last-FM (HetRec 2011) · escuchas + tags (Cantador et al., 2011)

Noticias
MIND · clics en Microsoft News (Wu et al., 2020)

Fondos de inversión
Funds · plataforma financiera en línea (industrial privado)

Estado del arte y marco teórico

Recomendación con KG

Embeddings	CKE usa TransR sobre el KG junto con CF (Zhang et al., 2016)
Caminos	PER y MCRec usan meta-paths diseñados a mano (Yu et al., 2014; Hu et al., 2018)
GNN	KGAT y KGIN propagan información por varios saltos (Wang et al., 2019, 2021)
Auto-supervisado	KGCL y KGRec usan aprendizaje contrastivo para filtrar ruido del KG (Yang et al., 2022, 2023)

LLMs en recomendación

LLM como recomendador
Recomendación zero/few-shot, o CLLM4Rec (Zhu et al., 2024). Con datasets grandes suele rendir menos que un modelo tradicional.

LLM como extractor de features
RLMRec y KAR generan perfiles o embeddings que alimentan un recomendador clásico (Ren et al., 2024; Xi et al., 2024). No aprovechan la estructura del KG.

Conceptos base que usa CoLaKG

- **LightGCN (He et al., 2020)**
- **Pérdida BPR (Rendle et al., 2009)**
- **SimCSE: embeddings de texto (Gao et al., 2021)**
- **Atención tipo GAT (Veličković et al., 2018)**

Contribución frente a otros trabajos

Familia	Usa la estructura del KG	Semántica del texto	Completa hechos faltantes	Relaciones globales de alto orden	Sin LLM al recomendar
KG + GNN (KGAT, KGIN, KGCL, KGRec)	✓	✗	✗	*parcial: apila capas*	✓
LLM como extractor (RLMRec, KAR)	*no: solo perfiles*	✓	*parcial*	✗	✓
LLM como recomendador (CLLM4Rec)	✗	✓	✗	✗	✗
CoLaKG	✓	✓	✓	✓	✓

Elaboración propia, basado en Cui et al. (2025)

1 **LLM comprende el KG**
Transforma la información contenida en el KG en texto y embeddings, lo que ataca los hechos faltantes y la pérdida de semántica.

2 **Local + global**
Combina subgrafos centrados en cada ítem con la recuperación de ítems semánticamente cercanos en todo el KG.

3 **Desacoplado y validado**
LLM se usa solo offline. Además, se evalúa en 4 datasets reales, uno de ellos industrial para validarlo.

CoLaKG: visión general

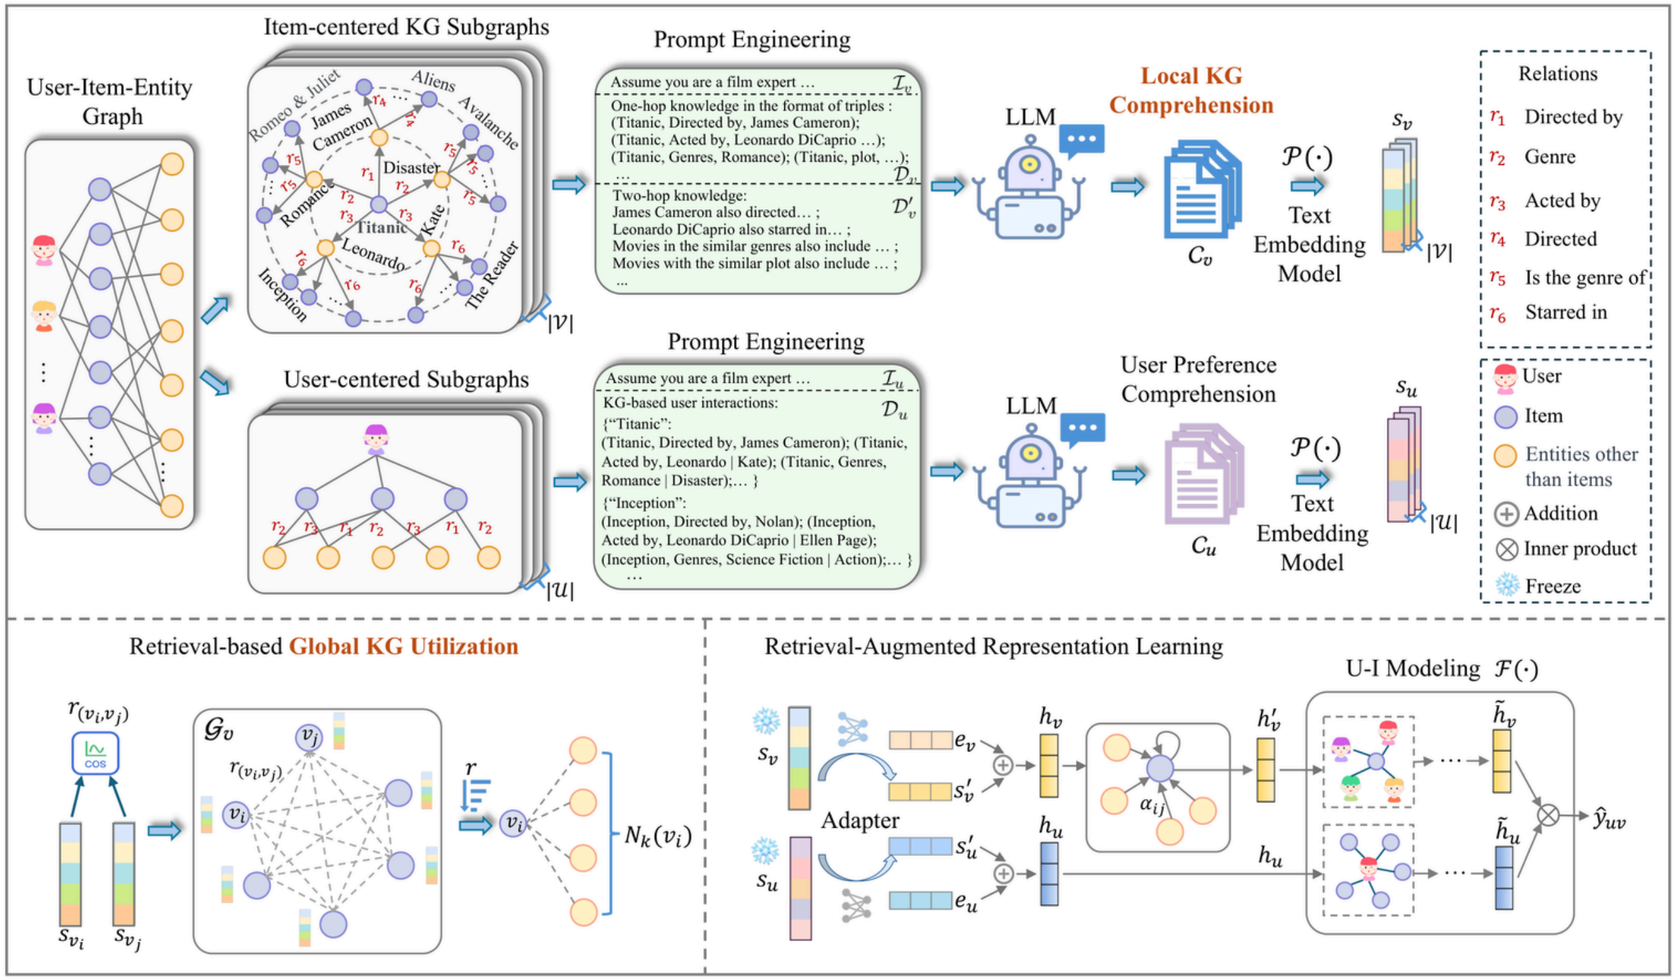


Figura 2. Arquitectura de CoLaKG (Cui et al., 2025)

Etapa 1 · offline

Comprender el KG con un LLM

- ***Local:*** subgrafo de cada ítem → s_v
- ***Usuario:*** historial + tripletas → s_u
- ***Global:*** grafo ítem-ítem → top-k vecinos

Etapa 2 · entrenamiento

Integrar en el recomendador

- Adapter + fusión con embeddings de ID
- Atención sobre vecinos
- LightGCN + pérdida BPR

Comprensión local del KG

1. **Subgrafo de 1 salto**
   Tripletas $\mathcal{T}v$ = {(*v, r, e*)} concatenadas en el texto $\mathcal{D}$v; si falta un atributo se escribe ***missing***.

2. **Muestreo de 2 saltos**
   Por cada atributo *e* se muestrean *m* tripletas (*e, r, v'*) y una plantilla las convierte en oraciones $\mathcal{D}'$v.

3. **Prompt al LLM**
   LLM completa, resume y describe a qué usuarios le gustaría el ítem.

4. **Embedding de texto**
   Un modelo pre-entrenado $\mathcal{P}$(SimCSE) convierte la respuesta Cv en el vector s_v.

$\mathcal{I}_v$	Assume you are an expert in movie recommendation. You will be given a certain movie with its first-order information (in the form of triples) and some second-order relationships (movies related to this movie). Please complete the missing knowledge, summarize the movie and analyze what kind of users would like it.
$\mathcal{D}_v$	**First-order info**: (Titanic, Directed by, James Cameron), (Titanic, Acted by, Leonardo DiCaprio), …
$\mathcal{D}'_v$	**Second-order info**: The movies with the same director (James Cameron) also include: Aliens, … The movies with the same actor (Leonardo DiCaprio) also include: Inception, … …

Figura 3. Plantilla del prompt para comprensión local (Cui et al., 2025)

$$C_v = \text{LLMs}(\mathcal{I}_v, \mathcal{D}_v, \mathcal{D}'_v). \quad (1)$$

$$\mathbf{s}_v = \mathcal{P}(C_v). \quad (2)$$

¿Por qué muestrear?
- Crecimiento exponencial con el radio.
- Prompt tiene un límite de tokens.

Preferencias del usuario y KG global

Comprensión de preferencias

Por cada ítem del historial de entrenamiento de *u* se concatenan su nombre y sus tripletas de 1 salto. El LLM resume los gustos del usuario (géneros, directores, actores).

$$\mathcal{D}_u = \oplus_{v \in \mathcal{G}_u} \{\text{name}_v : \mathcal{D}_v\}, \tag{5}$$

$$C_u = \text{LLMs}(\mathcal{I}_u, \mathcal{D}_u). \tag{6}$$

$$\mathbf{s}_u = \mathcal{P}(C_u). \tag{7}$$

El mismo LLM y el mismo $\mathcal{P}$ que para los ítems

Uso global del KG por recuperación

Se calcula la similitud coseno entre los embeddings de todos los subgrafos. Eso define un grafo ítem-ítem semántico $\mathcal{G}v$, y para cada ítem se recuperan sus **top-k** vecinos $\mathcal{N}_k(v_i)$.

$$r_{(v_i,v_j)} = \text{sim}(\mathbf{s}_{v_i}, \mathbf{s}_{v_j}), \quad v_i, v_j \in \mathcal{V} \text{ and } v_i \neq v_j, \tag{3}$$

$$\mathcal{G}_v = \{(v_i, r_{(v_i,v_j)}, v_j) | v_i, v_j \in \mathcal{V}, v_i \neq v_j\}. \tag{4}$$

Objetivo esperado: una relación de alto orden en el KG pasa a ser una arista directa, sin propagar capa por capa.

Representación aumentada por recuperación

1

Alineación entre modalidades

Un adapter (lineal + ELU) proyecta s_v y s_u (dim. 1024) al espacio de IDs (d = 64). Los vectores semánticos quedan congelados.

$$\mathbf{s}'_v = \sigma(\mathbf{W}_1\mathbf{s}_v); \quad \mathbf{s}'_u = \sigma(\mathbf{W}_2\mathbf{s}_u), \tag{8}$$

2

Fusión

Promedio entre el embedding de ID (señal colaborativa) y el embedding semántico.

$$\mathbf{h}_v = \frac{1}{2}(\mathbf{e}_v + \mathbf{s}'_v); \quad \mathbf{h}_u = \frac{1}{2}(\mathbf{e}_u + \mathbf{s}'_u), \tag{9}$$

3

Aumento con vecinos

La atención (tipo GAT) se calcula solo con la semántica de los ítems. Luego se agregan los top-k vecinos recuperados.

$$w_{ij} = a(\mathbf{W}\mathbf{s}_{v_i} \| \mathbf{W}\mathbf{s}_{v_j}). \tag{10}$$

$$\alpha_{ij} = \mathrm{softmax}_j(w_{ij}). \tag{11}$$

$$\mathbf{h}'_{v_i} = \sigma\left(\frac{1}{2}\left(\mathbf{h}_{v_i} + \sum\nolimits_{j \in \mathcal{N}_k(v_i)} \alpha_{ij}\mathbf{h}_{v_j}\right)\right), \tag{12}$$

Modelado usuario-ítem y entrenamiento

Backbone: LightGCN (He et al., 2020)

Propagación sin transformaciones ni no-linealidades, con L capas. Entradas: $h^{(0)}u = hu$ y $h^{(0)}v = h'v$.

$$\hat{y}_{uv} = \mathcal{F}(\mathbf{h}_u, \mathbf{h}'_v), \tag{13}$$

$$\mathbf{h}_u^{(l+1)} = \sum_{v \in \mathcal{M}_u} \frac{1}{\sqrt{|\mathcal{M}_u||\mathcal{M}_v|}} \mathbf{h}_v^{(l)}; \; \mathbf{h}_v^{(l+1)} = \sum_{u \in \mathcal{M}_v} \frac{1}{\sqrt{|\mathcal{M}_v||\mathcal{M}_u|}} \mathbf{h}_u^{(l)}, \tag{14}$$

$$\tilde{\mathbf{h}}_u = \frac{1}{L+1} \sum_{l=0}^{L} \mathbf{h}_u^{(l)}; \quad \tilde{\mathbf{h}}_v = \frac{1}{L+1} \sum_{l=0}^{L} \mathbf{h}_v'^{(l)}, \tag{15}$$

$$\hat{y}_{uv} = \tilde{\mathbf{h}}_u^{\top} \tilde{\mathbf{h}}_v. \tag{16}$$

Agregación por capa → promedio de capas → producto interno

Entrenamiento

Pérdida BPR (Rendle et al., 2009):

$$\mathcal{L} = \sum_{(u,v^+,v^-) \in O} -\ln \sigma(\hat{y}_{uv^+} - \hat{y}_{uv^-}) + \lambda \|\Theta\|_2^2. \tag{17}$$

- Cada positivo se empareja con 1 negativo muestreado
- Solo se entrena la etapa 2: embeddings de ID, adapters y atención

Configuración experimental

Statistics	MovieLens	Last-FM	MIND	Funds
# Users	6,040	1,859	44,603	209,999
# Items	3,260	2,813	15,174	5,701
# Interactions	998,539	86,608	1,285,064	1,225,318
Knowledge Graph				
# Entities	12,068	9,614	32,810	8,111
# Relations	12	2	14	12
# Triples	62,958	118,500	307,140	65,697

Tabla 1. Estadísticas de los datasets (Cui et al., 2025)

Preprocesamiento

- Se eliminan usuarios e ítems con < 5 interacciones
- Conjuntos Train/Test con razón 8:2
- 1 negativo por cada positivo
- m = 10 (ML, MIND) y m = 5 (Last-FM).

Métricas

- Recall@K y NDCG@K con K ∈ {10, 20}
- Protocolo all-ranking (todos los ítems no vistos son candidatos).

Baselines

- Clásicos: BPR-MF, NFM, LightGCN
- KG: CKE, RippleNet, KGAT, KGIN, KGCL, KGRec
- LLM: RLMRec, KAR, CLLM4Rec

Implementación

- LLM DeepSeek-V2 vía API, $\tau = 0$ y top-p = 0,001 (DeepSeek-AI, 2024)
- SimCSE-RoBERTa-large (Gao et al., 2021)
- d = 64, Adam con lr = 0,001, L = 3
- Promedio de 5 corridas.

Resultados principales

Model	MovieLens				Last-FM				MIND				Funds			
	R@10	N@10	R@20	N@20	R@10	N@10	R@20	N@20	R@10	N@10	R@20	N@20	R@10	N@10	R@20	N@20
BPR-MF	0.1257	0.3100	0.2048	0.3062	0.1307	0.1352	0.1971	0.1685	0.0315	0.0238	0.0537	0.0310	0.4514	0.3402	0.5806	0.3809
NFM	0.1346	0.3558	0.2129	0.3379	0.2246	0.2327	0.3273	0.2830	0.0495	0.0356	0.0802	0.0458	0.4388	0.3187	0.5756	0.3651
LightGCN	0.1598	0.3901	0.2512	0.3769	0.2589	0.2799	0.3642	0.3321	0.0624	0.0492	0.0998	0.0609	0.4992	0.3778	0.6353	0.4204
CKE	0.1524	0.3783	0.2373	0.3609	0.2342	0.2545	0.3266	0.3001	0.0526	0.0417	0.0822	0.0510	0.4926	0.3702	0.6294	0.4130
RippleNet	0.1415	0.3669	0.2201	0.3423	0.2267	0.2341	0.3248	0.2861	0.0472	0.0364	0.0785	0.0451	0.4764	0.3591	0.6124	0.4003
KGAT	0.1536	0.3782	0.2451	0.3661	0.2470	0.2595	0.3433	0.3075	0.0594	0.0456	0.0955	0.0571	0.5037	0.3751	0.6418	0.4182
KGIN	0.1631	0.3959	0.2562	0.3831	0.2562	0.2742	0.3611	0.3215	0.0640	0.0518	0.1022	0.0639	0.5079	0.3857	0.6428	0.4259
KGCL	0.1554	0.3797	0.2465	0.3677	0.2599	0.2763	0.3652	0.3284	0.0671	0.0543	0.1059	0.0670	0.5071	0.3877	0.6355	0.4273
KGRec	0.1640	0.3968	0.2571	0.3842	0.2571	0.2748	0.3617	0.3251	0.0627	0.0506	0.1003	0.0625	0.5104	0.3913	0.6467	0.4304
RLMRec	0.1613	0.3920	0.2524	0.3787	0.2597	0.2812	0.3651	0.3335	0.0619	0.0486	0.0990	0.0602	0.4988	0.3784	0.6351	0.4210
KAR	0.1582	0.3869	0.2511	0.3722	0.2532	0.2770	0.3612	0.3324	0.0615	0.0480	0.1002	0.0613	0.5033	0.3812	0.6312	0.4175
CLLM4Rec	0.1563	0.3841	0.2433	0.3637	0.2571	0.2793	0.3642	0.3268	0.0631	0.0494	0.1012	0.0628	0.4996	0.3791	0.6273	0.4103
CoLaKG	**0.1699**	**0.4130**	**0.2642**	**0.3974**	**0.2738**	**0.2948**	**0.3803**	**0.3471**	**0.0698**	**0.0562**	**0.1087**	**0.0684**	**0.5273**	**0.4012**	**0.6524**	**0.4392**

Tabla 2. Comparación de resultados (Cui et al., 2025)

+0,9 a 5,35 %

Sobre el mejor baseline en cada dataset y métrica.

p < 0,01

Mejora estadísticamente significativa en los 4 datasets.

Generalización y ablación

Model	MovieLens		Last-FM		MIND	
	R@20	N@20	R@20	N@20	R@20	N@20
BPR-MF	0.2048	0.3062	0.1971	0.1685	0.0537	0.0310
BPR-MF+Ours	0.2213	0.3255	0.2104	0.1812	0.0609	0.3986
NFM	0.2129	0.3379	0.3273	0.2830	0.0802	0.0458
NFM+Ours	0.2285	0.3527	0.3478	0.2996	0.0859	0.0487
LightGCN	0.2512	0.3769	0.3642	0.3321	0.0998	0.0609
LightGCN+Ours	0.2642	0.3974	0.3803	0.3471	0.1087	0.0684

Tabla 3. Validación de generalización (Cui et al., 2025)

	Metric	w/o $\mathbf{s}_v$	w/o $\mathbf{s}_u$	w/o $\mathcal{N}_k(v)$	w/o $\mathcal{D}'_v$	CoLaKG
ML	R@20	0.2553	0.2613	0.2603	0.2628	**0.2642**
	N@20	0.3811	0.3948	0.3902	0.3960	**0.3974**
Last-FM	R@20	0.3628	0.3785	0.3725	0.3789	**0.3803**
	N@20	0.3278	0.3465	0.3403	0.3459	**0.3471**
MIND	R@20	0.1043	0.1048	0.1064	0.1076	**0.1087**
	N@20	0.0640	0.0658	0.0662	0.0671	**0.0684**
Funds	R@20	0.6382	0.6481	0.6455	0.6499	**0.6524**
	N@20	0.4247	0.4351	0.4305	0.4378	**0.4392**

Tabla 4. Estudio de ablación (Cui et al., 2025)

- Mejora de los 3 backbones en los 3 datasets.
- Concluye que el enfoque es agnóstico al modelo.

- Orden de importancia:
  - Semántica de items
  - Vecinos recuperados
  - Semántica de usuarios
  - Conexiones de segundo orden

Hiperparámetros y robustez

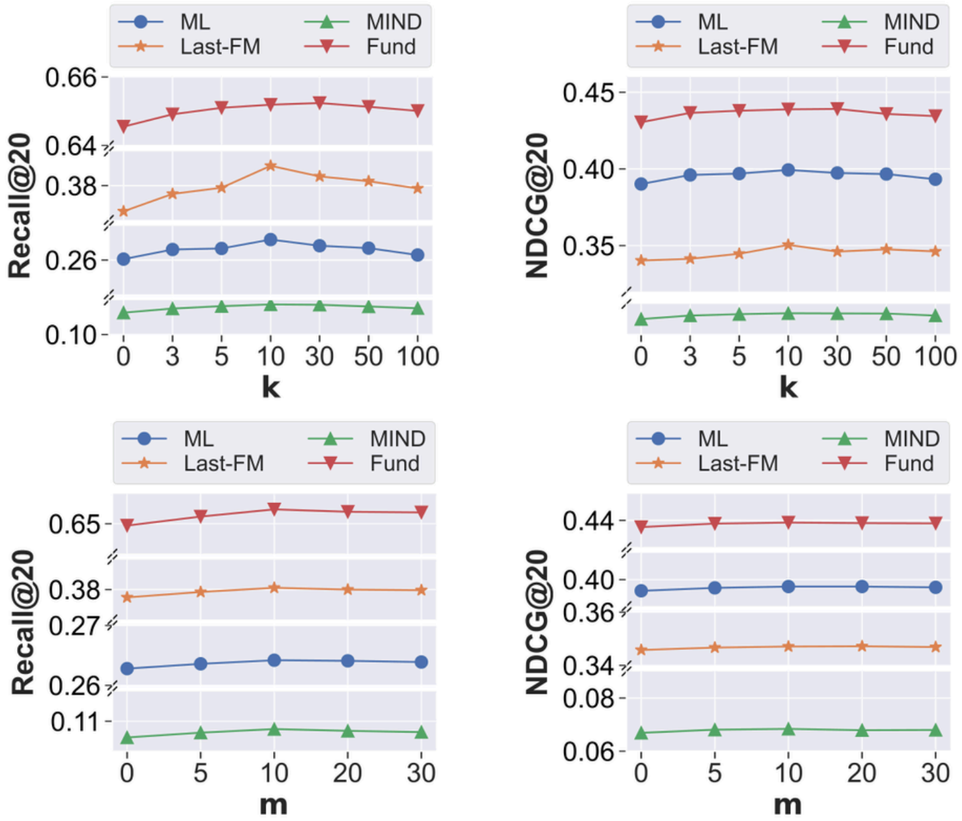


Figura 4. Estudio de hiperparámetros (Cui et al., 2025)

Número de vecinos k y muestras de 2 saltos m
Óptimo ≈ 10–30 vecinos. m > 0, poca ventaja al optimizar.

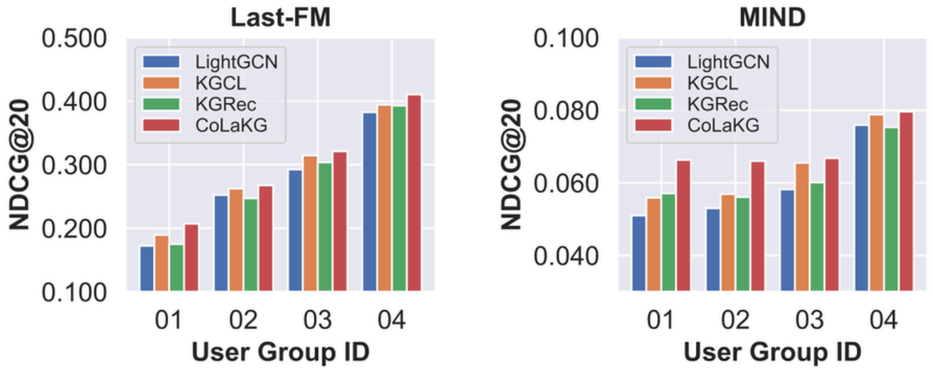


Figura 5. Comparación de performance según interacciones (Cui et al., 2025)

Dispersión (Last-FM, MIND): mayor ventaja en usuarios con menos interacciones (grupo 01).

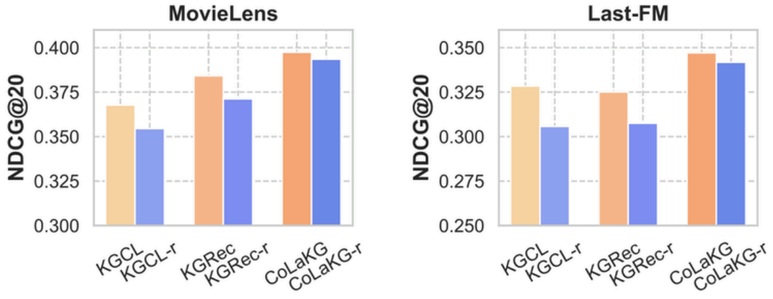


Figura 6. Comparación de performance con información faltante (Cui et al., 2025)

Hechos faltantes: CoLaKG es el que menos cae.

Caso de estudio



Figura 7. Caso de estudio (Cui et al., 2025)

Caso 1 · Apollo 13

- Top Gun y Star Trek: First Contact no comparten género ni otros atributos con Apollo 13.
- LLM los asocia por temas comunes de resiliencia, coraje y aventura.

Caso 2 · A Little Princess

- The Story of Cinderella y The Princess Bride deberían compartir género con A Little Princess, pero falta la conexión en el KG.
- LLM lo completa y conecta las películas.

Análisis crítico

Fortalezas

- LLM se usa offline y el recomendador sigue siendo LightGCN.
- Mejora consistente en varios datasets, todas las métricas y backbones.
- Estudio de ablación, robustez y generabilidad claros.
- Respuestas del LLM y los embeddings utilizados se encuentran en el repositorio.

Limitaciones y observaciones

- Inexistencia de análisis de costos.
- Metodología de datos se resume en un párrafo.
- Inconsistencias:
  - Interacciones: código muestra 71.294 interacciones de Last-FM, paper dice 86.608
  - Código no coincide con paper en varios ámbitos (variables no usadas, conexiones nulas ***unknown*** en vez de ***missing***)
- Evaluación dependiente del conocimiento de una LLM.

Conclusiones

- LLMs pueden «leer» subgrafos del KG: completan hechos faltantes y convierten el texto en semántica útil para recomendar.
- La recuperación sobre un grafo ítem-ítem semántico captura relaciones globales sin propagación profunda.
- Separar el LLM (offline) del recomendador lo hace viable en producción y aplicable a distintos backbones.

Demo en vivo: recuperación semántica

Referencias (1/2)

- Cantador, I., Brusilovsky, P., & Kuflik, T. (2011). Second workshop on information heterogeneity and fusion in recommender systems (HetRec 2011). En *Proceedings of the 5th ACM Conference on Recommender Systems* (pp. 387–388). ACM.
- Cui, Z., Weng, Y., Tang, X., Lyu, F., Liu, D., He, X., & Ma, C. (2025). Comprehending knowledge graphs with large language models for recommender systems. En *Proceedings of the 48th International ACM SIGIR Conference on Research and Development in Information Retrieval* (pp. 1229–1239). ACM. https://doi.org/10.1145/3726302.3729932
- DeepSeek-AI. (2024). *DeepSeek-V2: A strong, economical, and efficient mixture-of-experts language model* [Preprint]. arXiv. https://arxiv.org/abs/2405.04434
- Gao, T., Yao, X., & Chen, D. (2021). SimCSE: Simple contrastive learning of sentence embeddings. En *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing* (pp. 6894–6910). ACL.
- Guo, Q., Zhuang, F., Qin, C., Zhu, H., Xie, X., Xiong, H., & He, Q. (2022). A survey on knowledge graph-based recommender systems. *IEEE Transactions on Knowledge and Data Engineering, 34*(8), 3549–3568.
- Harper, F. M., & Konstan, J. A. (2015). The MovieLens datasets: History and context. *ACM Transactions on Interactive Intelligent Systems, 5*(4), Artículo 19.
- He, X., Deng, K., Wang, X., Li, Y., Zhang, Y., & Wang, M. (2020). LightGCN: Simplifying and powering graph convolution network for recommendation. En *Proceedings of the 43rd International ACM SIGIR Conference* (pp. 639–648). ACM.
- Hu, B., Shi, C., Zhao, W. X., & Yu, P. S. (2018). Leveraging meta-path based context for top-N recommendation with a neural co-attention model. En *Proceedings of the 24th ACM SIGKDD Conference* (pp. 1531–1540). ACM.
- Ren, X., Wei, W., Xia, L., Su, L., Cheng, S., Wang, J., Yin, D., & Huang, C. (2024). Representation learning with large language models for recommendation. En *Proceedings of the ACM Web Conference 2024* (pp. 3464–3475). ACM.
- Rendle, S., Freudenthaler, C., Gantner, Z., & Schmidt-Thieme, L. (2009). BPR: Bayesian personalized ranking from implicit feedback. En *Proceedings of the 25th Conference on Uncertainty in Artificial Intelligence* (pp. 452–461). AUAI Press.

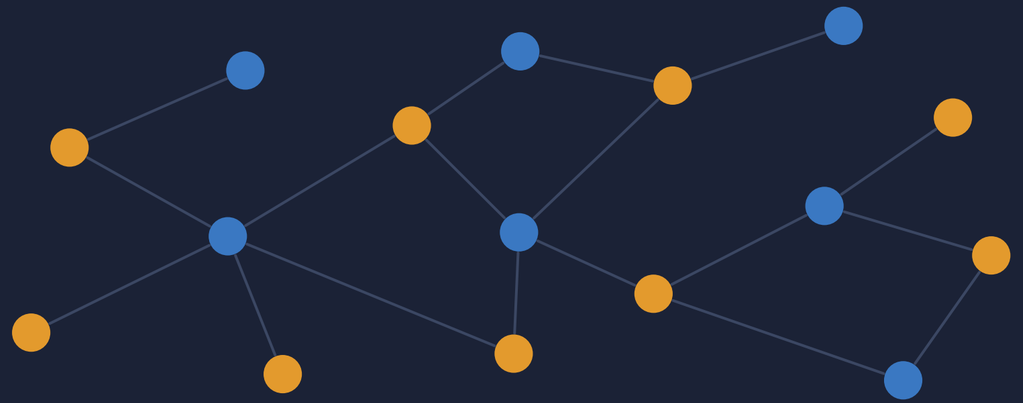
Referencias (2/2)

- Veličković, P., Cucurull, G., Casanova, A., Romero, A., Liò, P., & Bengio, Y. (2018). Graph attention networks. En *International Conference on Learning Representations (ICLR)*.
- Wang, X., He, X., Cao, Y., Liu, M., & Chua, T.-S. (2019). KGAT: Knowledge graph attention network for recommendation. En *Proceedings of the 25th ACM SIGKDD Conference* (pp. 950–958). ACM.
- Wang, X., Huang, T., Wang, D., Yuan, Y., Liu, Z., He, X., & Chua, T.-S. (2021). Learning intents behind interactions with knowledge graph for recommendation. En *Proceedings of the Web Conference 2021* (pp. 878–887). ACM.
- Wu, F., Qiao, Y., Chen, J.-H., Wu, C., Qi, T., Lian, J., Liu, D., Xie, X., Gao, J., Wu, W., & Zhou, M. (2020). MIND: A large-scale dataset for news recommendation. En *Proceedings of the 58th Annual Meeting of the ACL* (pp. 3597–3606). ACL.
- Xi, Y., Liu, W., Lin, J., Cai, X., Zhu, H., Zhu, J., Chen, B., Tang, R., Zhang, W., & Yu, Y. (2024). Towards open-world recommendation with knowledge augmentation from large language models. En *Proceedings of the 18th ACM Conference on Recommender Systems* (pp. 12–22). ACM.
- Yang, Y., Huang, C., Xia, L., & Huang, C. (2023). Knowledge graph self-supervised rationalization for recommendation. En *Proceedings of the 29th ACM SIGKDD Conference* (pp. 3046–3056). ACM.
- Yang, Y., Huang, C., Xia, L., & Li, C. (2022). Knowledge graph contrastive learning for recommendation. En *Proceedings of the 45th International ACM SIGIR Conference* (pp. 1434–1443). ACM.
- Yu, X., Ren, X., Sun, Y., Gu, Q., Sturt, B., Khandelwal, U., Norick, B., & Han, J. (2014). Personalized entity recommendation: A heterogeneous information network approach. En *Proceedings of the 7th ACM WSDM Conference* (pp. 283–292). ACM.
- Zhang, F., Yuan, N. J., Lian, D., Xie, X., & Ma, W.-Y. (2016). Collaborative knowledge base embedding for recommender systems. En *Proceedings of the 22nd ACM SIGKDD Conference* (pp. 353–362). ACM.
- Zhu, Y., Wu, L., Guo, Q., Hong, L., & Li, J. (2024). Collaborative large language model for recommender systems. En *Proceedings of the ACM Web Conference 2024* (pp. 3162–3172). ACM.

SIGIR ’25 · Padua, Italia

Comprehending Knowledge Graphs with Large Language Models for Recommender Systems

Ziqiang Cui, Yunpeng Weng, Xing Tang, Fuyuan Lyu, Dugang Liu, Xiuqiang He y Chen Ma
City University of Hong Kong · FiT, Tencent · McGill & MILA · Shenzhen University · Shenzhen Technology University



Benjamín Flores, Agustín González, Tomás Labraña
IIC3633 - Sistemas Recomendadores - 05/11/2026