Recommendation as Language Processing (RLP):

A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5)

Geng, S., Liu, S., Fu, Z., Ge, Y., & Zhang, Y. (2022)

Presentado por: Juan Barra, Max Casassus, Isabel Quezada (Grupo 8)
12/11/26

Contexto one-model-task

¿Y si recomendar fuera simplemente generar lenguaje?

Los sistemas tradicionales separan tareas, arquitecturas y objetivos. P5 adopta la lógica text-to-text: expresa múltiples problemas de recomendación como pares de entrada y salida en lenguaje, y los resuelve con un único modelo preentrenado.

Antes

Un modelo especializado por tarea, con señales y funciones objetivo distintas.

P5

Una interfaz textual común: prompt → generación. El conocimiento se comparte entre tareas.

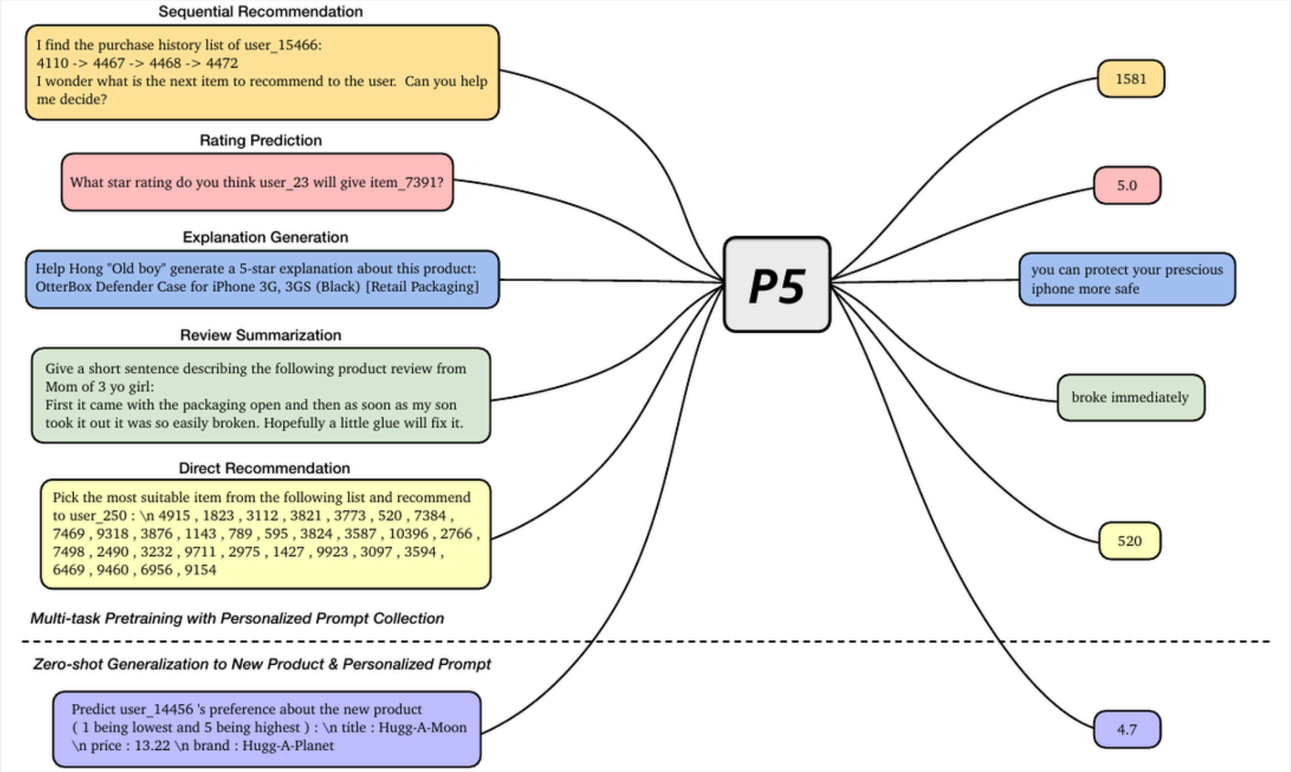
Raffel et al. (2020). Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer. JMLR 21(140). · Brown et al. (2020). Language Models are Few-Shot Learners. NeurIPS.

Problema de recomendación

U: conjunto de usuarios **I: conjunto de ítems**

Cada observación (usuario, ítem, contexto) se transforma mediante una plantilla en un prompt x. El modelo no entrega un score aislado: genera una secuencia textual y que representa la predicción requerida.

Prompt x → **Texto y**



Ej.: «What star rating do you think user_23 will give item_73?» → «5.0»

Geng, S., Liu, S., Fu, Z., Ge, Y., & Zhang, Y. (2022). Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5). RecSys '22.

Estado del arte y marco teórico

P5 se construye sobre T5 (Transformer codificador–decodificador preentrenado) y se apoya en cuatro líneas de trabajo previas:

Marcos unificados

T5 y GPT-3 resuelven muchas tareas de PLN como texto a texto con un mismo modelo. Según los autores, no consideran personalización.

Prompts en PLN

GPT-3 popularizó los prompts. FLAN y T0 entrenan con tareas redactadas como instrucciones y generalizan zero-shot. P5 adapta esta idea.

PLN en recomendación

Explicaciones, secuencias tratadas como lenguaje, extracción de texto y recomendación conversacional. Suelen proponerse por separado.

Arranque en frío

Usuarios o ítems sin historial: se modela contenido o se transfiere desde otros dominios. P5 predice ítems de un dominio no visto.

Raffel et al. (2020). T5. JMLR · Brown et al. (2020). GPT-3. NeurIPS · Liu et al. (2021). Pre-train, Prompt, and Predict. arXiv · Wei et al. (2022). FLAN. ICLR · Sanh et al. (2022). T0. ICLR · Li et al. (2021). PETER. ACL · Sun et al. (2019). BERT4Rec. CIKM · Lee et al. (2019). MeLU. KDD · Geng et al. (2022), Sección 2.

Contribución

P5 propone una interfaz común para aprender, transferir y evaluar múltiples capacidades de recomendación.

01 Unificación

Primer marco que integra cinco familias de tareas de recomendación en un solo modelo y una sola pérdida (según los autores).

02 Personalización

Colección de prompts personalizados: plantillas con campos de usuario e ítem para cada familia de tareas.

03 Resultados

Rendimiento competitivo frente a modelos específicos en las cinco familias, con prompts vistos en el entrenamiento.

04 Zero-shot

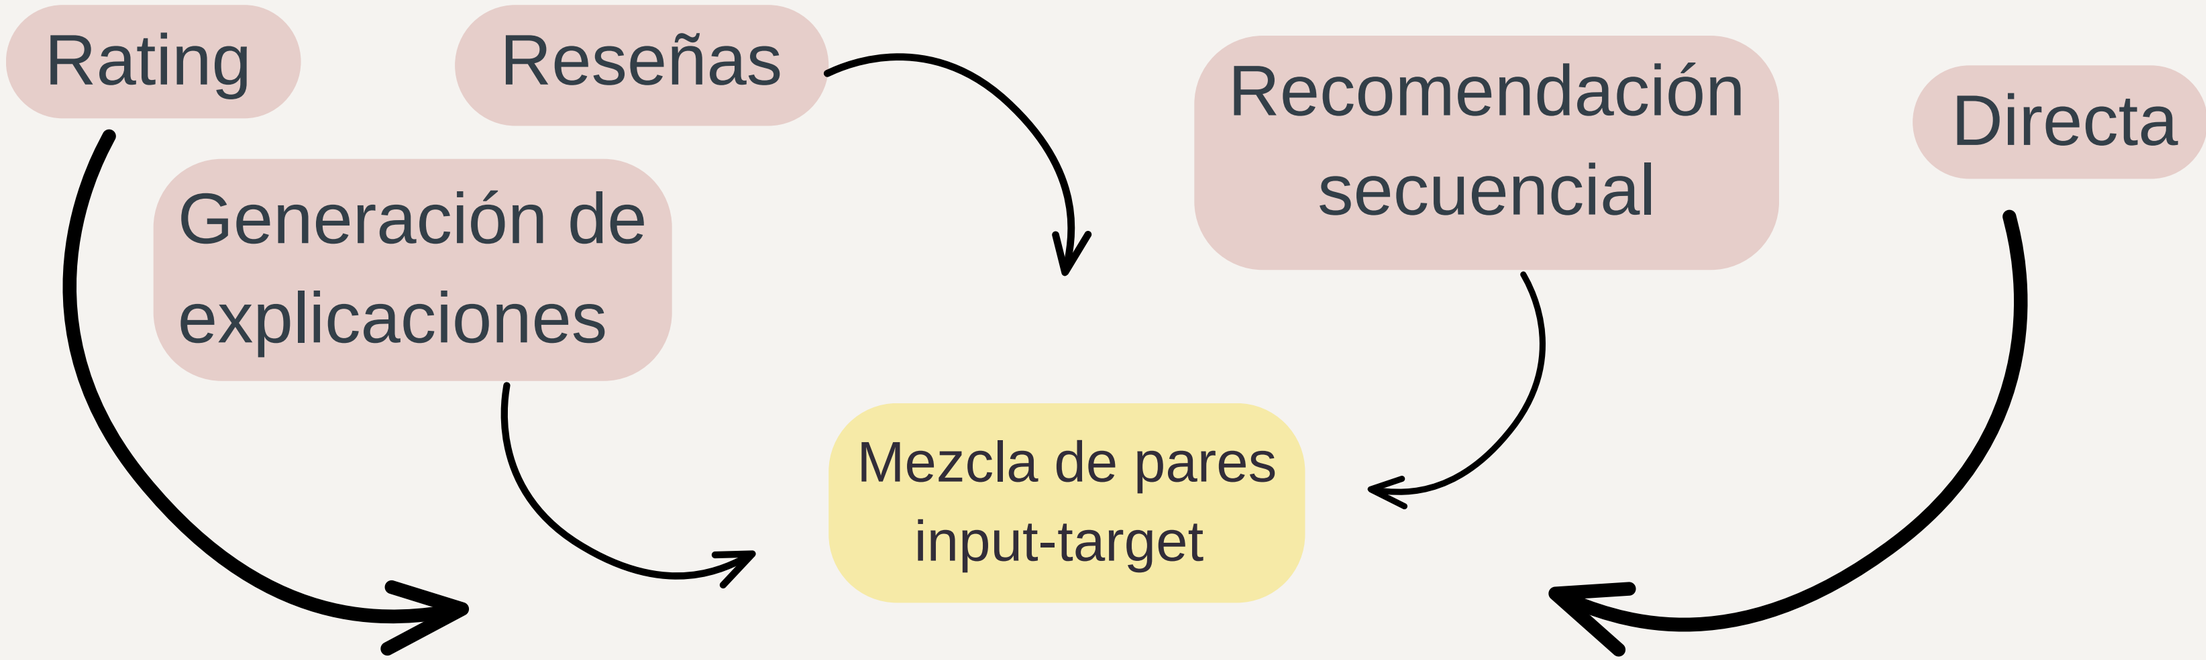
Generaliza a prompts no vistos y a ítems de dominios nuevos.

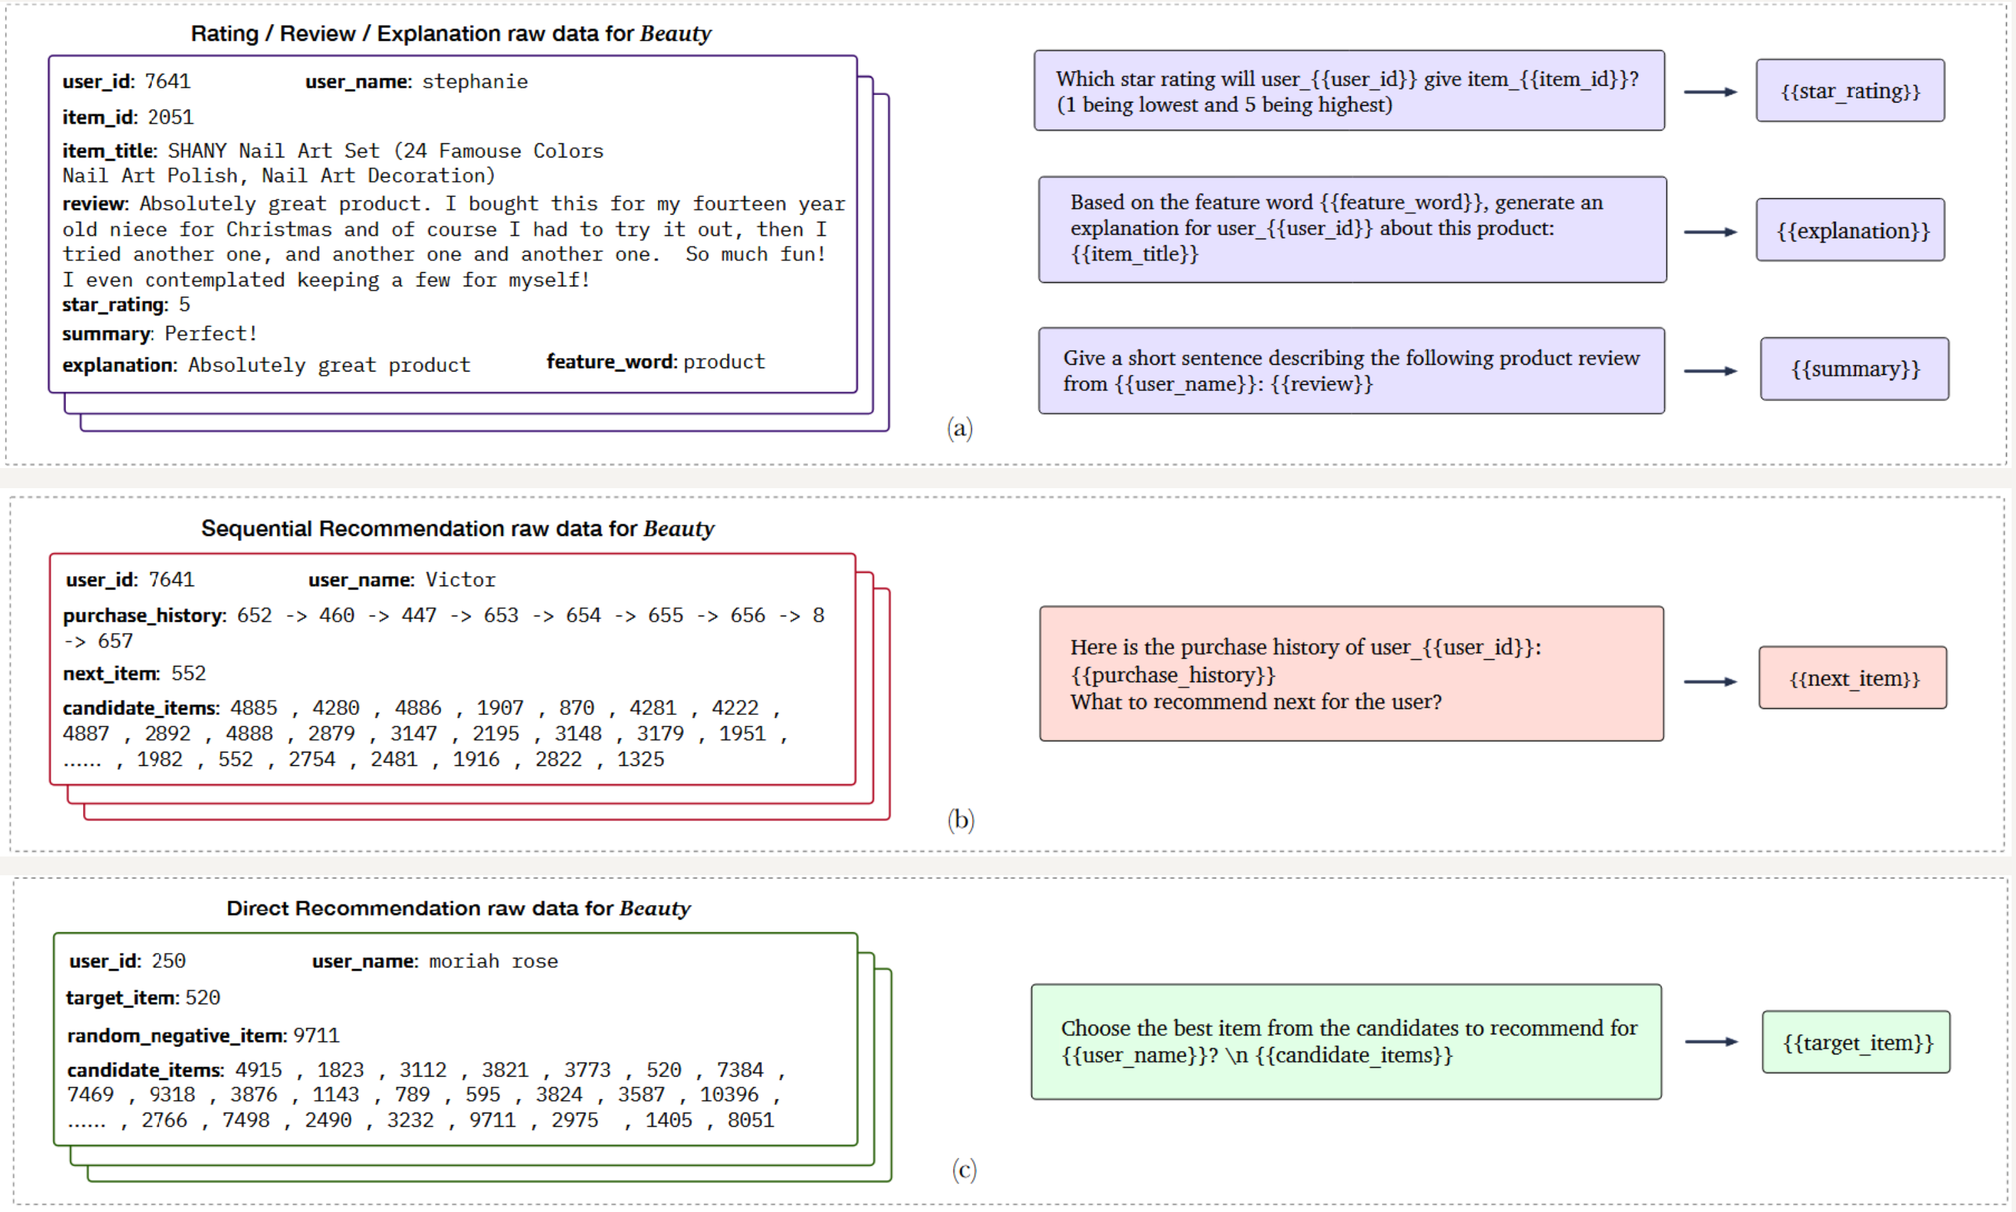
De modelos aislados a un paradigma general de recomendación como lenguaje.

Geng, S., Liu, S., Fu, Z., Ge, Y., & Zhang, Y. (2022). Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5). RecSys '22. Sección 1 (contribuciones).

Input template + Target template + Metadata + Personalización para usuarios e items

Colección de Prompts personalizados

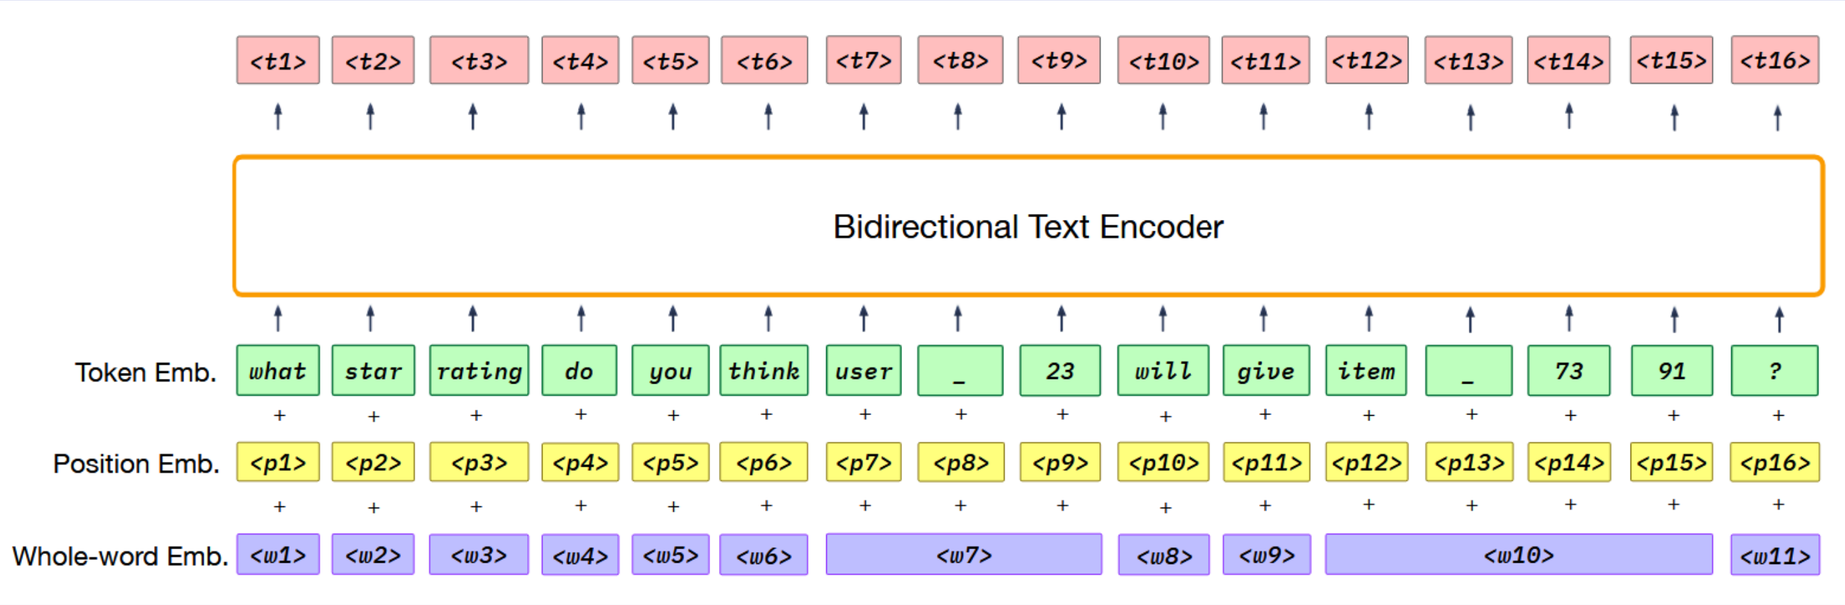


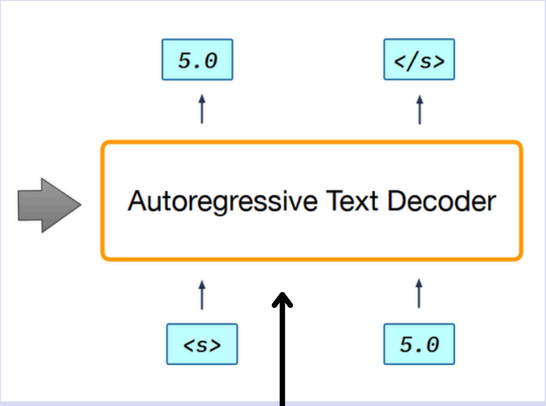


Geng, S., Liu, S., Fu, Z., Ge, Y., & Zhang, Y. (2022). Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5). RecSys '22.

Detalle de solución

Pretraining





$$\mathcal{L}_{\theta}^{\mathrm{P5}} = -\sum_{j=1}^{|\mathbf{y}|} \log P_{\theta}\left(\mathbf{y}_j \mid \mathbf{y}_{<j}, \mathbf{x}\right)$$

Unificación de tareas de recomendación

Geng, S., Liu, S., Fu, Z., Ge, Y., & Zhang, Y. (2022). Recommendation as Language Processing (RLP): A Unified Pretrain, Personalized Prompt & Predict Paradigm (P5). RecSys '22.

Rating

Reseñas

Generación de explicaciones

Greedy search

Recomendación secuencial

Directa

Beam search

$$\mathbf{C} = [C_1, \cdots, C_B] = \text{Beam_Search}(\mathcal{D}, \mathbf{t}, B)$$

Experimentos

RQ1 ¿**Cómo se desempeña** nuestro marco unificado P5 en comparación con los métodos específicos para cada tarea en las cinco familias de tareas?

RQ2 ¿Tiene P5 suficiente capacidad de **generalización zero-shot** al transferirse a prompts personalizados no vistos, ya sea para ítems existentes o nuevos?

RQ3 ¿Cómo afectan al **rendimiento** de P5 los **factores de escala** como el tamaño del modelo, el número de familias de tareas y la cantidad de prompts?

RQ4 ¿Cuál es la mejor manera de implementar la personalización en P5: adoptar un **token adicional** e independiente para cada usuario/ítem **o** utilizar la **configuración por defecto**?

RQ5 ¿Cuánto **tiempo** le toma a P5 realizar el preentrenamiento? ¿Es **eficiente** realizar inferencias con el modelo P5 preentrenado?

Datos y protocolo

4 dominios (Amazon Sports, Beauty, Toys y Yelp) · 1 modelo P5 multitarea por dominio · Prompts vistos y reservados (zero-shot)

Familia de tarea (salida)	Métricas	Partición (split)
1. Rating (puntaje numérico 1–5)	RMSE ↓ MAE ↓	80 / 10 / 10 aleatorio
2. Secuencial (ID del siguiente ítem)	HR@5/10 ↑ NDCG@5/10 ↑	Leave-one-out (último ítem)
3. Explicación (texto justificando compra)	BLEU-4 ↑ ROUGE-1/2/L ↑	80 / 10 / 10 aleatorio
4. Reseñas (resumen y preferencia)	BLEU-2 ↑ · ROUGE ↑ RMSE ↓ · MAE ↓	80 / 10 / 10 aleatorio
5. Directa (Sí/No y top-k candidatos)	HR@1/5/10 ↑ NDCG@5/10 ↑	Train secuencial (sin fuga)

Secuencial: catálogo completo (all-item)
Beam Search (B=20) conserva 20 secuencias de IDs candidatas. Se evalúa sobre todo el catálogo: 12.101 ítems
en Beauty y 18.357 en Sports, sin muestreo negativo.

Directa: 1 positivo + 99 negativos (1 de 100)
Sin historial reciente: elige el positivo entre 100 candidatos
por usuario. Prompts generativos: Beam Search (B=20). Sí/No: ranking por probabilidad de «sí».

Generalización a prompts no vistos
Amazon: 47 prompts = 42 de entrenamiento + 5 reservados;
Yelp: 44 = 39 + 5. Se reserva el último de cada familia.
Backbone T5: P5-small 60,75M y P5-base 223,28M parámetros.

Fuente: Geng et al., RecSys 2022, Secciones 4.1 y 5.1, Tabla 1 y Apéndices D–E.

Recomendación secuencial

Catálogo completo: Beauty (12.101 ítems) · P5 supera los baselines en los 4 dominios (Sports, Beauty, Toys y Yelp)

P5-base = T5-base con 223,28M parámetros; Yelp reporta P5-small (60,75M).

Modelo y prompt	HR@5 ↑	NDCG@5 ↑	HR@10 ↑	NDCG@10 ↑
S3-Rec	0,0387	0,0244	0,0647	0,0327
P5-base, visto (2-3)	0,0508	0,0379	0,0664	**0,0429**
P5-base, reservado (2-13)	0,0493	0,0367	0,0645	0,0416

- **+31,2% relativo en NDCG@10 sobre S3-Rec (0,0429 vs. 0,0327) y +2,6% en HR@10 (0,0664 vs. 0,0647).**
- La ganancia se concentra en las primeras posiciones del top-10: HR@5 sube +31,3% (de 0,0387 a 0,0508).
- Con el prompt reservado zero-shot (2-13), mantiene 0,0416 en NDCG@10 (+27,2% vs. S3-Rec), sin ver esa plantilla al entrenar.

Fuente: Geng et al., RecSys 2022, Sección 5.3.2, Tabla 3 (Amazon) y Apéndice A, Tabla 11 (Yelp). Baselines: Caser, HGN, GRU4Rec, BERT4Rec, FDSA, SASRec, S3-Rec.

Resultados mixtos según tarea y métrica

P5 iguala o mejora baselines en varias tareas, pero existen compromisos claros según la métrica, la tarea y el tamaño del dataset

1. Predicción de ratings (Amazon Beauty, escala 1–5)

Modelo	MAE ↓	RMSE ↓
MF (Matrix Factorization)	0,9461	**1,1973**
MLP	0,9597	1,3078
P5-small, visto (1-6)	**0,8428**	1,3128
P5-base, visto (1-6)	0,8534	1,2843

¿Por qué mejora MAE pero empeora RMSE?

• En Beauty (P5-base 1-6 vs. MF), MAE baja 9,8% (0,8534 vs. 0,9461), pero RMSE sube 7,3% (1,2843 vs. 1,1973).

• P5 genera el puntaje como texto. Un MAE menor indica menor error absoluto medio; un RMSE mayor penaliza más las desviaciones grandes. Es compatible con errores extremos, sin demostrar su causa.

5. Recomendación directa (1 de 100) vs. SimpleX (Tablas 7 y 14)

• Beauty: P5-small (5-4) supera HR@1 de SimpleX (0,0862 vs. 0,0325) y NDCG@10 (0,1993 vs. 0,1711).

• SimpleX gana en top-10 en Toys (NDCG@10: 0,1469 vs. 0,1248, mejor P5) y Yelp (0,3020 vs. 0,1780).

3 y 4. Explicaciones y reseñas vs. PETER+, GPT-2 y T0

• Beauty: sin pista (3-3), P5-small gana a los baselines. Con pista (3-9), PETER+ gana BLEU-4 (3,26 vs. 1,98); P5-small gana ROUGE.

• Resúmenes Amazon: P5 supera a GPT-2 (1,5B) y T0 (11B). En preferencia desde reseñas, T0 gana en Yelp.

RQ3: escala del modelo vs. tamaño del dominio (§5.5)

• Toys: P5-small (60,75M) supera a P5-base (223,28M) en NDCG@10 secuencial (2-3): 0,0587 vs. 0,0534.

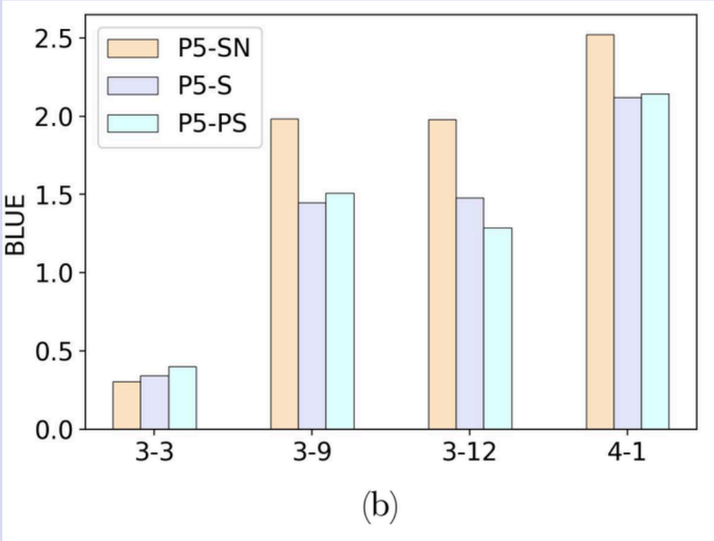
• Sports, con más datos: P5-base gana (2-13: 0,0336 vs. 0,0188). Los autores vinculan la capacidad necesaria al tamaño del dominio.

Fuente: Geng et al., RecSys 2022, Secciones 5.3 y 5.5, Tablas 2, 3, 4, 5, 6, 7, 12, 13 y 14.

Efecto del entrenamiento multitarea: texto vs. ranking

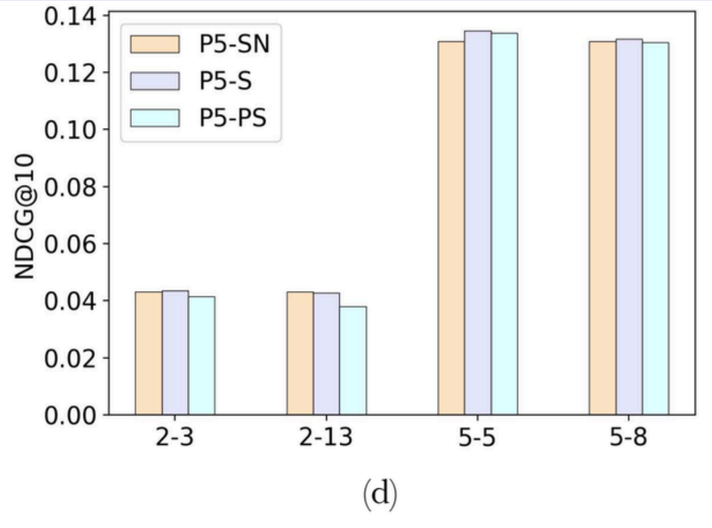
Beauty: P5-S cede BLEU en texto, mantiene o mejora el ranking y generaliza a prompts nuevos con preentrenamiento multitarea

Fig. 5(b): texto · BLEU-4 (3-*) / BLEU-2 (4-1) ↑



3-3: explicación sin pista · 3-9 y 3-12*: con pista
4-1: resumen
* = prompt reservado zero-shot

Fig. 5(d): ranking de ítems · NDCG@10 ↑



2-3 y 2-13*: secuencial (all-item)
5-5 y 5-8*: directa (1 de 100)
* = prompt reservado zero-shot

- Multitarea (§5.6): P5-SN gana BLEU en 3-9, 3-12 y 4-1. P5-S mantiene o mejora el ranking (2-3, 2-13 y 5-5) con un checkpoint.
- Prompts (§5.7): con solo 18 plantillas (P5-PS) cae la generalización, especialmente en 2-13* y 3-12*.

P5-SN (barra naranja): 1 sola familia

Entrenado por separado en una única familia de tareas. Cubrir las cinco requiere 5 modelos distintos; gana BLEU con pista (3-9, 3-12) y resumen (4-1).

P5-S (barra lavanda): multitarea completo

Un modelo P5-small (60,75M) con las 5 familias y todos los prompts de entrenamiento. Mejora el ranking visto (2-3, 5-5) y es similar en 2-13*.

P5-PS (barra celeste): prompts reducidos

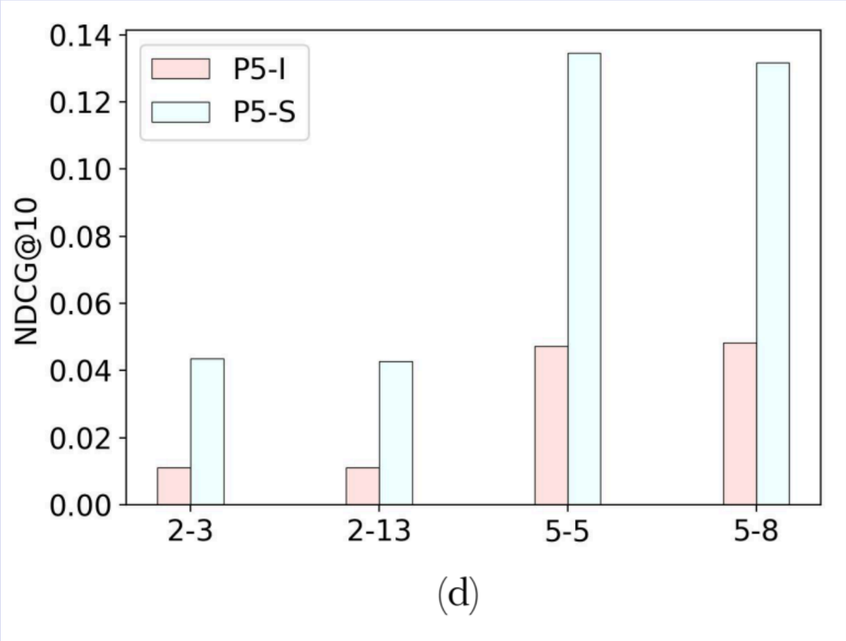
Solo 18 prompts que cubren los campos importantes. Menos variedad de plantillas reduce la generalización a prompts nuevos (*).

Fuente: Geng et al., RecSys 2022, Secciones 5.6 y 5.7, Figura 5(b) y Figura 5(d), Amazon Beauty.

Representación de IDs y ranking

Beauty: P5-S supera a los tokens nuevos en NDCG@10, cerca de 4× en secuencial y 3× en directa, con subpalabras de T5

Fig. 6(d): tokenización de IDs · NDCG@10 ↑ (Beauty)



Eje X: 2-3 (visto) y 2-13* (zero-shot): secuencial, catálogo completo.
5-5 (visto) y 5-8* (zero-shot): directa, 1 positivo + 99 negativos.

P5-I: un token atómico nuevo por usuario e ítem

- "item_7391" se agrega como un token único <item_7391>. Beauty suma 34.464 tokens de usuarios e ítems.
- Con pocas interacciones, sus vectores son difíciles de entrenar: es la interpretación de los autores.

P5-S: SentencePiece + whole-word embedding

- Ejemplo del paper: "item_7391" → ["item", "_", "73", "91"]. Reutiliza el vocabulario de T5 sin un token nuevo por entidad.
- Un whole-word embedding común indica qué subpalabras pertenecen al mismo identificador.

Efecto selectivo en ranking (§5.8, Figuras 6a–6d)

- Rating y resumen: similares; P5-I mejora algo las explicaciones (6a/6b).
- P5-S vs. P5-I en NDCG@10: ≈0,043 vs. ≈0,011 en secuencial; ≈0,13 vs. ≈0,047 en directa. La ablación no aísla el efecto de whole-word embedding.

Fuente: Geng et al., RecSys 2022, Secciones 4.1 y 5.8, Figura 6(a)–6(d), Amazon Beauty.

Transferencia de dominio y eficiencia

Transferencia zero-shot en Amazon (§5.4.2) y tiempos medidos de preentrenamiento e inferencia en GPU (Apéndice B)

1. Toys → Beauty sin ajuste (P5-base, Tabla 9)

Pool de 741 usuarios compartidos. Subconjunto destino Beauty: 439 usuarios y 586 ítems. P5-base se entrena en Toys; describe el ítem nuevo con atributos como título, marca y precio.

Prompt	Tarea en Beauty	Métrica	Resultado
Z-1 / Z-4	Preferencia binaria (con atributos)	Accuracy ↑	**0,7922**
Z-2 / Z-3	Rating 1–5 (con atributos)	MAE ↓	0,8244
Z-6	Explicación CON pista y rating dado	ROUGE-1 ↑ BLEU-2 ↑	**13,8487** **0,8623**
Z-5 / Z-7	Explicación SIN palabra pista	ROUGE-1 ↑ BLEU-2 ↑	3,5441 0,1940

Alcance real de la transferencia entre dominios

- 79,2% en preferencia y MAE 0,8244 en rating, con usuarios conocidos y atributos del ítem nuevo.
- Z-6 recibe pista y rating: ROUGE-1=13,85; Z-5/Z-7, sin pista, 3,54. No se evalúa ranking de IDs nuevos.

2. Costo y latencia en Beauty (Tabla 15)

P5 en Beauty: 10 épocas, 4× RTX A5000; T5 ya preentrenado.
Small (60,75M): 6,7 h; base (223,28M): 24,3 h.
Batch reportado (§5.1): 32 (small) y 16 (base).

Tarea / unidad	Decodificación	Small (ms)	Base (ms)
Rating (1-10) por par usuario–ítem	Greedy	**4,93**	13,40
Reseña (4-1 / 4-4) por reseña	Greedy	6,25–8,66	14,85–23,51
Explicación (3-12) por par usuario–ítem	Greedy	13,41	34,71
Secuencial (2-13) por usuario; all-item	Beam Search B=20	53,96	78,19
Directa (5-8) por usuario; 1 de 100	Beam Search B=20	57,40	**98,80**

Generar el top-k con Beam Search (B=20)

- Ranking: 53,96–98,80 ms/usuario en 1 GPU. La recomendación directa procesa 100 candidatos.
- Falta una comparación en el mismo hardware con ANN/producto punto y una medición que aísle el efecto del ancho del beam.

Fuente: Geng et al., RecSys 2022, Sección 5.4.2 (Tablas 8–9 y Figura 4) y Apéndice B (Tabla 15, Amazon Beauty).

Conclusión de la evaluación

Aporte validado

• Un único modelo multitarea por dominio resuelve 5 familias y generaliza
zero-shot a prompts no vistos.

• Ventaja secuencial sobre catálogo completo: +31,2% en NDCG@10 en Beauty frente a S3-Rec. También mejora HR@1 directo en Beauty.

• La representación estándar de IDs,
con subpalabras y whole-word embedding, supera a los tokens nuevos
en ranking.

Límites observados

• Resultados mixtos: RMSE en ratings
sube 7,3% en Beauty; PETER+ gana BLEU-4 con pista y SimpleX gana top-10 directo en Toys y Yelp.

• La escala depende del dominio: P5-small supera a P5-base en Toys.
Más parámetros no garantizan ganar.

• Beauty en GPU: ranking con Beam Search (B=20), 53,96–98,80 ms/usuario. Ratings con greedy: 4,93–13,40 ms/par usuario–ítem.

Balance metodológico

• P5 demuestra la viabilidad de RLP:
unifica tareas con lenguaje y plantea
una ruta hacia modelos fundacionales
generativos en RecSys.

• La transferencia entre dominios usa
atributos textuales y usuarios compartidos. No evalúa ranking frío de
IDs nuevos; sin pista, generar explicaciones resulta difícil.

Fuente: Geng et al., RecSys 2022, Secciones 5.3–5.8 y Apéndice B, Tabla 15. Síntesis del alcance de la evidencia reportada.

Gracias

Anexo

Yelp y muestreo de interacciones

Resultados fuera de Amazon (Apéndice A) y repetición del muestreo de candidatos para recomendación directa (Apéndice C)

Yelp: 30.431 usuarios · 20.033 ítems

Secuencial · catálogo completo (Tabla 11) · ↑

Modelo / prompt	HR@5	NDCG@5	HR@10	NDCG@10
S3-Rec	0,0201	0,0123	0,0341	0,0168
P5-small (2-3)	0,0568	0,0402	0,0707	**0,0447**
P5-small (2-13*)	0,0574	0,0403	0,0703	**0,0445**

Directa · 1 positivo + 99 negativos (Tabla 14) · ↑

Modelo / prompt	HR@1	HR@5	NDCG@5	HR@10	NDCG@10
SimpleX	0,0569	**0,3970**	**0,2538**	**0,5473**	**0,3020**
P5-small (5-5)	**0,0696**	0,2134	0,1423	0,3178	0,1758
P5-small (5-8*)	**0,0705**	0,2136	0,1432	0,3219	0,1780

P5-small gana NDCG@10 secuencial.
En directa, mejora HR@1 frente a SimpleX y cede top-10.
BPR-MF logra el mayor HR@1 (0,0813; Tabla 14).

Beauty: N=10 vs. 200 ejemplos por interacción

Apéndice C: recomendación directa generativa
Por interacción se muestrean 99 negativos y se agrega el positivo. Se elige al azar un prompt de 5-5 a 5-8. Repetir N veces crea N ejemplos: 10 por defecto, o 200 en Tabla 16.

P5-small Prompt	N=10 (Tabla 7) HR@10 / NDCG@10 ↑	N=200 (Tabla 16) HR@10 / NDCG@10 ↑
5-5 (visto)	0,2370 / 0,1360	**0,3289 / 0,1906**
5-8* (zero-shot)	0,2317 / 0,1318	**0,3665 / 0,2184**

Más ejemplos cambian el resultado en Beauty
- En Beauty, P5-small 5-8* sube NDCG@10 de 0,1318 a 0,2184 (+65,7%) y supera a SimpleX (0,1711).
- Más muestras de candidatos, con las mismas plantillas y sin interacciones reales nuevas. La Tabla 16 evalúa solo directa.

Fuente: Geng et al., RecSys 2022, Tabla 1; Apéndice A, Tablas 11 y 14; Apéndice C, Tabla 16; Tabla 7 (N=10). * = prompt reservado.

Explicaciones vs. PETER y PETER+

Sin palabra pista (3-3) y con pista (3-9 visto; 3-12* zero-shot) en Amazon Beauty · Tabla 4, métricas en %

Condición	Modelo / prompt	BLEU-4 ↑	ROUGE-1 ↑	ROUGE-2 ↑	ROUGE-L ↑
Sin pista	Attn2Seq	0,7889	12,6590	1,6820	9,7481
Sin pista	NRT	0,8295	12,7815	1,8543	9,9477
Sin pista	PETER	1,1541	14,8497	2,1413	11,4143
Sin pista	P5-small (3-3)	**1,2237**	**17,6938**	**2,2489**	**12,8606**
Sin pista	P5-base (3-3)	0,9742	16,4530	1,8858	11,8765
Con pista	PETER+	**3,2606**	25,5541	5,9668	19,7168
Con pista	P5-small (3-9)	1,9788	**25,6253**	**6,3678**	**19,9497**
Con pista	P5-base (3-9)	1,8765	25,1183	6,0764	19,4488
Con pista	P5-small (3-12*)	1,9425	25,1474	6,0551	19,5601
Con pista	P5-base (3-12*)	1,9031	25,1763	6,1980	19,5188

- En Beauty, P5-small (3-3) supera a los tres baselines en las cuatro métricas. P5-base no domina: pierde BLEU-4 y ROUGE-2 ante PETER.
- Con pista (3-9), PETER+ gana BLEU-4 (3,2606 vs. 1,9788 de P5-small); P5-small mejora los tres ROUGE, por márgenes pequeños. ROUGE mide coincidencia textual, no fidelidad de la explicación.

Fuente: Geng et al., RecSys 2022, Sección 5.3.3, Tabla 4 (Amazon Beauty). * = prompt reservado zero-shot.