IIC3633

Causal Inference for Recommender Systems

Wang, Liang, Charlin y Blei · RecSys 2020



Grupo 9
Antonia Parra · Sebastián Barría

Contexto

Recomendar es intervenir, pero aprendemos de datos que no son un experimento

Objetivo Tradicional

Meta Clásica: Predecir qué películas le gustarán al usuario usando su historial de calificaciones.

Sesgo de Datos: Los usuarios no ven películas al azar, solo califican aquello que ven.

Limitación: Asume implícitamente que los datos provienen de un experimento aleatorio ideal.

Confusores No Observados

Variables Ocultas: Factores que influyen en qué decide ver el usuario y cómo lo califica.
Ejemplo: modas, estado de ánimo, país, entre otras.

Problema Causal: No es posible medir todos los factores de confusión, lo que sesga fuertemente las preferencias inferidas.

Recomendación como Intervención

¿Cuál sería la calificación si forzáramos al usuario a ver la película?

Eficiencia y Valor: Lo valioso es sugerir ítems que verá y disfrutará únicamente si se le muestran.

La solución: El recomendador desconfundido busca responder esta pregunta corrigiendo el sesgo sin requerir experimentos aleatorios.

Problema de Recomendación

- **a_ui** ∈ {0,1}: exposición; si el usuario u vio el ítem i.
- **y_ui**: calificación observada (solo existe cuando a_ui = 1).
- **y_ui(1)**: calificación si se le muestra el ítem.
- **y_ui(0)**: calificación si no se le miestra.

Objetivo de recomendación
Predecir la calificación contrafactual **ŷ_ui(1)** para los ítems no vistos (a_ui = 0).

Eq. 1 · Factorización Matricial como resultados potenciales

$$y_{ui}(a) = \theta_u^T \beta_i \cdot a + \epsilon_{ui}$$

$$\epsilon_{ui} \sim N(0, \sigma^2)$$

- θ_u: preferencias latentes del usuario.
- β_i: atributos latentes del ítem.
- ϵ_ui: error o ruido aleatorio.

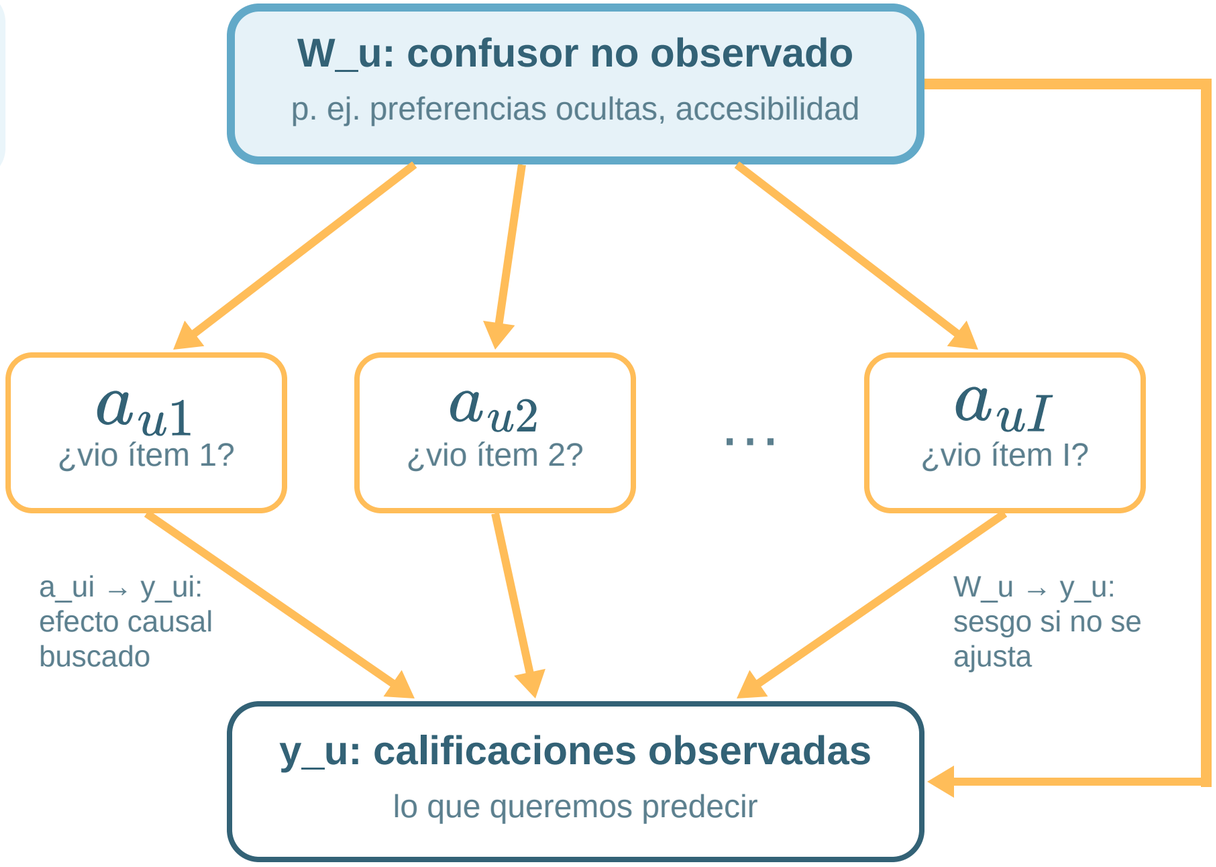
Con a = 1 es la MF probabilística de Mnih y Salakhutdinov [11].
Notación de Rubin [4], [5].

El Sesgo de Confusión: La Falla de la Ignorabilidad en MF

Ignorabilidad: $\{y_u(0), y_u(1)\} \perp a_u$

La decisión de qué películas ver es independiente de cómo las calificaría

- **Violación en la práctica**: la forma en que un usuario descubre y elige contenido depende directamente de sus gustos y de la exposición previa [1].
- **Solución clásica**: medir todos los confusores W_u y condicionar en ellos:
  $$\{y_u(0), y_u(1)\} \perp a_u \mid W_u$$
- **El obstáculo**: requiere ignorabilidad fuerte (haber medido todos los confusores), algo que en la realidad es inalcanzable e inverificable estadísticamente [6].



Estado del Arte y Marco Teórico

De corregir sesgos estadísticos a la inferencia causal sin covariables

1. Modelos MNAR

- Los datos no faltan al azar (Missing Not at Random).
- Modelan explícitamente el proceso de ausencia/exposición para mejorar predicciones.

Se queda en un enfoque predictivo y observacional; no formula la recomendación formalmente como una intervención causal.

Marlin & Zemel 2009 [7]

2. Enfoque Bandidos

- Aprendizaje en línea y exploración-explotación.
- Usa muestreo por importancia para evaluar políticas con datos sesgados.

Buscamos resolver un problema ortogonal: razonamiento offline con modelos paramétricos sobre preferencias de usuario, no selección online de algoritmos.

Li et al. (2010) [13],
Vanchinathan et al. (2014) [14]

3. Ponderación IPW

- Trata la exposición como un tratamiento causal. Pondera cada error por el inverso de la propensión: 1/P(exposición).

Requiere datos de un experimento aleatorios (costoso/inviable) o medir covariables externas explícitas del usuario e ítem para calcular la propensión.

Schnabel et al. (2016) [8]

4. El Desconfundidor

- Al haber múltiples causas (miles de ítems), las correlaciones entre decisiones revelan evidencia indirecta de los confusores ocultos.

Propuesta: Adaptar el desconfundidor a recomendación: no requiere de datos aleatorios ni covariables externas; basta con la matriz observada.

Wang y Blei 2019 [2]

Contribución

Inferencia causal en recomendación sin requerir experimentos ni covariables externas

	MF Clásica	ExpoMF [9] / MNAR [7]	IPW-MF [8]	Recomendador Desconfundido
¿Enfoque causal o predictivo?	Puramente predictivo (asume datos al azar)	Predictivo (modelo qué ítems no se observaron)	Causal (trata la exposición como intervención)	Causal formal (responde la pregunta contrafactual)
¿Corrige confusores no observados?	No	No	Solo si se observaron covariables suficientes	Sí, confusores que afecten a múltiples ítems.
¿Qué datos adicionales exige?	Ninguno	Ninguno	Ensayos aleatorizados	Ninguno
Compatibilidad con modelos base	Modelo base único	Arquitectura propia rígida	Modifica la función de pérdida con pesos	Marco flexible y modular

Solución

El deconfounded recommender

La idea (Wang y Blei [2]): un confusor que afecta a muchas exposiciones las vuelve correlacionadas.
Si un modelo aprende qué ítems tienden a verse juntos, termina capturando esa causa oculta [1]. Ese sustituto se agrega como dato extra al modelo que predice notas, para que no confunda “lo vio porque lo tenía a mano” con “le gusta mucho”.

1. **Ajustar Poisson factorization a las exposiciones a_ui (siguiente slide)**
2. **Calcular el sustituto â_ui = E[π_u · λ_i | a]**
3. **Ajustar la MF con y_u · â_ui como covariable**
4. **Predecir ŷ_ui(1) y recomendar el top-K**



DETALLE DE LA SOLUCIÓN · PASO 1 · ANALIZAR EXPOSICIÓN

Un modelo de qué ve cada usuario: Poisson factorization

$$a_{ui} \mid \pi_u, \lambda_i \sim \text{Poisson}(\pi_u \cdot \lambda_i) \qquad \pi_u \sim \text{Gamma}(c_1, c_2) \qquad \lambda_i \sim \text{Gamma}(c_3, c_4)$$

- a_ui: Exposición. a_ui: 1 si el usuario calificó el ítem, 0 si no
- π_u: preferencias de descubrimiento del usuario. Qué le suele llegar a ese usuario
- λ_i: atributos que hacen visible al ítem [1]. A qué tipo de usuarios les llega
- Se encuentran los valores que mejor explican la matriz de quién calificó qué [10]. (Ascenso por coordenadas)

Esto solo nos permite concluir cúales ítems llegan más fácil a ese usuario (tienen más exposición)

DETALLE DE LA SOLUCIÓN · PASOS 2 Y 3

El sustituto entra como una variable más

$$\hat{a}_{ui} = E[\, \pi_u \cdot \lambda_i \mid a \,]$$

$$y_{ui}(a) = \theta_u \cdot \beta_i \cdot a + \gamma_u \cdot \hat{a}_{ui} + \varepsilon_{ui}$$

Se toma el valor obtenido en el paso anterior y se agrega a la fórmula de la nota, para descontar el efecto de “lo tenía a mano”.

- â_ui: Lo que el modelo estimó en el paso anterior dado lo que se sabe (a), qué tan esperable era que u viera i
- y_ui: Nota que el usuario u le pondría al ítem i si lo viera
- γ_u: cuánto pesa el confusor en los ratings de cada usuario [1] cuánto influye que al usuario se le muestre mucho o poco. Lo aprende mediante MF
- a: interruptor, 1 si lo calificó (lo vio) y 0 si no
- θ_u (vector de gustos del usuario u) y β_i (vector de características del ítem i) solo para ítems que vio, también se aprenden mediante MF
- ε_ui: Ruido



DETALLE DE LA PARTE 3 DE LA SOLUCIÓN

Funciona con cualquier MF

La corrección **no** depende de la MF: se suma igual a cualquiera. Los autores la probaron con tres factorizaciones distintas: la clásica, la de Poisson y la ponderada para datos implícitos

$$y_{ui}(a) \sim p(\cdot \mid m(\theta_u \cdot \beta_i, a) + y_u \cdot \hat{a}_{ui},\ v(\theta_u \cdot \beta_i, a))$$

m: media y v: varianza propia de cada MF

Probabilistic MF

La MF clásica, notas en forma de campana [11].

Poisson MF

Trata las notas como conteos, con valores siempre positivos [10].

Weighted MF

Para clics y vistas; más peso a lo que más se usó [12].

Ejemplo del paper

Una fan de westerns vio dos dramas coreanos, poco accesibles en su zona, y le gustaron. **La MF clásica centra todo en westerns.** Como â es bajo para los dramas coreanos y aun así le gustaron, **el deconfounder sube ese gusto** y recomienda más dramas coreanos [1].

EVALUACIÓN · SIMULACIÓN

Simulación

¿Para qué? Con datos reales no sabemos cuánta confusión hay. Por eso inventaron datos (1.000 usuarios y 1.000 ítems) para comprobar si el método de verdad la corrige [1].

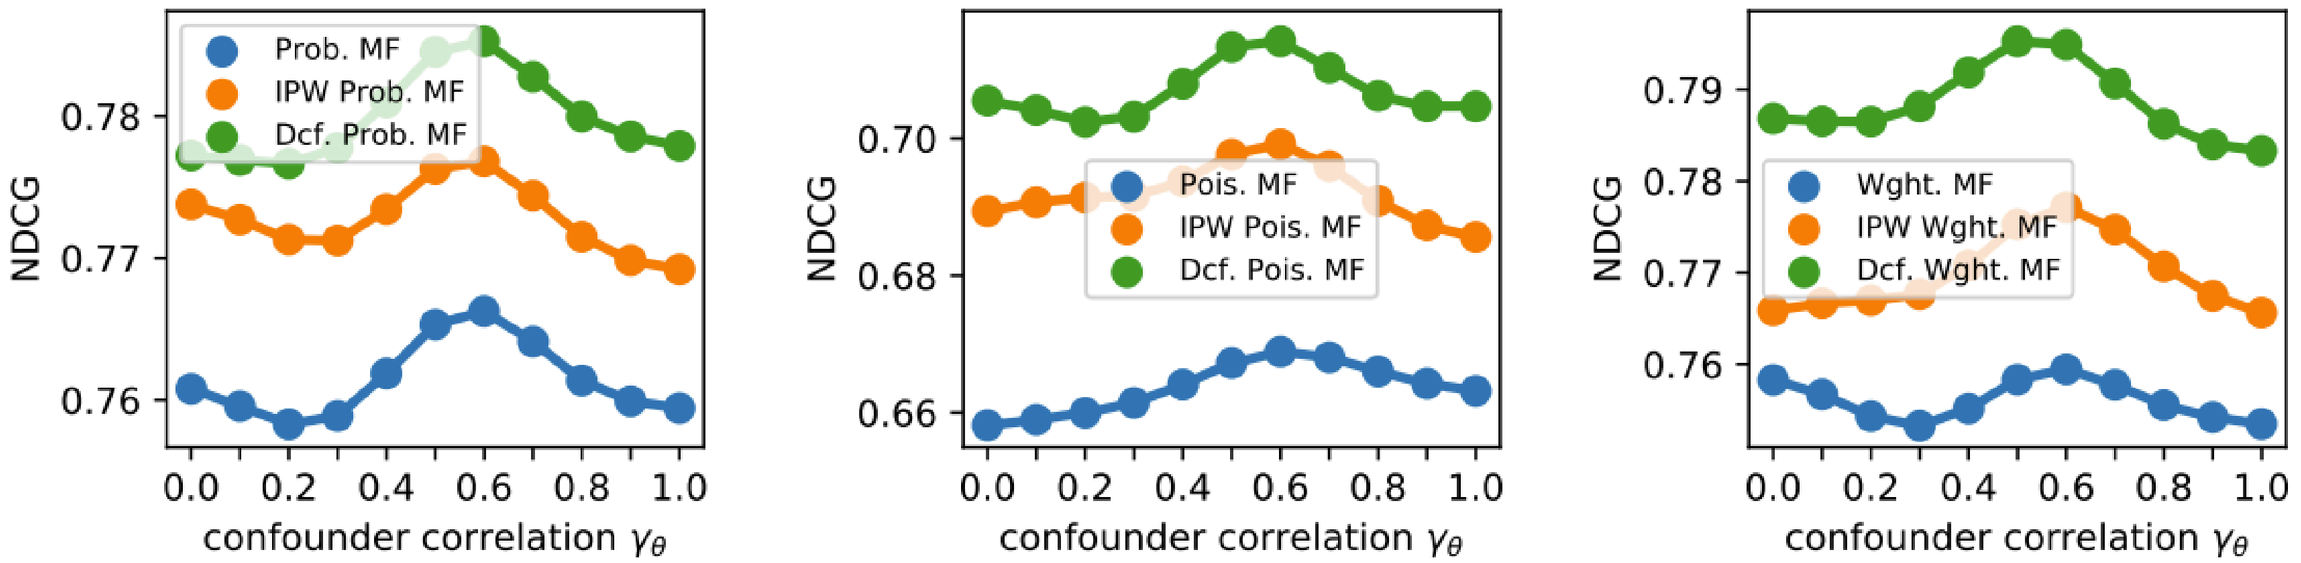


Figura 1 de [1]. Azul = MF normal · Naranja = IPW · Verde = deconfounder · Eje Y: NDCG (más alto = mejor).

¿Qué es la confusión? Una causa oculta que influye a la vez en qué ítems ve el usuario y en cómo los califica; así se mezcla “le gusta” con “lo vio”. En el eje X (γθ) va de 0 (poca confusión) a 1 (mucha). (Como que las vea solo porque el recomendador recomienda mucho de ese tipo)

EVALUACIÓN · DATOS REALES (YAHOO! R3 Y COAT)

Gana casi siempre, pero por poco

Comparan solo contra la misma MF sin corregir e IPW-MF [8] (lo mismo que la anterior multiplicando lo pesos al entrenar la MF por 1/a)

	Usuarios existentes (generalización débil)				Usuarios nuevos (generalización fuerte)			
	Yahoo! R3		Coat		Yahoo! R3		Coat	
	NDCG	Recall@5	NDCG	Recall@5	NDCG	Recall@5	NDCG	Recall@5
Prob. MF [11]	0,811	0,671	0,719	0,451	0,811	0,831	0,779	0,650
IPW Prob. MF [8]	0,813	0,676	0,714	0,480	0,814	**0,834**	0,781	0,548
Dcf. Prob. MF [1]	**0,815**	**0,680**	**0,721**	**0,487**	**0,816**	0,793	**0,805**	**0,760**
Pois. MF [10]	0,773	0,510	0,680	0,358	0,767	**0,771**	0,725	0,608
IPW Pois. MF [8]	0,783	0,550	0,692	0,362	0,772	0,735	0,717	0,601
Dcf. Pois. MF [1]	**0,788**	**0,565**	**0,696**	**0,387**	**0,782**	0,741	**0,739**	**0,618**
Wght. MF [12]	0,821	0,641	0,718	0,554	0,802	0,776	**0,799**	**0,617**
IPW Wght. MF [8]	0,822	0,644	0,717	0,449	0,800	0,772	0,770	0,600
Dcf. Wght. MF [1]	**0,823**	**0,648**	**0,720**	**0,566**	**0,810**	**0,782**	0,766	0,594

Tabla 1 de [1]: NDCG y Recall@5 en test aleatorio. Dcf. = deconfounder

El deconfounder es una mejora consistente pero modesta: casi siempre mejora la misma MF, pero las ganancias son chicas y fallan con usuarios nuevos

Mejor que la MF base en 20 de 24 casos y que IPW en 21 de 24. Mejoras pequeñas; las 4 derrotas son con usuarios nuevos.

CONCLUSIÓN

Influyente, pero no por sí solo

Método

- No detecta causas ocultas que afectan a un solo ítem [2].
- Su teoría todavía se discute [3].

Resultados

- Mejoras chicas, sin pruebas de significancia [1].
- Pierde 4 veces, todas con usuarios nuevos (el paper no explica por qué)

Legado

- Influyó en la recomendación causal [17].
- Lo siguen DecRS, PDA y Deep-Deconf [15], [16], [18].

La lección: pensar en qué pasaría si le mostramos el ítem, no solo en lo que vio.

Referencias

[1] Wang, Liang, Charlin y Blei. Causal Inference for Recommender Systems. RecSys 2020.
[2] Wang y Blei. The Blessings of Multiple Causes. JASA 114(528), 2019.
[3] D'Amour. On Multi-Cause Approaches to Causal Inference with Unobserved Confounding. AISTATS 2019.
[4] Rubin. Estimating causal effects of treatments in randomized and nonrandomized studies. J. Educ. Psychol., 1974.
[5] Imbens y Rubin. Causal Inference for Statistics, Social, and Biomedical Sciences. Cambridge UP, 2015.
[6] Holland, Glymour y Granger. Statistics and causal inference. ETS Research Report, 1985.
[7] Marlin y Zemel. Collaborative prediction and ranking with non-random missing data. RecSys 2009.
[8] Schnabel et al. Recommendations as Treatments: Debiasing Learning and Evaluation. ICML 2016.
[9] Liang, Charlin, McInerney y Blei. Modeling User Exposure in Recommendation. WWW 2016.
[10] Gopalan, Hofman y Blei. Scalable Recommendation with Hierarchical Poisson Factorization. UAI 2015.
[11] Mnih y Salakhutdinov. Probabilistic Matrix Factorization. NIPS 2008.
[12] Hu, Koren y Volinsky. Collaborative Filtering for Implicit Feedback Datasets. ICDM 2008.
[13] Li, Chu, Langford y Schapire. A Contextual-Bandit Approach to Personalized News Article Recommendation. WWW 2010.
[14] Vanchinathan, Nikolic, De Bona y Krause. Explore-exploit in Top-N Recommender Systems via Gaussian Processes. RecSys 2014.
[15] Wang, Feng, He y Chua. Deconfounded Recommendation for Alleviating Bias Amplification. KDD 2021.
[16] Zhu et al. Deep Causal Reasoning for Recommendations. arXiv:2201.02088.
[17] Gao et al. Causal Inference in Recommender Systems: A Survey and Future Directions. ACM TOIS, 2024.
[18] Zhang et al. Causal Intervention for Leveraging Popularity Bias in Recommendation. SIGIR 2021.

IIC3633

Muchas **gracias**

¿Preguntas?

