SEMINARIO IIC3633 · SISTEMAS RECOMENDADORES

Deep Neural Networks for YouTube Recommendations

Covington, Adams y Sargin · Google · RecSys 2016

Victor Bórquez · Vicente Espinoza — Grupo 4 · 27 de octubre de 2026

CONTEXTO

Tres razones hacen difícil recomendar en YouTube

Escala

Más de mil millones de usuarios y millones de videos.

Freshness

Se suben muchas horas de video por segundo, y los usuarios prefieren lo nuevo

Ruido

Casi solo hay feedback implícito (que vio y cuanto vio). Dificil saber si el usuario quedó satisfecho.

PROBLEMA DE RECOMENDACIÓN

Dos preguntas: ¿qué verá ahora y cuánto lo verá?

ETAPA 1 · CANDIDATOS · ¿CUÁL VA A VER EL USUARIO A CONTINUACIÓN?

Clasificación extrema

$$P(w_t=i \mid U,C) = \text{softmax}(v_i \cdot u)$$
$$= \exp(v_i \cdot u) / \Sigma_j \exp(v_j \cdot u)$$

Cada video es una clase (millones). u = embedding de usuario + contexto; v_j = embedding de cada video.

ETAPA 2 · RANKING · ¿CUÁNTOS MINUTOS VERÁ DE CADA UNO SI SE LO MUESTRO?

Watch time esperado

$$\text{score(impresión)} \approx E[T]$$

Por cada **impresión** (cada vez que se muestra un video, con o sin clic) se predicen los minutos vistos. No se ordena por CTR (tasa de clics): premia el clickbait.

De co-visitación a redes profundas

2010

Co-visitación

"Quienes vieron este video también vieron este otro" (Davidson et al.).

→

Sistema anterior

Matrix factorization

MF con rank loss (WSABIE): embeddings de usuario y video, score por producto punto.

→

2016 · este paper

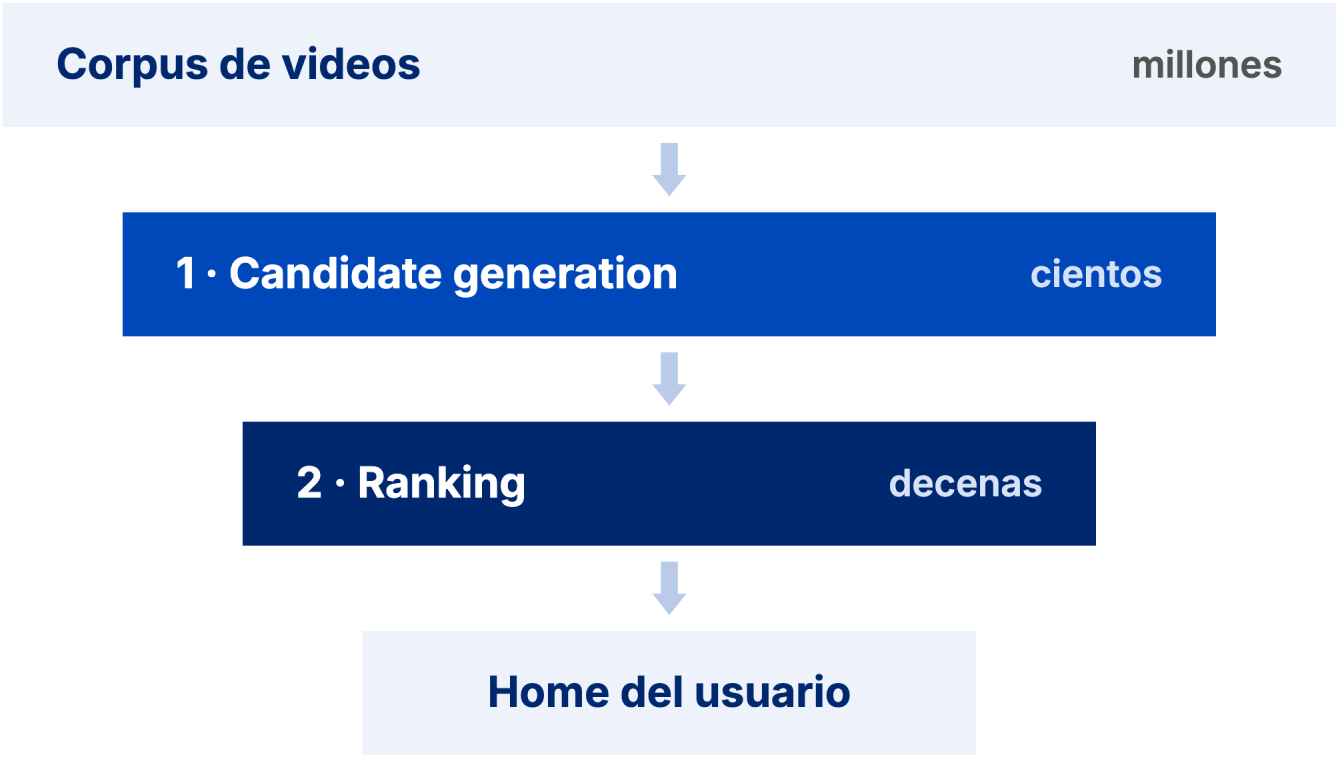
Red profunda

Generaliza MF de forma no lineal. Sin capas ocultas, rinde casi igual que el sistema anterior.

INSPIRACIÓN **word2vec (CBOW):** el historial es la "frase" y el próximo video es la "palabra" que se predice.

ARQUITECTURA DEL SISTEMA

Un embudo de dos etapas: millones → decenas



ETAPA 1

Barata y amplia: personaliza “a grandes rasgos” con vistas, búsquedas y demografía.

ETAPA 2

Cara y precisa: cientos de features por par. Además mezcla candidatos de otras fuentes.

Se decide con A/B test: offline y online no siempre coinciden

ETAPA 1 · CANDIDATE GENERATION

La red resume al usuario en un vector u

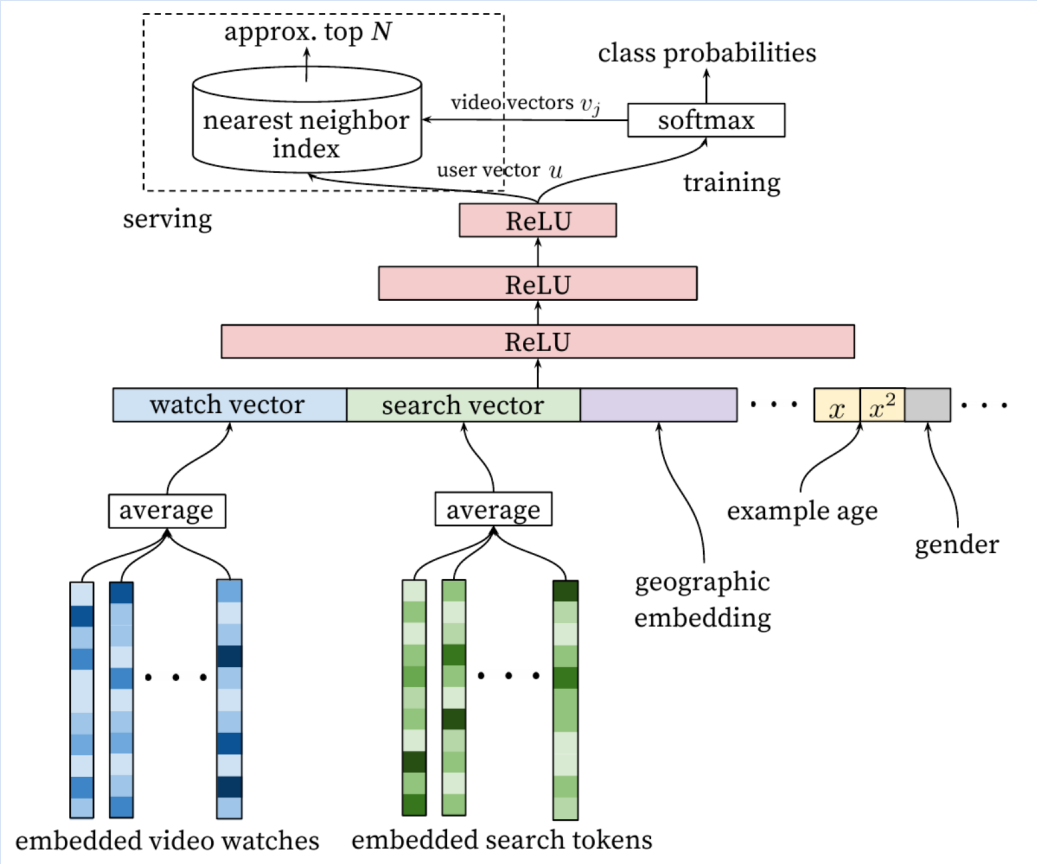


Fig. 3 del paper (Covington et al., 2016)

01 **Embeddings de 256 dim.** para 1M de videos y 1M de tokens de búsqueda: hasta 50 vistas y 50 búsquedas recientes.

02 **Promedio** de cada bolsa, concatenado con geografía, dispositivo, género, edad y example age.

03 **Torre ReLU** 1024 → 512 → 256 que produce u. Los embeddings se aprenden junto con la red.

Con 0 capas ocultas ≈ matrix factorization

ETAPA 1 · ENTRENAMIENTO Y SERVING

Entrenar con negativos, servir con vecinos

ENTRENAMIENTO

>100×

más rápido que el softmax completo

- Se muestrean miles de clases negativas
- Importance weighting corrige el sesgo del muestreo
- Hierarchical softmax rindió peor

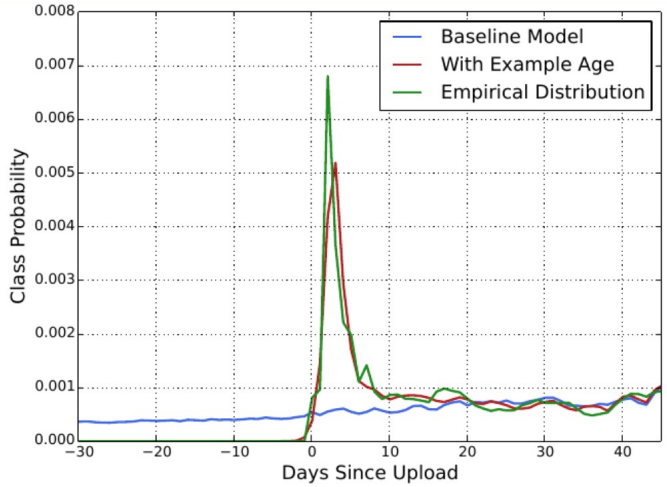
SERVING

decenas de ms

de latencia para puntuar millones de videos

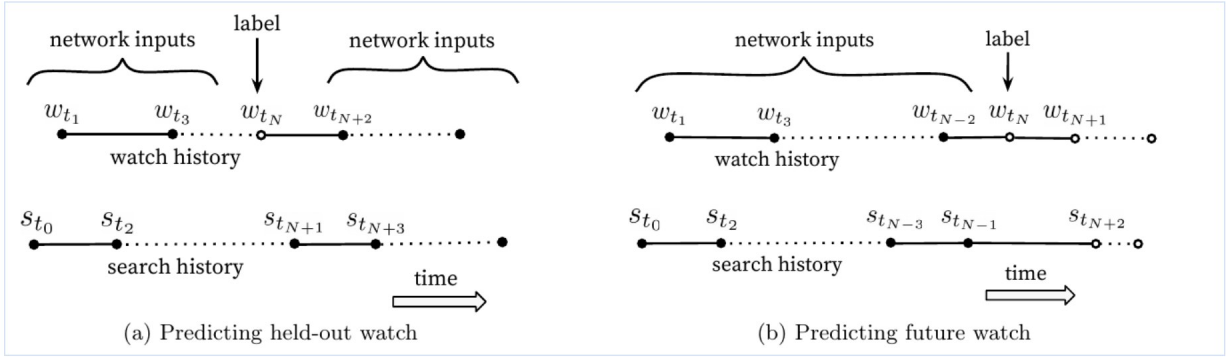
- No se necesitan probabilidades, solo el orden
- Top-N = mayores productos punto $u \cdot v_j$ en un índice de vecinos aproximados
- El A/B no fue sensible al algoritmo de vecinos

Dos decisiones de datos que pesan mucho



1 · Example age

Al entrenar: cada ejemplo lleva cuánto hace que ocurrió. Un video nuevo solo aparece en ejemplos recientes.
Al recomendar: se fija en 0 → “predice para ahora”.

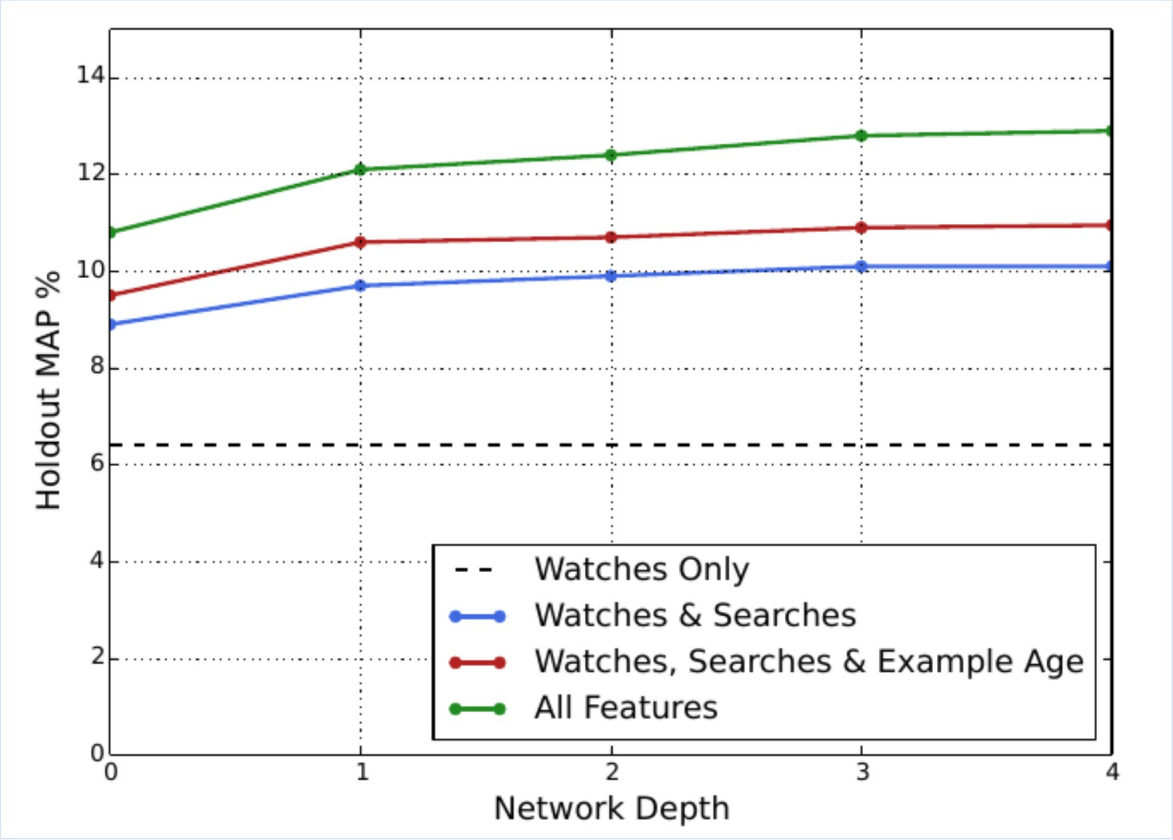


2 · Próxima vista (b), no una al azar (a)

Ocultar una vista al azar le da el futuro como input. El consumo es asimétrico: los episodios van en orden y se pasa de lo popular a lo nicho.

ETAPA 1 · RESULTADOS

Más features y más capas suben el MAP



~6% → ~13%

MAP de holdout, leído de la figura: solo vistas vs. todas las features con 4 capas

- Cada grupo de features suma: búsquedas, example age, demografía
- La profundidad ayuda más cuantas más features hay: las capas modelan sus interacciones
- Sin capas ocultas ≈ el sistema anterior de MF

ETAPA 2 · RANKING

En ranking manda la historia usuario–canal

LAS FEATURES MÁS ÚTILES

¿Cuántos videos de este canal vio?

¿Hace cuánto vio este tema?

¿Qué fuente lo propuso, y con qué score?

¿Cuántas veces se le mostró sin que lo viera? Esto genera rotación: las listas no se repiten.

CÓMO ENTRAN A LA RED

Categóricas → embeddings de dimensión ∝ log(vocabulario). Top-N IDs por clics; el resto va al vector cero.

Embeddings compartidos: un solo embedding de video para la impresión, el último visto y la semilla.

Continuas → cuantiles en [0, 1), más $\tilde{x}^2$ y $\sqrt{\tilde{x}}$.

ETAPA 2 · WEIGHTED LOGISTIC REGRESSION

Una regresión reponderada que predice minutos

1 · PESOS AL ENTRENAR

Impresión con clic

peso = T_i

minutos que la vio

Impresión sin clic

peso = 1

2 · QUÉ APRENDEN LOS ODDS

odds = ΣT_i / (N – k)

≈ E[T] · (1 + P)

≈ E[T]

N = impresiones, k = clics, P = tasa de clic. Como P es chica, los odds son el tiempo esperado.

3 · AL SERVIR

e^(Wx + b)

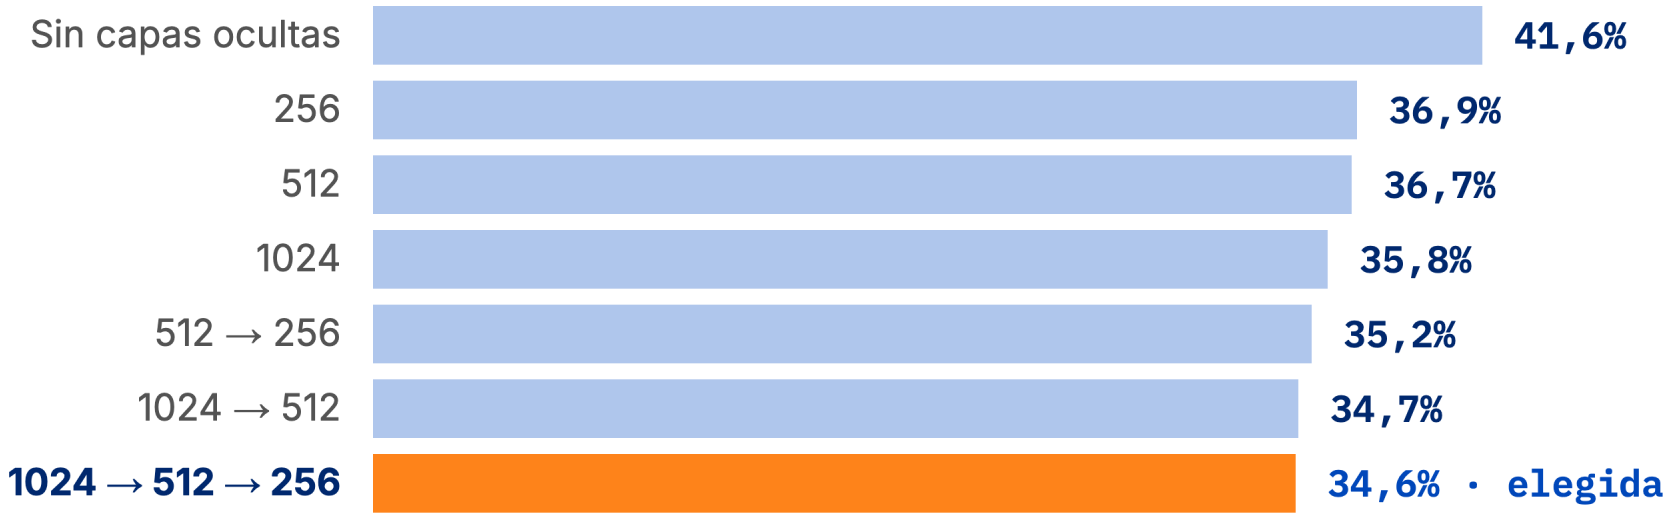
La activación final exponencial entrega directamente los minutos esperados.

No hace falta una loss nueva: solo cambian los pesos.

ETAPA 2 · RESULTADOS (TABLA 1)

Más ancho y profundo: pérdida de 41,6% a 34,6%

Pérdida ponderada por usuario: % del watch time mal predicho en pares (clic, sin clic) de una misma página. Menor es mejor.



Sin pesos por watch time: +4,1% de pérdida

Sin $\tilde{x}^2$ y $\sqrt{\tilde{x}}$: +0,2%

Límite: CPU de serving

CIERRE

Lecciones, críticas y lo que vino después

Lecciones

- El problema sustituto importa más que la arquitectura
- Ocultarle información a la red evita sobreajustar al sitio
- Optimizar minutos vistos, no clics

Críticas

- Poco reproducible: sin código replicable
- Promediar el historial pierde el orden
- El watch time puede premiar contenido adictivo

Legado

- Two-tower retrieval como estándar (Yi et al., 2019)
- Ranking multitarea con MMoE (Zhao et al., 2019)
- Generativos (TIGER, OneRec): siguen prediciendo el próximo ítem

BIBLIOGRAFÍA

Referencias

1. Covington, Adams y Sargin. Deep Neural Networks for YouTube Recommendations. RecSys 2016.
2. Davidson et al. The YouTube Video Recommendation System. RecSys 2010.
3. Weston, Bengio y Usunier. WSABIE: Scaling Up to Large Vocabulary Image Annotation. IJCAI 2011.
4. Mikolov et al. Distributed Representations of Words and Phrases. NIPS 2013.
5. Jean et al. On Using Very Large Target Vocabulary for Neural Machine Translation. 2014.
6. Zhao et al. Recommending What Video to Watch Next: A Multitask Ranking System. RecSys 2019.

SEMINARIO IIC3633 · SISTEMAS RECOMENDADORES

Deep Neural Networks for YouTube Recommendations

Covington, Adams y Sargin · Google · RecSys 2016

Victor Bórquez · Vicente Espinoza — Grupo 4 · 27 de octubre de 2026