



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE
ESCUELA DE INGENIERÍA
DEPARTAMENTO DE CIENCIA DE LA COMPUTACIÓN

IIC3633 Sistemas Recomendadores (2026-2)

Tarea 1

Indicaciones

- Fecha de entrega: **Viernes 11 de septiembre del 2026 , 20:00 horas.**
- La tarea debe realizarse **en grupos de dos personas**. Para inscribir sus grupos, deberán inscribirse en CANVAS a más tardar el día **viernes 21 de agosto a las 20:00** . Quiénes no tengan grupo para esa fecha, serán asignados de manera aleatoria.
- La copia será sancionada con una nota 1,1 en la tarea, además de las sanciones disciplinarias correspondientes.
- Entrega a través de CANVAS, en el buzón de la tarea correspondiente. Solamente deberá entregar uno de los estudiantes del grupo, con los nombres de ambos estudiantes en todos los archivos entregados.
- Cada hora o fracción de atraso descuenta 0,5 puntos de la nota obtenida, llegando a 1,0 en 12 horas. Se considera como entrega el último archivo subido por alguno de los miembros del grupo. No se revisarán tareas que hayan sido subidas con anterioridad a la última.
- Se debe hacer la tarea en Google Colab o en Jupyter Notebooks para facilitar la revisión. Deberán entregar estos notebooks ejecutados como parte de su código.
- Los datos entregados contienen más información de la estrictamente necesaria para el desarrollo de las actividades. Está permitido utilizar esta información extra si se desean mejorar los métodos descritos en las actividades. Sin embargo, debe existir una justificación para el uso de los mismos y además, los métodos de las actividades no pueden perder su estructura.
- Cualquier pregunta que les surja durante el desarrollo de la tarea la pueden hacer llegar mediante las **Issues** del repositorio del curso.
- **Uso de IA:** Se permite el uso de modelos de lenguaje como ayuda para el desarrollo de la tarea siempre y cuando se cumplan las siguientes condiciones:
 - Se debe compartir la conversación completa de cada una de las sesiones usadas (link de ChatGPT, Claude, Gemini, etc)

- El código y el informe debe ser redactado por ustedes. Se puede usar la IA para realizar consultas de contenido, ortografía y dudas de código, pero no se puede pedir a la IA que realice la tarea (o una parte de esta) por ustedes.
-

OBJETIVO

En esta tarea pondrán en práctica sus conocimientos sobre sistemas recomendadores utilizando un conjunto de datos pertenecientes a un sitio web de recetas. Experimentarán con recomendación no personalizada, basada en feedback implícito y explícito, y recomendación basada en contenido.

EVALUACIÓN

La calificación de esta tarea se dividirá en tres instancias. La primera corresponderá al 25 % de la nota y consistirá en una interrogación práctica sobre métricas de recomendación, la cual se evaluará el día por avisar (horario sujeto a disponibilidad DIPRE). La segunda corresponderá a otro 25 % de la nota y será una interrogación escrita con preguntas conceptuales de la materia. Finalmente, el 50 % restante se obtendrá a partir del desarrollo del práctico descrito en este enunciado.

Además, esta tarea incluye la posibilidad de aumentar la calificación mediante bonos, los cuales se detallan en la sección *Bonuses*.

DESCRIPCIÓN DEL CONJUNTO DE DATOS

En esta tarea utilizarán el dataset de recetas, el cual pueden descargar en este [enlace](#). Este se compone de los siguientes archivos:

- **Dataset de entrenamiento (train.csv):** registros que contienen la calificación entregada por un usuario a una receta. Cada fila incluye:
 - **user_id:** Identificador único del usuario.
 - **recipe_id:** Identificador único de la receta evaluada. Corresponde a la columna id del archivo de metadata.
 - **date:** Fecha en que el usuario evaluó la receta, en formato AAAA-MM-DD.
 - **rating:** Evaluación entregada por el usuario a la receta, en una escala entera de 0 a 5, donde valores mayores indican mayor preferencia.
- **Dataset de validación (validation.csv):** registros con el mismo formato que el dataset de entrenamiento. **Sobre este conjunto deben reportar todos los resultados de la tarea.**
- **Dataset de recetas (RAW_recipes.csv):** registros que contienen información descriptiva y nutricional de las recetas. Cada fila incluye:

- **name:** Nombre de la receta.
 - **id:** Identificador único de la receta. Corresponde a la columna `recipe_id` de los archivos de interacciones.
 - **minutes:** Tiempo estimado de preparación de la receta, en minutos.
 - **contributor_id:** Identificador único del usuario que publicó la receta.
 - **submitted:** Fecha de publicación de la receta.
 - **tags:** Lista de etiquetas asociadas a la receta, tales como tipo de cocina, ingredientes principales o tiempo de preparación.
 - **nutrition:** Lista con información nutricional de la receta, incluyendo calorías, grasas, azúcar, sodio, proteínas y carbohidratos.
 - **n_steps:** Número de pasos de preparación.
 - **steps:** Lista con los pasos necesarios para preparar la receta.
 - **description:** Descripción textual de la receta.
 - **ingredients:** Lista de ingredientes requeridos para preparar la receta.
 - **n_ingredients:** Número de ingredientes de la receta.
- **Embeddings de texto** (`food_bert_embeddings.npy`): archivo en formato NumPy con una matriz que contiene una representación vectorial del texto de cada receta (su nombre y su descripción), obtenida con un modelo **BERT**. Cada fila corresponde a una de las recetas que aparecen en los conjuntos de interacciones, y puede utilizarse como característica de contenido, ya sea directamente o como alternativa a las representaciones que ustedes construyan.
 - **Mapeo de los embeddings** (`food_item_id_to_idx.npy`): diccionario que asocia cada `recipe_id` con un índice entero. Este índice indica a qué fila de la matriz anterior corresponde cada receta, por lo que sin este archivo los embeddings no son utilizables.
 - **Dataset de testeo de ratings** (`competicion_rating.txt`): archivo que contiene pares de usuarios y artistas para los cuales se debe predecir la evaluación entregada por el usuario. Cada fila incluye los campos `user_id`, `item_id` y `rating`, donde la columna `rating` se encuentra vacía y debe ser completada con las predicciones del modelo para participar en el bonus de la tarea.
 - **Dataset de testeo de rankings** (`competicion_ranking.json`): archivo que contiene una lista de identificadores de usuarios. Para cada usuario se debe generar una lista con las 10 recomendaciones de artistas que el modelo estime más relevantes. Estas listas deben ser completadas para poder optar al bonus de la tarea.

RECOMENDADORES A IMPLEMENTAR

Algoritmos

Para la predicción de los ratings entregados por los usuarios se deben utilizar los siguientes algoritmos:

- User-based collaborative filtering
- Item-based collaborative filtering
- FunkSVD
- SVD++ (opcional)

Además, para la generación de las listas de recomendación se deben utilizar los siguientes algoritmos:

- Random
- Most Popular
- Item-based collaborative filtering
- FunkSVD
- ALS
- BPR
- Content-Based
- Factorization Machines (opcional)

Métricas

Para evaluar la predicción de ratings se deberá utilizar **RMSE** y **MAE**, mientras que para evaluar la generación de listas de recomendación se deberá utilizar **Recall@K**, **nDCG** y **MAP**. Además, deberán hacer uso de la información adicional de los artistas para obtener la Diversidad y Novedad de las listas de recomendación. Se trabajará con listas de 10 recomendaciones para cada usuario (Top-N recommendation).

LIBRERÍAS

Pueden utilizar cualquier librería en python implementadas para recomendación. Las más utilizadas son **PyReclab**, **Surprise**, **Implicit** y **LigthFM (opcional)**, pero esto queda a su criterio.

ENTREGABLES

La tarea deberá ser entregada a través de la plataforma CANVAS, se les solicita enviar los siguientes archivos:

1. Informe de análisis de los datos entregados y de los métodos utilizados
2. Código de los algoritmos implementados
3. Resultados de la evaluación de las predicciones

A continuación encontrarán una descripción detallada de cada uno de estos.

1. Informe (4.2 pts.)

El informe debe estar en formato pdf y deberá ser parte de la entrega en canvas. El informe tiene dos partes.

1.1. Análisis de datos (0.8 pts.)

La primera consiste en un análisis de los datos (tablas y gráficos) que incluya, al menos, estadísticas de los usuarios, de los ítems, densidad del dataset (ítems por usuario y usuarios por ítem), como por ejemplo la tabla Cuadro 1. Así mismo debes reportar gráficos de distribución, como las figuras Figura 1 y Figura 2.




Figura 1: Ejemplo de gráfico mostrando la distribución de ratings en un dataset ficticio.




Figura 2: Ejemplo de gráfico mostrando una distribución long-tail del número de ratings por usuario.

Statistic	Training	Validation
Number of Users	80	20
Number of Items	400	100
Total Ratings	960	240
Average Number of Ratings per User	12.0	12.0
Average Number of Ratings per Item	2.4	2.4
Average Rating	3.7	3.8
Rating Standard Deviation	0.5	0.6
Highest Number of Ratings by a User	45	20
Highest Number of Ratings for an Item	14	5
Density (%)	3.0 %	12.0 %

Cuadro 1: Ejemplo de tabla con estadísticas ficticias de un dataset.

Method	RMSE	Recall@10	NDCG@10	MAP@10	Diversity	Novelty
Method A	0.845	0.175	0.890	0.340	0.620	0.740
Method B	0.812	0.185	0.905	0.350	0.640	0.755
Method C	0.830	0.180	0.895	0.345	0.635	0.750
Method D	0.870	0.170	0.885	0.335	0.610	0.730
Method E	0.910	0.160	0.870	0.320	0.590	0.710

Cuadro 2: Ejemplo de tabla comparando métodos de recomendación en varias métricas.

1.2. Métodos RecSys (3.4 pts.)

En la segunda parte deben comparar y analizar los métodos utilizados respecto a, al menos, su rendimiento general y su implementación (dificultades y otros) Además, de las métricas respectivas:

- RMSE, MAP (Predicción de ratings)
- Recall@10, MAP@10 y nDCG@10 (Generación de rankings)
- Diversidad (cantidad de estilos distintos recomendados en promedio)
- Novedad (self-information): $\frac{1}{|U|} \sum_{u \in U} \sum_{i \in L} \log(1/p_{oi})$

Para reportar estas métricas debes entrenar con el dataset de entrenamiento y **reportar los resultados sobre el dataset de validación**. Debes reportar con una tabla similar a la tabla Cuadro 2.

DESCUENTOS. En caso de que las tablas de resultados se obtengan a partir de un subconjunto de los datos, optarás a un máximo de 2.4 puntos de los 3.4 puntos posibles de esta sección.

ANÁLISIS DE SENSIBILIDAD. Se espera que el informe contenga gráficos sobre el impacto de usar diferente número de vecinos (mínimo dos K en ItemKnn) y de factores latentes (mínimo tres números de factores en métodos como FunkSVD, ALS y BPR). Considerar también

Sensitivity Analysis: Latent Factors vs. Number of Neighbors




Figura 3: Ejemplo de gráfico 3D mostrando el efecto de dos variables sobre RMSE.

informar sobre impacto de hiperparámetros como learning rate y regularización (λ). Para esto es ideal gráficos como la Figura 3.

2. Código (1.8 pts.)

Por cada uno de los métodos solicitados debe entregar el código que permita replicar los resultados obtenidos. Se solicita entregar uno o varios jupyter notebooks que permitan replicar experimentos.

Es obligatorio agregar un archivo README.md que permita entender la estructura de archivos y detalles necesarios para replicar los experimentos realizados.

BONUSES

Recomendación híbrida (Bono de 0.5 pts.)

Cada familia de algoritmos que implementaron falla de una manera distinta. Los métodos colaborativos y de popularidad explotan bien la señal de consumo agregada, pero sólo pueden recomendar ítems que ya acumularon interacciones. La recomendación basada en contenido puede puntuar cualquier receta para la que exista metadata, pero ignora por completo lo que el resto de los usuarios opina de ella.

Para optar a este bono deben implementar **al menos un recomendador híbrido** que combine una señal de contenido con una colaborativa, reportarlo en la misma tabla de métricas que el resto de los métodos y compararlo contra los componentes que lo forman por separado.

La estrategia de hibridación es decisión de ustedes. Lo que se evalúa es el análisis: por qué esperaban que funcionara en *este* dataset y qué pasó realmente.

Competición (Bono para Top5)

Para optar a una bonificación, los grupos deberán enviar sus predicciones y recomendaciones de recetas completando los archivos `competicion_rating.txt` y `competicion_ranking.json` con los resultados obtenidos por su mejor modelo. Deben enviarse ambos archivos para participar en la competición.

Las bonificaciones se otorgarán a los cinco mejores trabajos según la siguiente distribución:

- 1.5 punto para el primer lugar
- 1 puntos para el segundo lugar
- 0.75 punto para el tercer lugar
- 0.4 puntos para el cuarto lugar
- 0.15 puntos para el quinto lugar

Para esta parte pueden ir más allá de los algoritmos analizados previamente y experimentar con ensambles (ver **ensemble learning**) y utilizar otras técnicas no vistas en clases, como SVD++ o Factorization Machines. A continuación se detallan los archivos:

- `competicion_rating.txt`: Este archivo tiene el fomarto de `user_id, item_id, rating`, pero con los valores de ratings vacios. La columna **rating** deberá ser llenada con sus predicciones de ratings para los correspondientes usuarios y recetas.

```
user_id,item_id,rating
356857,1017874,
699019,1011623,
699019,1016776,
356857,1015560,
1725629,1012481,
699019,1036157,
1396811,1017645,
1396811,1005598,
356857,1009238,
1364128,1042908,
392323,1029239,
76592,1008412,
699019,1013384,
566205,1043718,
1637889,1053203,
76592,1008877,
76592,1097970,
```

Figura 4: Inicio del archivo `competicion_rating.txt`

- `competicion_ranking.json`: Este archivo contiene una lista de IDs de usuarios y columnas vacías con enumeración del 1 al 10. Se deben completar las columnas vacías con el top 10 de recomendaciones para el usuario del ID correspondiente, siendo la recomendación de la columna 1 la más deseada a recomendar y la de la columna 10 la menos deseada.


```
1  {  
2    "59": [],  
3    "85": [],  
4    "2195": [],  
5    "163": [],  
6    "135": [],  
7    "94344": [],  
8    "885235": [],  
9    "438": [],  
10   "5207": [],  
11   "180": [],  
12   "1350136": [],  
13   "483": [],  
14   "99654": [],  
15   "446": [],  
16   "27817": [],  
17   "553": [],
```

Figura 5: Inicio del archivo competicion_ranking.json